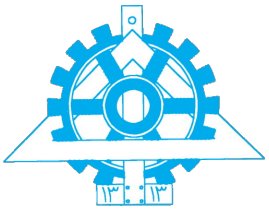


دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۱

نام و نام خانوادگی

محمدمهدی یاری

شماره دانشجویی

۸۱۰۱۰۲۵۳۲

۱۵ آبان ۱۴۰۴

فهرست مطالب

چکیده ۱

۱ Question 1: Bayes Rule vs. Random Decisions ۲

۱.۱ 1.1. Show that this risk R_{rand} is always no smaller than the Bayes risk R_{Bayes} ۳

۲.۱ 1.2. Under what conditions on the posterior are the two decision rules the same? ۶

۲ Question 2: Bayes Boundaries for Gaussian Classes ۶

۱.۲ Q۲.۱: Derivation of the threshold ۶

۲.۲ Q۲.۲: 2D Gaussian Classification ۸

۱.۲.۲ (a) Write the two discriminant functions $g_1(\mathbf{x})$ and $g_2(\mathbf{x})$ ۸

۲.۲.۲ (b) Derive the equation for the decision boundary $g_1(\mathbf{x}) = g_2(\mathbf{x})$ ۱۰

۳.۲.۲ (c) How would the boundary decision change if we changed the priors؟ the covariances؟ ۱۰

۴.۲.۲ (d) Using computer software، sample ۱۰۰ points... . ۱۱

۳ Question 3: Naive Bayes Parameter Estimation (MLE) ۱۲

۱.۳ 3.1. Write the Joint Log-Likelihood Function $\ell(\phi)$ ۱۲

۲.۳ 3.2. Show that the MLEs correspond to the empirical frequencies ۱۳

۴ Question 4: Modeling Goals with MLE ۱۵

۱.۴ 4.1. Derive an expression for the maximum-likelihood estimate of the parameter λ ۱۵
۲.۴ 4.2. Give a numerical estimate of λ after the first five games and find the probability ۱۶
۳.۴ 4.3. Give an updated numerical estimate of λ after six games ۱۶

۵ Question 5: MLE Derivation of the Least Squares Loss **۱۷**
۱.۵ 5.1. Write the likelihood $p(y^{(i)}|\mathbf{x}^{(i)}; \boldsymbol{\theta}, \sigma^2)$ ۱۷
۲.۵ 5.2. Show that maximizing the log-likelihood is equivalent to minimizing MSE ۱۷

۶ Question 6: Effect of Priors on the Decision Boundary **۱۸**
۱.۶ 6.1. Derive the decision boundary condition (x^*) ۱۸
۲.۶ 6.2. Explain how the value of x^* shifts ۱۹

۷ Question 7: Naive Bayes Warm-Up **۲۰**
۱.۷ 7.1. Bayes' Rule for Drug Test ۲۰
۲.۷ 7.2. Naive Bayes Classification ۲۱

۸ Question 8: Classifying Spam with Naive Bayes **۲۲**
۱.۸ Q۸.۱: خواندن و پارس کردن دیتا ۲۲
۲.۸ Q۸.۲: محاسبه احتمالات پیشین (Priors) ۲۳
۳.۸ Q۸.۳: محاسبه احتمالات شرطی (Likelihoods) ۲۳
۴.۸ Q۸.۴: تست مدل و تحلیل دقت ۲۴
۵.۸ Q۸.۵: تأثیر پارامتر هموارسازی (m) ۲۵
۶.۸ Q۸.۶: چگونه دسته‌بند را فریب دهیم؟ ۲۶

۹ Question 9: Cloud vs. Clear Sky **۲۶**
۱.۹ قدم ۰: آماده‌سازی و تقسیم دیتا ۲۷
۲.۹ Q۹.۱: طراحی و «آموزش» معیار اول (میانگین رنگ آبی) ۲۷
۳.۹ Q۹.۲: تست معیار اول (رنگ آبی) ۲۸

۴.۹ Q۹.۳: طراحی و «آموزش» معیار دوم (اشباع رنگ) ۲۸
۵.۹ Q۹.۴: تست و تحلیل خطای معیار دوم (اشباع رنگ) ۲۹
۶.۹ Q۹.۵: مقایسه‌ی نهایی مدل‌ها ۳۰

مراجع **۳۱**

فهرست تصاویر

۱ نمودار دقت بر حسب k (در مقیاس لاگاریتمی). ۲۵
۲ یک نمونه تصویر از دیتاست آموزشی به همراه برچسب آن. ۲۷
۳ ۴ تصویری که توسط معیار ۲ (اشباع) اشتباه دسته‌بندی شدند. ۲۹

فهرست جداول

۱ ۵ کلمه‌ی محتمل‌تر در هر کلاس بر اساس $P(w_i|c)$. ۲۴
۲ تأثیر k (پارامتر هموارسازی) بر دقت نهایی مدل. ۲۵
۳ مقایسه‌ی عملکرد دو معیار طراحی شده. ۳۰

چکیده

هدف از این مجموعه تمرین، درک عمیق و پیاده‌سازی مفاهیم اساسی «تئوری تصمیم بیزی» و «تخمین بیشینه درست‌نمایی» (MLE) بود.

در بخش‌های تئوری، مفاهیمی چون قانون بیز، ریسک تصمیم (Risk) و توابع تشخیص گوسی بررسی شدند. نشان داده شد که ماکزیمم کردن تابع درست‌نمایی در رگرسیون خطی، با فرض نویز گوسی، معادل مینیمم کردن خطای میانگین مربعات (MSE) است. همچنین ثابت شد که تخمین پارامترها با روش MLE برای مدل‌های نایو بیز برنولی و پواسون، دقیقاً معادل محاسبه‌ی فراوانی‌های تجربی (میانگین نمونه) است.

در بخش‌های پیاده‌سازی، یک فیلتر اسپم کامل به روش «بیزِ ساده‌لوحانه چندجمله‌ای» پیاده‌سازی شد. در این فرآیند، از هموارسازی لاپلاس (m-estimate) برای مقابله با احتمال صفر و از لاگ‌ـاحتمالات برای جلوگیری از خطای عددی (underflow) استفاده گردید. در نهایت، یک دسته‌بندی ابتکاری (heuristic) برای تشخیص تصاویر «ابری» از «صاف»، تنها با استفاده از معیارهای ساده و قابل تفسیر مبتنی بر رنگ (مانند میانگین اشباع در فضای HSV) طراحی، تست و تحلیل شد.

Question 1: Bayes Rule vs. Random Decisions

ما در این سوال با تابع (zero-one loss function) کار داریم که این یعنی ما کلاً دو تا حالت داریم که اگه تصمیم‌مون درست بود خطای ما 0 هست و اگر تصمیم‌مون اشتباه باشه خطامون 1 هست.

برای اینکه ریسک رو حساب کنیم، انگار میاییم امید ریاضی میزان خطامون رو حساب می‌کنیم و چون اینجا ما توزیع برنولی داریم، امید ریاضی می‌شه:

$$R = E[\text{Loss}] = (1 \times P(\text{Error})) + (0 \times P(\text{Correct})) = P(\text{Error})$$

و همچنین می‌دونیم که:

$$R = 1 - P(\text{Correct})$$

حالا میاییم احتمال اینکه اگه x رو دیده باشیم و درست باشه رو حساب می‌کنیم (همون $P(\text{Correct}|x)$). این برابر با اینه که دوتا اتفاق زیر بیوفته: اول اینکه هم کلاس واقعی سیگنال برابر با ω_i باشه و هم ما دقیقاً همین کلاس رو از بین K تا کلاس انتخاب کرده باشیم. پس چون ما باید برای همه کلاس‌ها این عبارت رو حساب کنیم، در واقع یک سیگمایی داریم که:

$$P(\text{Correct}|x) = \sum_{i=1}^{K} P(\text{Class True} = \omega_i \text{ and Guess Our} = \omega_i|x)$$

چون این دوتا اتفاقی که گفتیم (یعنی انتخاب شانسی ما و اینکه اون کلاس واقعاً درست باشه) از هم مستقلند، پس تو هم ضرب‌شون می‌کنیم.

عبارت اول همون احتمال پسین هست که می‌شه:

$$P(\text{Class True} = \omega_i|x) = p(\omega_i|x)$$

عبارت دوم هم که توی صورت سوال گفته شده و برابر است با:

$$P(\text{Guess Our} = \omega_i|x) = p(\omega_i|x)$$

پس سیگما می‌شه:

$$P(\text{Correct}|x) = \sum_{i=1}^{K} p(\omega_i|x) \cdot p(\omega_i|x) = \sum_{i=1}^{K} p(\omega_i|x)^2$$

حالا داریم:

$$R(\alpha_{rand}|x) = 1 - \sum_{i=1}^{K} p(\omega_i|x)^2$$

و با انتگرال، ریسک کلی رو حساب می‌کنیم:

$$R_{rand} = \int R(\alpha_{rand}|x)p(x)dx = \int \left(1 - \sum_{i=1}^{K} p(\omega_i|x)^2\right) p(x)dx$$

1.1. Show that this risk R_{rand} is always no smaller than the Bayes risk R_{Bayes} ۱.۱

(توجه: بخش ۱.۱ و ۲.۱ و ۳.۱ مربوط به سوال ۱ هستند)

در این بخش می‌خوایم ثابت کنیم که ریسک (خطای) قانون تصادفی ما، هیچ‌وقت بهتر از ریسک قانون بهینه‌ی بیز نیست. یعنی باید ثابت کنیم:

$$R_{rand} \geq R_{Bayes}$$

برای این کار، کافیه ریسک شرطی اون‌ها رو برای یک x دلخواه مقایسه کنیم. یعنی ثابت می‌کنیم که:

$$R(\alpha_{rand}|x) \geq R(\alpha_{Bayes}|x)$$

ما فرمول $R(\alpha_{rand}|x)$ رو از بخش قبل داریم. پس اول باید فرمول $R(\alpha_{Bayes}|x)$ رو به دست بیاریم.

قانون بیز، برخلاف قانون تصادفی، خیلی قاطع عمل می‌کنه. این قانون میاد احتمال پسین $p(\omega_i|x)$ رو برای همه‌ی K کلاس حساب می‌کنه و کلاسی رو انتخاب می‌کنه که بیشترین احتمال رو داره.

$$\alpha_{Bayes}(x) = \omega^* = \arg\max_i p(\omega_i|x)$$

بیاییم اون احتمال ماکزیمم رو $p_{\max}$ بنامیم:

$$p_{\max} = \max_i p(\omega_i|x)$$

حالا، احتمال درست بودن برای قانون بیز چقدره؟ قانون بیز همیشه کلاس ω^* رو حدس می‌زنه. این حدس فقط زمانی درسته که کلاس واقعی هم دقیقاً همون ω^* باشه. پس:

$$P_{Bayes}(\text{Correct}|x) = P(\text{Class True} = \omega^*|x) = p_{\max}$$

و ریسک (احتمال خطا) برای قانون بیز می‌شه:

$$R(\alpha_{Bayes}|x) = 1 - P_{Bayes}(\text{Correct}|x) = 1 - p_{\max}$$

$$R(\alpha_{Bayes}|x) = 1 - \max_i p(\omega_i|x)$$

حالا باید این نامساوی رو ثابت کنیم:

$$R(\alpha_{rand}|x) \geq R(\alpha_{Bayes}|x)$$

داریم:

$$1 - \sum_{i=1}^{K} p(\omega_i|x)^2 \geq 1 - \max_i p(\omega_i|x)$$

$$\sum_{i=1}^{K} p(\omega_i|x)^2 \leq \max_i p(\omega_i|x)$$

برای سادگی، $p_i = p(\omega_i|x)$ و $p_{\max} = \max p_i$ می‌نویسیم.
ما می‌دونیم که $p_{\max}$ بزرگترین p_i در بین همه است. پس برای هر i داریم: $p_i \leq p_{\max}$.

حالا از سمت چپ نامساوی شروع می‌کنیم:

$$\sum_{i=1}^{K} p_i^2 = \sum_{i=1}^{K} (p_i \cdot p_i)$$

چون $p_i \leq p_{\max}$، می‌تونیم p_i دوم رو با $p_{\max}$ جایگزین کنیم، که این کار حاصل عبارت رو بزرگتر یا مساوی می‌کنه:

$$\sum_{i=1}^{K} (p_i \cdot p_i) \leq \sum_{i=1}^{K} (p_i \cdot p_{\max})$$

حالا $p_{\max}$ رو از سیگما فاکتور می‌گیریم (چون یک عدد ثابته):

$$\sum_{i=1}^{K} (p_i \cdot p_{\max}) = p_{\max} \cdot \left(\sum_{i=1}^{K} p_i \right)$$

و همونطور که می‌دونیم، مجموع تمام احتمالات پسین همیشه برابر 1 است:

$$\sum_{i=1}^{K} p_i = 1$$

پس در نهایت داریم:

$$p_{\max} \cdot \left(\sum_{i=1}^{K} p_i \right) = p_{\max} \cdot 1 = p_{\max}$$

اینطوری ثابت کردیم که $\sum p_i^2 \leq p_{\max}$ و در نتیجه نامساوی اصلی هم اثبات شد.

$$R(\alpha_{rand}|x) \geq R(\alpha_{Bayes}|x)$$

1.2. Under what conditions on the posterior are the two decision rules the same? ۲.۱

در اثبات بخش قبلی این عبارت رو در نظر بگیرید:

$$\sum_{i=1}^{K}(p_i \cdot p_i) \leq \sum_{i=1}^{K}(p_i \cdot p_{\max})$$

این نامساوی زمانی به تساوی تبدیل می‌شه که تک‌تک جملات داخل سیگما با هم برابر باشند. یعنی برای همه‌ی i ها (از 1 تا K) باید این برقرار باشه:

$$p_i \cdot p_i = p_i \cdot p_{\max}$$

پس یعنی یا p_i ها باید 0 باشن یا اینکه برابر با $p_{\max}$ باشن. که ما 0 رو در نظر نمیگیریم چون در اون صورت اصلا کلاس در نظر نمیگرفتیم. پس به طور کلی ریسک دو قانون زمانی برابر است که تمام احتمالات پسینِ غیرصفر ($p(\omega_i|x) > 0$)، با همدیگر برابر باشند.

Question 2: Bayes Boundaries for Gaussian Classes

Q۲.۱: Derivation of the threshold ۱.۲

مرز تصمیم، نقطه‌ی x (که ما بهش می‌گیم τ) هست که در اون، ریسک مورد انتظار برای هر دو تصمیم با هم برابر می‌شه.

$$R(\alpha_1|x) = R(\alpha_2|x)$$

که α_1 یعنی تصمیم بگیریم کلاس ω_1 است و α_2 یعنی تصمیم بگیریم ω_2 است.

$$R(\alpha_i|x) = \sum_{j=1}^{2} \lambda_{ij} P(\omega_j|x)$$

$$R(\alpha_1|x) = \lambda_{11} P(\omega_1|x) + \lambda_{12} P(\omega_2|x)$$

$$R(\alpha_2|x) = \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x)$$

$$\lambda_{11}P(\omega_1|x) + \lambda_{12}P(\omega_2|x) = \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x)$$

با فرض $\lambda_{11} = 0$ و $\lambda_{22} = 0$:

$$0 \cdot P(\omega_1|x) + \lambda_{12}P(\omega_2|x) = \lambda_{21}P(\omega_1|x) + 0 \cdot P(\omega_2|x)$$

$$\lambda_{12}P(\omega_2|x) = \lambda_{21}P(\omega_1|x)$$

طبق بیز داریم:

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{p(x)}$$

$$\lambda_{12}\frac{p(x|\omega_2)P(\omega_2)}{p(x)} = \lambda_{21}\frac{p(x|\omega_1)P(\omega_1)}{p(x)}$$

$$\lambda_{12}p(x|\omega_2)P(\omega_2) = \lambda_{21}p(x|\omega_1)P(\omega_1)$$

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} = \frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}$$

حالا فرمول PDF گوسی ($N(0, \sigma^2)$ برای ω_1 و $N(1, \sigma^2)$ برای ω_2) جایگذاری می‌کنیم:

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu_i)^2}{2\sigma^2}\right)$$

$$\frac{\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-0)^2}{2\sigma^2}\right)}{\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-1)^2}{2\sigma^2}\right)} = \frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}$$

$$\exp\left(-\frac{x^2}{2\sigma^2} - \left(-\frac{(x-1)^2}{2\sigma^2}\right)\right) = \frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}$$

$$\exp\left(\frac{(x-1)^2 - x^2}{2\sigma^2}\right) = \frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}$$

از دو طرف ln می‌گیریم:

$$\frac{(x-1)^2 - x^2}{2\sigma^2} = \ln\left(\frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}\right)$$

$$(x-1)^2 - x^2 = (x^2 - 2x + 1) - x^2 = 1 - 2x$$

جایگذاری می‌کنیم (و x رو به τ تغییر می‌دیم):

$$\frac{1-2\tau}{2\sigma^2} = \ln\left(\frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}\right)$$

$$1-2\tau = 2\sigma^2 \ln\left(\frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}\right)$$

$$2\tau = 1-2\sigma^2 \ln\left(\frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}\right)$$

$$\tau = \frac{1}{2} - \sigma^2 \ln\left(\frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}\right)$$

۲.۲ Classification Gaussian ۲D Q۲.۲:

۱.۲.۲ Write (a) two the discriminant functions $g_2(\mathbf{x})$ and $g_1(\mathbf{x})$

تابع تشخیص $g_i(\mathbf{x})$ تابعیه که به ازای هر ورودی $\mathbf{x}$، یک امتیاز به کلاس ω_i می‌ده.

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

فرمول PDF گوسی چندمتغیره (که $d = 2$ است) اینه:

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu_i)^T\Sigma_i^{-1}(\mathbf{x}-\mu_i)\right)$$

از این ln می‌گیریم:

$$\ln p(\mathbf{x}|\omega_i) = -\frac{1}{2}(\mathbf{x}-\mu_i)^T\Sigma_i^{-1}(\mathbf{x}-\mu_i) - \frac{d}{2}\ln(2\pi) - \frac{1}{2}\ln|\Sigma_i|$$

پس $g_i(\mathbf{x})$ کامل این می‌شه:

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x}-\mu_i)^T\Sigma_i^{-1}(\mathbf{x}-\mu_i) - \frac{d}{2}\ln(2\pi) - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$$

سوال گفته که ($\Sigma_1 = \Sigma_2 = \Sigma$). به خاطر همین، ترم‌های $\frac{d}{2}\ln(2\pi)$ و $\frac{1}{2}\ln|\Sigma|$ برای g_1 و g_2 ثابت و یکسان هستن و حذف می‌شن:

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x}-\mu_i)^T\Sigma^{-1}(\mathbf{x}-\mu_i) + \ln P(\omega_i)$$

همچنین سوال گفته $\Sigma = 3I$. پس وارون اون می‌شه $\Sigma^{-1} = \frac{1}{3}I$.

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x}-\mu_i)^T\left(\frac{1}{3}I\right)(\mathbf{x}-\mu_i) + \ln P(\omega_i)$$

$$g_i(\mathbf{x}) = -\frac{1}{6}(\mathbf{x}-\mu_i)^T(\mathbf{x}-\mu_i) + \ln P(\omega_i)$$

$$g_i(\mathbf{x}) = -\frac{1}{6}(\mathbf{x}^T\mathbf{x} - 2\mu_i^T\mathbf{x} + \mu_i^T\mu_i) + \ln P(\omega_i)$$

$$g_i(\mathbf{x}) = \left(-\frac{1}{6}\mathbf{x}^T\mathbf{x}\right) + \frac{1}{3}\mu_i^T\mathbf{x} - \frac{1}{6}\mu_i^T\mu_i + \ln P(\omega_i)$$

ترم $\left(-\frac{1}{6}\mathbf{x}^T\mathbf{x}\right)$ هم در g_1 و هم در g_2 مشترکه پس حذف می‌شه. فرم نهایی و خطی $g_i(\mathbf{x})$ این می‌شه:

$$g_i(\mathbf{x}) = \frac{1}{3}\mu_i^T\mathbf{x} - \frac{1}{6}\mu_i^T\mu_i + \ln P(\omega_i)$$

حالا مقادیر رو جایگذاری می‌کنیم:

- $\mu_1 = \begin{bmatrix}4\\11\end{bmatrix}$، $P(\omega_1) = 0.6$
- $\mu_1^T\mathbf{x} = 4x_1 + 11x_2$
- $\mu_1^T\mu_1 = 4^2 + 11^2 = 137$

$$g_1(\mathbf{x}) = \frac{1}{3}(4x_1 + 11x_2) - \frac{1}{6}(137) + \ln(0.6)$$

$$g_1(\mathbf{x}) = \frac{4}{3}x_1 + \frac{11}{3}x_2 - \frac{137}{6} + \ln(0.6)$$

- $\mu_2 = \begin{bmatrix}10\\3\end{bmatrix}$، $P(\omega_2) = 0.4$

- $\mu_2^T \mathbf{x} = 10x_1 + 3x_2$
- $\mu_2^T \mu_2 = 10^2 + 3^2 = 109$

$$g_2(\mathbf{x}) = \frac{1}{3}(10x_1 + 3x_2) - \frac{1}{6}(109) + \ln(0.4)$$
$$g_2(\mathbf{x}) = \frac{10}{3}x_1 + x_2 - \frac{109}{6} + \ln(0.4)$$

۲.۲.۲ (b) Derive the equation for the boundary decision $g_1(\mathbf{x}) = g_2(\mathbf{x})$

$$\left(\frac{10}{3} - \frac{4}{3}\right) x_1 = \frac{6}{3}x_1 = 2x_1$$
$$\left(1 - \frac{11}{3}\right) x_2 = \left(\frac{3}{3} - \frac{11}{3}\right) x_2 = -\frac{8}{3}x_2$$
$$\left(-\frac{109}{6} - \left(-\frac{137}{6}\right)\right) + (\ln(0.4) - \ln(0.6))$$
$$= \left(\frac{137 - 109}{6}\right) + \ln\left(\frac{0.4}{0.6}\right)$$
$$= \frac{28}{6} + \ln\left(\frac{2}{3}\right) = \frac{14}{3} + \ln\left(\frac{2}{3}\right)$$

معادله نهایی ($g_2(\mathbf{x}) - g_1(\mathbf{x}) = 0$):

$$2x_1 - \frac{8}{3}x_2 + \frac{14}{3} + \ln\left(\frac{2}{3}\right) = 0$$

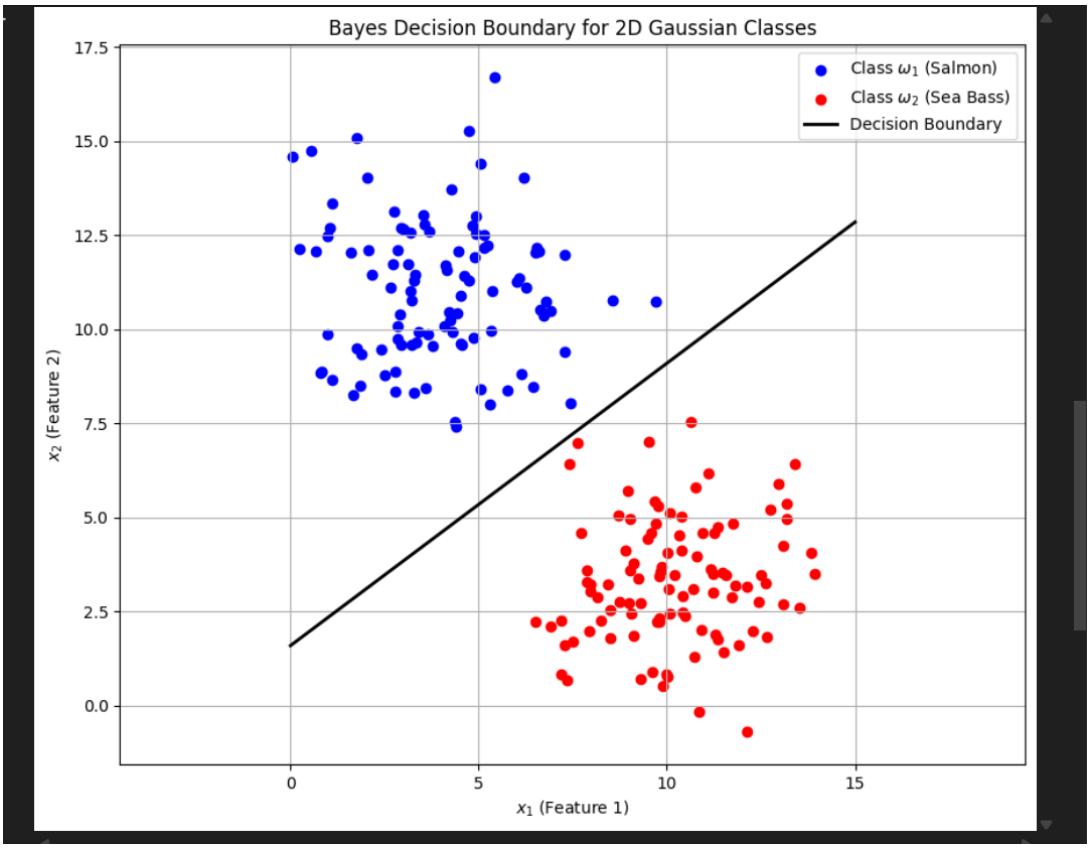
۳.۲.۲ (c) How would the boundary decision change if we change the priors? the covariances?

۱. اگر احتمالات پیشین (Priors) را عوض کنیم اگه به معادله مرزی $g_1(\mathbf{x}) = g_2(\mathbf{x})$ نگاه کنیم، $P(\omega_1)$ و $P(\omega_2)$ فقط در جمله ثابت معادله (عرض از مبدأ) ظاهر می‌شوند و روی شیب (ضرایب x_1 و x_2) تاثیری ندارند. پس عوض کردن Priors، شیب خط را تغییر نمی‌دهد، بلکه فقط باعث جابجایی موازی خط مرزی می‌شود.

۲. اگر ماتریس‌های کوواریانس (Σ_i) را عوض کنیم این تغییر اساسی‌تر است. ما در بخش (a) فرض کردیم $\Sigma_1 = \Sigma_2$ و به همین دلیل توانستیم ترم‌های درجه دوم (مثل $\mathbf{x}^T\mathbf{x}$) را از دو طرف ساده کنیم و به یک مرز خطی برسیم. اگه $\Sigma_1 \neq \Sigma_2$ باشد، دیگر نمیتوانیم این ترم‌های درجه دوم را ساده کنیم. پس ترم‌های درجه دوم (مثل x_1^2, x_2^2, x_1x_2) در معادله‌ی مرز باقی می‌مانند. این یعنی مرز تصمیم ما دیگر یک «خط راست» (Linear) نخواهد بود، بلکه یک «تابع درجه دوم» (Quadratic) خواهد شد (مثلاً سهمی یا هذلولی).

۴.۲.۲ (d) Using computer، software sample ۱۰۰ points...

در این بخش، ۱۰۰ نمونه تصادفی از هر کدام از دو توزیع گوسی (ω_1 و ω_2) تولید کردیم. سپس این نقاط را به همراه مرز تصمیم خطی که در بخش (b) به دست آوردیم، در یک نمودار دوبعدی رسم کردیم. همانطور که در شکل پایین مشاهده می‌شود، خط مرزی به خوبی دو کلاس را از هم جدا می‌کند و مراکز داده (آبی در $\begin{bmatrix}4\\11\end{bmatrix}$ و قرمز در $\begin{bmatrix}10\\3\end{bmatrix}$) به درستی نمایش داده شده‌اند.



Question 3: Naive Bayes Parameter Estimation (MLE)

۱.۳ 3.1. Write the Joint Log-Likelihood Function $\ell(\phi)$

فرض می‌کنیم N نمونه آموزشی داریم و همه‌ی نمونه‌ها از هم مستقل (I.I.D.) هستند. پس احتمال کل دیتا برابر است با حاصل‌ضرب احتمال تک‌تک نمونه‌ها:

$$L(\phi) = P(\text{کل دیتا}|\phi) = \prod_{i=1}^{N} P(\mathbf{x}^{(i)}, y^{(i)}|\phi)$$

که در آن $y^{(i)}$ برچسب (کلاس) و $\mathbf{x}^{(i)}$ بردار ویژگی‌های نمونه iـام است.

حالا از دو طرف ln می‌گیریم. لگاریتم، حاصل‌ضرب ($\prod$) را به حاصل‌جمع ($\sum$) تبدیل می‌کند:

$$\ell(\phi) = \ln(L(\phi)) = \ln\left(\prod_{i=1}^{N} P(\mathbf{x}^{(i)}, y^{(i)}|\phi)\right)$$

$$\ell(\phi) = \sum_{i=1}^{N} \ln P(\mathbf{x}^{(i)}, y^{(i)}|\phi)$$

با استفاده از قانون $P(A,B) = P(A|B)P(B)$، عبارت داخل لگاریتم را می‌شکنیم:

$$\ell(\phi) = \sum_{i=1}^{N} \ln\left(P(\mathbf{x}^{(i)}|y^{(i)}, \phi) \cdot P(y^{(i)}|\phi)\right)$$

و چون $\ln(A \cdot B) = \ln(A) + \ln(B)$، جمع را باز می‌کنیم:

$$\ell(\phi) = \sum_{i=1}^{N} \left[\ln P(\mathbf{x}^{(i)}|y^{(i)}, \phi) + \ln P(y^{(i)}|\phi)\right]$$

اینجا از فرض Bayes Naive استفاده میکنیم :

$$P(\mathbf{x}^{(i)}|y^{(i)}) = \prod_{j=1}^{M} P(x_j^{(i)}|y^{(i)}, \phi)$$

(که M تعداد کل ویژگی‌ها است).

حالا این حاصل‌ضرب را در معادله‌ی $\ell(\phi)$ جایگذاری می‌کنیم:

$$\ell(\phi) = \sum_{i=1}^{N} \left[\ln \left(\prod_{j=1}^{M} P(x_j^{(i)}|y^{(i)}, \phi) \right) + \ln P(y^{(i)}|\phi) \right]$$

$$\ell(\phi) = \sum_{i=1}^{N} \left[\left(\sum_{j=1}^{M} \ln P(x_j^{(i)}|y^{(i)}, \phi) \right) + \ln P(y^{(i)}|\phi) \right]$$

$$\ell(\phi) = \sum_{i=1}^{N} \sum_{j=1}^{M} \ln P(x_j^{(i)}|y^{(i)}, \phi) + \sum_{i=1}^{N} \ln P(y^{(i)}|\phi)$$

۲.۳ 3.2. Show that the MLEs correspond to the empirical frequencies

هدف ما ماکزیمم کردن تابع $\ell(\phi)$ است که در بخش ۱ به دست آوردیم. نکته کلیدی این است که $\ell(\phi)$ به دو بخش مجزا تفکیک می‌شود: یکی برای پارامتر پیشین (ϕ_y) و دیگری برای پارامترهای ویژگی ($\phi_{j|y}$). ما می‌توانیم هر کدام را جداگانه ماکزیمم کنیم.

الف) تخمین پارامتر پیشین

$$\ell_y(\phi_y) = \sum_{i=1}^{N} \ln P(y^{(i)}|\phi_y)$$

برای مدل برنولی می‌دانیم: $P(y^{(i)} = 1) = \phi_y$ و $P(y^{(i)} = 0) = 1 - \phi_y$. بیایید N_1 را تعداد نمونه‌هایی که $y^{(i)} = 1$ هستند و N_0 را $y^{(i)} = 0$ بنامیم.

$$\ell_y(\phi_y) = N_1 \cdot \ln(\phi_y) + N_0 \cdot \ln(1 - \phi_y)$$

$$\ell_y(\phi_y) = N_1 \ln(\phi_y) + (N - N_1) \ln(1 - \phi_y)$$

برای ماکزیمم کردن، نسبت به ϕ_y مشتق می‌گیریم و مساوی صفر قرار می‌دهیم:

$$\frac{\partial \ell_y}{\partial \phi_y} = N_1 \cdot \frac{1}{\phi_y} + (N - N_1) \cdot \frac{1}{1 - \phi_y} \cdot (-1) = 0$$

$$\frac{N_1}{\phi_y} = \frac{N - N_1}{1 - \phi_y}$$

$$N_1(1 - \phi_y) = (N - N_1)\phi_y$$

$$N_1 - N_1\phi_y = N\phi_y - N_1\phi_y$$

$$N_1 = N\phi_y$$

و در نهایت:

$$\phi_y = \frac{N_1}{N} = \frac{\text{Count}(y = 1)}{\text{Count Total}}$$

ب) تخمین پارامترهای ویژگی (مثلاً $\phi_{j|y=1}$)

حالا می‌خواهیم $\ell(\phi)$ را نسبت به پارامتر $\phi_{k|y=1} = P(x_k = 1|y = 1)$ ماکزیمم کنیم. از تابع $\ell(\phi)$ کامل، فقط جملاتی را نگه می‌داریم که به $\phi_{k|y=1}$ بستگی دارند (یعنی $y^{(i)} = 1$ و $j = k$):

$$\ell_{k,y=1} = \sum_{i \text{ s.t. } y^{(i)}=1} \ln P(x_k^{(i)}|y^{(i)} = 1)$$

این عبارت، جمع روی تمام N_1 نمونه‌ای است که $y^{(i)} = 1$ هستند. این N_1 نمونه، خود به دو دسته تقسیم می‌شوند:

- $N_{1,k,1} = \text{Count}(y = 1 \text{ and } x_k = 1)$
- $N_{1,k,0} = \text{Count}(y = 1 \text{ and } x_k = 0)$

(که $N_{1,k,1} + N_{1,k,0} = N_1$)

$$\ell_{k,y=1} = N_{1,k,1} \cdot \ln(\phi_{k|y=1}) + N_{1,k,0} \cdot \ln(1 - \phi_{k|y=1})$$

این فرمول، از نظر ریاضی مشابه بخش (الف) است. با حل کردن این معادله به این نتیجه می‌رسیم:

$$\phi_{k|y=1} = \frac{N_{1,k,1}}{N_{1,k,1} + N_{1,k,0}} = \frac{N_{1,k,1}}{N_1}$$

حالا با برگرداندن نماد k به j:

$$\phi_{j|y=1} = \frac{\text{Count}(x_j = 1 \text{ and } y = 1)}{\text{Count}(y = 1)}$$

اثبات برای $\phi_{j|y=0}$ نیز دقیقاً به همین شکل انجام می‌شود.

Question 4: Modeling Goals with MLE

۱.۴ 4.1. Derive an expression for the maximum-likelihood estimate of the parameter λ

فرض می‌کنیم n بازی انجام شده و نتایج (x_i) مستقل (iid) هستند.

$$L(\lambda) = P(x_1, ..., x_n|\lambda) = \prod_{i=1}^{n} P(x_i|\lambda)$$

با جایگذاری فرمول پواسون ($P(x_i|\lambda) = \frac{e^{-\lambda}\lambda^{x_i}}{x_i!}$):

$$L(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{x_i}}{x_i!}$$

از دو طرف ln می‌گیریم:

$$\ell(\lambda) = \ln(L(\lambda)) = \sum_{i=1}^{n} \ln\left(\frac{e^{-\lambda}\lambda^{x_i}}{x_i!}\right)$$

$$\ell(\lambda) = \sum_{i=1}^{n} \left(\ln(e^{-\lambda}) + \ln(\lambda^{x_i}) - \ln(x_i!) \right)$$

$$\ell(\lambda) = \sum_{i=1}^{n} \left(-\lambda + x_i \ln(\lambda) - \ln(x_i!) \right)$$

$$\ell(\lambda) = -n\lambda + \ln(\lambda) \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \ln(x_i!)$$

از $\ell(\lambda)$ نسبت به λ مشتق می‌گیریم و مساوی صفر قرار می‌دهیم:

$$\frac{\partial \ell}{\partial \lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^{n} x_i - 0 = 0$$

$$\frac{1}{\lambda} \sum_{i=1}^{n} x_i = n$$

$$\lambda_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

نتیجه: تخمین MLE برای λ در توزیع پواسون، همان میانگین نمونه (sample mean) است.

۲.۴ 4.2. Give a numerical estimate of λ after the first five games and find the probability

$$\lambda = \frac{2+4+6+0+1}{5} = \frac{13}{5} = 2.6$$

$$P(x = 6 | \lambda = 2.6) = \frac{e^{-2.6}(2.6)^6}{6!} \approx \frac{0.07427 \times 308.9158}{720} \approx 0.03187$$

۳.۴ 4.3. Give an updated numerical estimate of λ after six games

$$\lambda_{\text{new}} = \frac{2+4+6+0+1+8}{6} = \frac{21}{6} = 3.5$$

$$P(x = 6 | \lambda = 3.5) = \frac{e^{-3.5}(3.5)^6}{6!} \approx \frac{0.0302 \times 1838.2656}{720} \approx 0.0771$$

Question 5: MLE Derivation of the Least Squares Loss

5.1. Write the likelihood $p(y^{(i)}|\mathbf{x}^{(i)};\boldsymbol{\theta},\sigma^2)$ ۱.۵

$$y^{(i)} = \boldsymbol{\theta}^T\mathbf{x}^{(i)} + \epsilon^{(i)} \quad \text{where} \quad \epsilon^{(i)} \sim N(0,\sigma^2)$$

$$\epsilon^{(i)} = y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)}$$

توزیع $y^{(i)}$ یک توزیع گوسی با میانگین و واریانس زیر است:

- **Mean:** $E[y^{(i)}] = E[\boldsymbol{\theta}^T\mathbf{x}^{(i)} + \epsilon^{(i)}] = \boldsymbol{\theta}^T\mathbf{x}^{(i)} + E[\epsilon^{(i)}] = \boldsymbol{\theta}^T\mathbf{x}^{(i)}$
- **Variance:** $\text{Var}(y^{(i)}) = \text{Var}(\boldsymbol{\theta}^T\mathbf{x}^{(i)} + \epsilon^{(i)}) = 0 + \text{Var}(\epsilon^{(i)}) = \sigma^2$

پس، $p(y^{(i)}|\mathbf{x}^{(i)};\boldsymbol{\theta},\sigma^2) \sim N(\boldsymbol{\theta}^T\mathbf{x}^{(i)},\sigma^2)$.

$$p(y^{(i)}|\mathbf{x}^{(i)};\boldsymbol{\theta},\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2}{2\sigma^2}\right)$$

5.2. Show that maximizing the log-likelihood is equivalent to minimizing MSE ۲.۵

$$L(\boldsymbol{\theta}) = \prod_{i=1}^{N} p(y^{(i)}|\mathbf{x}^{(i)};\boldsymbol{\theta},\sigma^2) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2}{2\sigma^2}\right)$$

$$\ell(\boldsymbol{\theta}) = \ln(L(\boldsymbol{\theta})) = \sum_{i=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2}{2\sigma^2}\right)\right]$$

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^{N} \left[\ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2}{2\sigma^2}\right]$$

$$\ell(\boldsymbol{\theta}) = N \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{1}{2\sigma^2}\sum_{i=1}^{N}(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2$$

ما می‌خواهیم $\boldsymbol{\theta}$ ای پیدا کنیم که $\ell(\boldsymbol{\theta})$ را ماکزیمم کند:

$$\boldsymbol{\theta}_{\text{MLE}} = \arg\max_{\boldsymbol{\theta}} \left[N \ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{1}{2\sigma^2}\sum_{i=1}^{N}(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2 \right]$$

ترم اول (شامل $N\ln(...)$) نسبت به $\boldsymbol{\theta}$ ثابت است. ترم دوم یک ضریب ثابت منفی ($\frac{-1}{2\sigma^2}$) دارد. ماکزیمم کردن این عبارت معادل «ماکزیمم کردن منفیِ یک عبارت» است، که خود معادل «مینیمم کردنِ آن عبارت» است:

$$\boldsymbol{\theta}_{\text{MLE}} = \arg\min_{\boldsymbol{\theta}} \left[\sum_{i=1}^{N}(y^{(i)} - \boldsymbol{\theta}^T\mathbf{x}^{(i)})^2 \right]$$

این عبارتی که به دست آوردیم همان تابع هزینه «مجموع مربعات خطا» (SSE) است که مینیمم کردن آن معادل مینیمم کردن «میانگین مربعات خطا» (MSE) می‌باشد.

Question 6: Effect of Priors on the Decision Boundary

۱.۶ 6.1. Derive the decision boundary condition (x^*)

مرز تصمیم (x^*) نقطه‌ای است که در آن احتمالات پسین برابرند.

$$P(\omega_1|x^*) = P(\omega_2|x^*)$$

$$\frac{p(x^*|\omega_1)P(\omega_1)}{p(x^*)} = \frac{p(x^*|\omega_2)P(\omega_2)}{p(x^*)}$$

$$p(x^*|\omega_1)P(\omega_1) = p(x^*|\omega_2)P(\omega_2)$$

برای سادگی، از توابع تشخیص لگاریتمی استفاده می‌کنیم ($g_i(x) = \ln p(x|\omega_i) + \ln P(\omega_i)$).
مرز در $g_1(x^*) = g_2(x^*)$ رخ می‌دهد:

$$\ln p(x^*|\omega_1) + \ln P(\omega_1) = \ln p(x^*|\omega_2) + \ln P(\omega_2)$$

$$\ln\left(\frac{p(x^*|\omega_1)}{p(x^*|\omega_2)}\right) = \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

با جایگذاری توابع گوسی و ساده‌سازی:

$$\ln\left(\frac{\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(x^*-\mu_1)^2}{2\sigma^2}\right)}{\frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{(x^*-\mu_2)^2}{2\sigma^2}\right)}\right) = \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

$$\frac{(x^*-\mu_2)^2 - (x^*-\mu_1)^2}{2\sigma^2} = \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

$$(x^{*2} - 2x^*\mu_2 + \mu_2^2) - (x^{*2} - 2x^*\mu_1 + \mu_1^2) = 2\sigma^2 \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

$$2x^*(\mu_1 - \mu_2) + (\mu_2^2 - \mu_1^2) = 2\sigma^2 \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

$$2x^*(\mu_1 - \mu_2) = (\mu_1^2 - \mu_2^2) + 2\sigma^2 \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

$$2x^*(\mu_1 - \mu_2) = (\mu_1 - \mu_2)(\mu_1 + \mu_2) + 2\sigma^2 \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

$$x^* = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2}{\mu_1 - \mu_2} \ln\left(\frac{P(\omega_2)}{P(\omega_1)}\right)$$

۲.۶ 6.2. Explain how the value of x^* shifts

خب حالا اینو تحلیل می‌کنم. اول اینکه به ما گفته شده احتمال‌های پیشین با هم برابر نیست. اگر برابر می‌بود، حاصل اون لگاریتم می‌شد $\ln(1) = 0$ پس جابجایی نداشتیم. حالا اگر $P(\omega_1)$ بیشتر بشه، نسبت کسر $\frac{P(\omega_2)}{P(\omega_1)}$ از 1 کمتر می‌شه و لگاریتم (ln) منفی می‌شه. و بدون از دست دادن کلیت مسئله هم فرض می‌کنیم $\mu_1 < \mu_2$. پس در «جمله‌ی جابجایی»، هم مخرج $(\mu_1 - \mu_2)$ منفی است و هم ترم ln منفی است. حاصل این دو منفی، یک عدد مثبت می‌شود. پس یعنی یه چیزی باید به اون نقطه‌ی میانی $\frac{\mu_1+\mu_2}{2}$ اضافه بشه، در نتیجه مرز x^* به سمت راست (به سمت μ_2) شیفت می‌خوره.

Question 7: Naive Bayes Warm-Up

7.1. Bayes' Rule for Drug Test ۱.۷

$$P(T=1|D=1)=0.99$$
$$P(T=0|D=0)=0.99$$
$$P(D=1)=0.001$$

مقادیر مورد نیاز:

$$P(D=0)=1-P(D=1)=1-0.001=0.999$$

$$P(T=1|D=0)=1-P(T=0|D=0)=1-0.99=0.01 \quad \text{(مثبت کاذب)}$$

قدم اول: محاسبه $P(T=1)$ (احتمال کل مثبت شدن)

$$P(T=1)=P(T=1|D=1)P(D=1)+P(T=1|D=0)P(D=0)$$

$$P(T=1)=(0.99\cdot 0.001)+(0.01\cdot 0.999)$$

$$P(T=1)=0.00099+0.00999=0.01098$$

قدم دوم: محاسبه $P(D=1|T=1)$ (قانون بیز)

$$P(D=1|T=1)=\frac{P(T=1|D=1)\cdot P(D=1)}{P(T=1)}$$

$$P(D=1|T=1)=\frac{0.99\cdot 0.001}{0.01098}=\frac{0.00099}{0.01098}\approx 0.09016$$

$$X = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 0 & 1 \\ 1 & 1 \\ 1 & 1 \\ 0 & 0 \\ 1 & 0 \\ 1 & 0 \\ 1 & 1 \\ 1 & 0 \end{bmatrix}, \quad y = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 1 \\ 1 \\ 0 \\ 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}$$

probabilities prior class the of estimates the Compute (a)

قراره با شمارش احتمالات پیشین رو حساب کنیم: تعداد کل نمونه‌ها $N = 10$.

- تعداد نمونه‌های $y = 1$ (کلاس ۱): $N_1 = 6$
- تعداد نمونه‌های $y = 0$ (کلاس ۰): $N_0 = 4$

بنابراین، احتمالات پیشین عبارتند از:

$$P(y = 1) = \frac{N_1}{N} = \frac{6}{10} = 0.6$$

$$P(y = 0) = \frac{N_0}{N} = \frac{4}{10} = 0.4$$

probabilities conditional ۴ the of estimates the Compute (b)

ما احتمالات شرطی را با شمارش ویژگی‌ها در هر کلاس به دست می‌آوریم.

برای کلاس $y = 1$ (که $N_1 = 6$ نمونه دارد):

- $P(x_1 = 1|y = 1) = \frac{\text{Count}(x_1=1 \text{ and } y=1)}{N_1} = \frac{5}{6} \approx 0.833$

- $P(x_2 = 1|y = 1) = \frac{\text{Count}(x_2=1 \text{ and } y=1)}{N_1} = \frac{5}{6} \approx 0.833$

برای کلاس $y = 0$ (که $N_0 = 4$ نمونه دارد):

- $P(x_1 = 1|y = 0) = \frac{\text{Count}(x_1=1 \text{ and } y=0)}{N_0} = \frac{2}{4} = 0.5$
- $P(x_2 = 1|y = 0) = \frac{\text{Count}(x_2=1 \text{ and } y=0)}{N_0} = \frac{1}{4} = 0.25$

(c) What is the most likely label for the test example? Show your work)

$$\text{Score}(y = 1) \propto P(x_1 = 1|y = 1) \cdot P(x_2 = 1|y = 1) \cdot P(y = 1)$$

$$\text{Score}(y = 1) \propto \left(\frac{5}{6}\right) \cdot \left(\frac{5}{6}\right) \cdot (0.6)$$

$$\text{Score}(y = 1) \propto \frac{25}{36} \cdot \frac{6}{10} = \frac{150}{360} = \frac{5}{12} \approx 0.4167$$

$$\text{Score}(y = 0) \propto P(x_1 = 1|y = 0) \cdot P(x_2 = 1|y = 0) \cdot P(y = 0)$$

$$\text{Score}(y = 0) \propto \left(\frac{1}{2}\right) \cdot \left(\frac{1}{4}\right) \cdot (0.4)$$

$$\text{Score}(y = 0) \propto \frac{1}{8} \cdot \frac{4}{10} = \frac{4}{80} = \frac{1}{20} = 0.05$$

$$0.4167 \quad (\text{برای } y = 1) \quad > \quad 0.05 \quad (\text{برای } y = 0)$$

چون $y = 1$ بیشتر هست پس لیبل نمونه تستی مون میشه یک

Question 8: Classifying Spam with Naive Bayes

۱.۸ Q۸.۱: خواندن و پارس کردن دیتا

بر خلاف فایل‌های CSV استاندارد، این دیتاست (train_۸ و test_۸) فایل‌های متنی با طول خط متغیر هستند. به همین دلیل، نمی‌توان از ابزارهایی مثل Pandas به صورت مستقیم استفاده

کرد. راه‌حل، خواندن فایل به صورت خط به خط بود. در هر خط، کلمه‌ی دوم به عنوان لیبل ('spam') یا ('ham') و باقی کلمات به صورت جفت‌های (شناسه‌ی کلمه، تعداد) خوانده شدند.

۲.۸ Q۸.۲: محاسبه احتمالات پیشین (Priors)

اولین قدم در آموزش مدل، محاسبه‌ی احتمال پیشین (Prior) برای هر کلاس است.

$$P(c) = \frac{\text{تعداد ایمیل‌های کلاس } c}{\text{تعداد کل ایمیل‌ها}}$$

نتایج به دست آمده (بر اساس خروجی کد):

- تعداد کل ایمیل‌های آموزشی: $N = 9000$
- $P(\text{spam}) = \frac{5163}{9000} \approx 0.5737$
- $P(\text{ham}) = \frac{3837}{9000} \approx 0.4263$

۳.۸ Q۸.۳: محاسبه احتمالات شرطی (Likelihoods)

در این بخش، پارامترهای مدل ($P(w_i|c)$) را با استفاده از m-estimate (که معادل Laplace Smoothing "Add-1" است) محاسبه کردیم.

$$P(w_i|c) = \frac{\text{Count}(w_i, c) + 1}{\text{Count}(\text{ words Total} c) + |\text{Vocabulary}|}$$

مقادیر کلیدی به دست آمده از دیتای آموزشی عبارتند از:

- اندازه‌ی کل دیکشنری: $|\text{Vocabulary}| = 1000$
- تعداد کل کلمات در ایمیل‌های اسپم: $1,655,369$
- تعداد کل کلمات در ایمیل‌های هم: $1,577,820$

با استفاده از این پارامترها، ۵ کلمه‌ای که بیشترین احتمال را در هر کلاس داشتند، استخراج شدند:

Words Ham ۵ Top	Words Spam ۵ Top
۰۴۴۳۲۲.۰ 'aaaaaaaa...':	۰۳۸۱۹۴.۰ 'enron':
۰۴۲۴۴۴.۰ 'enron':	۰۲۳۶۱۹.۰ 'a':
۰۳۳۱۶۹.۰ 'the':	۰۲۱۷۳۸.۰ 'corp':
۰۲۵۳۳۰.۰ 'to':	۰۲۱۴۲۵.۰ 'the':
۰۱۷۷۳۷.۰ 'a':	۰۱۹۶۸۷.۰ 'to':

جدول ۱: ۵ کلمه‌ی محتمل‌تر در هر کلاس بر اساس $P(w_i|c)$.

۴.۸ Q۸.۴: تست مدل و تحلیل دقت

برای جلوگیری از خطای Numerical Underflow، از **جمع لاگ‌ـاحتمالات** برای تصمیم‌گیری استفاده شد:

$$\text{LogScore}(c) = \ln(P(c)) + \sum_{w_i \in \text{email}} (\text{count}_i \cdot \ln(P(w_i|c)))$$

مدل روی ۱۰۰۰ ایمیل تست اجرا شد.

- **Accuracy: ۹۰%.۲۰** (۹۰۲ پیش‌بینی درست از ۱۰۰۰)

ماتریس درهم‌ریختگی (Confusion Matrix):

HAM Predicted:	SPAM Predicted:	
(FN) ۲۰	(TP) ۵۶۰	**SPAM Actual:**
(TN) ۳۴۲	(FP) ۷۸	**HAM Actual:**

تحلیل گزارش دسته‌بندی:

support	-scoref1	recall	precision	
580	92.0	97.0	88.0	spam
420	87.0	81.0	94.0	ham

- **Recall بالای اسپم (۹۷.۰):** مدل در پیدا کردن ایمیل‌های اسپم عالی عمل کرده.
- **مشکل اصلی (False Positives):** مدل ۷۸ ایمیل سالم (ham) را به اشتباه «اسپم» تشخیص داده است.

۵.۸ Q۸.۵: تأثیر پارامتر هموارسازی (m)

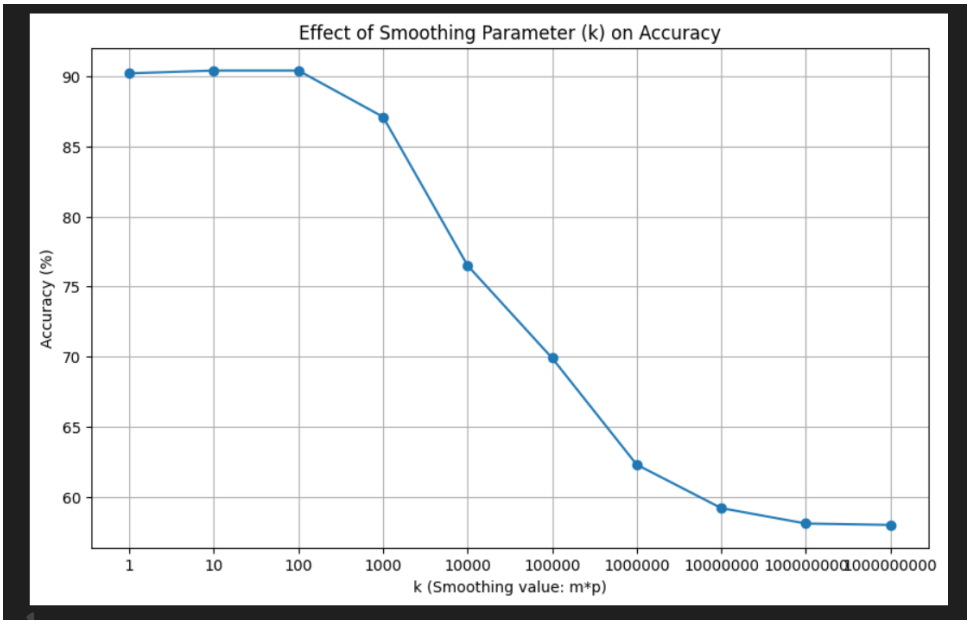
در این بخش، k (که در $m = k \cdot |\text{Vocab}|$ ضرب می‌شود) را تغییر دادیم. $k = 1$ معادل Add-1 بود.

$$P(w_i|c) = \frac{\text{Count}(w_i, c) + k}{\text{Count}(\text{ words Total}c) + (k \cdot |\text{Vocabulary}|)}$$

نتایج دقت بر اساس kهای مختلف:

k-Value	(%) Accuracy
k = ۱	۹۰.۲۰%
k = ۱۰	۹۰.۴۰%
k = ۱۰۰	۹۰.۴۰%
k = ۱۰۰۰	۸۷.۱۰%
k = ۱۰۰۰۰	۷۶.۵۰%

جدول ۲: تأثیر k (پارامتر هموارسازی) بر دقت نهایی مدل.



شکل ۱: نمودار دقت بر حسب k (در مقیاس لاگاریتمی).

تحلیل نتایج:

- **عملکرد بهینه:** $k = 10$ یا $k = 100$ بهینه‌ترین نتایج را با دقت 90.40% می‌دهند.

- **افت دقت (Underfitting):** با افزایش شدید k (به ۱۰۰۰ و ۱۰۰۰۰)، دقت افت می‌کند.
- **دلیل افت (نزدیک شدن به پرایور):** وقتی k بسیار بزرگ می‌شود، شمارش واقعی کلمات ($\text{Count}(w_i)$) در برابر k بی‌اهمیت می‌شود. احتمال همه‌ی کلمات تقریباً یکسان و برابر با «باور اولیه» ما ($p = 1/|\text{Vocab}|$) می‌شود و مدل اصطلاحاً Underfit می‌کند.

۶.۸ Q۸.۶: چگونه دسته‌بند را فریب دهیم؟

برای فریب دادن این مدل، اسپمر باید کاری کند که امتیاز لاگ «سالم» از «اسپم» بیشتر شود.

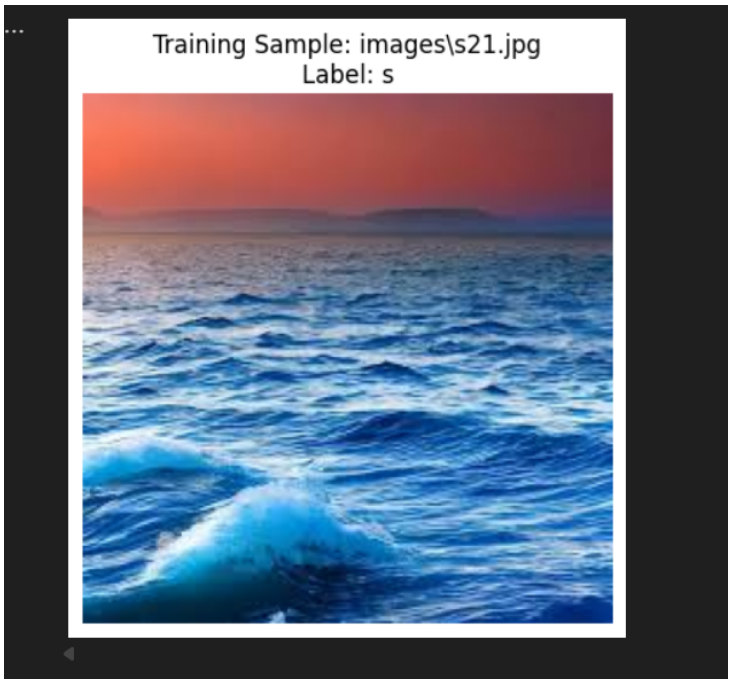
- **۱. حمله‌ی «کلمه‌ی خوب»:** اسپمر پیام اسپم خود را می‌نویسد، اما در انتها تعداد زیادی کلمه با احتمال $P(w_i|\text{ham})$ بالا اضافه می‌کند. این کلمات (حتی پنهان) امتیاز «سالم» را به شدت افزایش داده و باعث می‌شوند ایمیل از فیلتر عبور کند.
- **۲. حمله‌ی «مبهم‌سازی کلمه»:** اسپمر کلمات کلیدی اسپم (مثل viagra) را به صورت مبهم (مثل v1agra یا v.i.a.g.r.a) می‌نویسد. از آنجایی که این کلمات در دیکشنری آموزشی نیستند، مدل با آن‌ها مانند «کلمه‌ی ناشناس» رفتار می‌کند و سیگنال اسپم را دریافت نمی‌کند.
- **۳. حمله‌ی «اسپم تصویری»:** مؤثرترین روش، قرار دادن کل پیام اسپم در قالب یک **عکس** است. مدل ما مبتنی بر متن است و قابلیت خواندن متن از روی تصویر (OCR) را ندارد.

Question 9: Cloud vs. Clear Sky

در این سوال، هدف طراحی یک دسته‌بندی ساده و ابتکاری برای تشخیص تصاویر آسمان «ابری» (c) از «صاف» (s) بود.

۱.۹ قدم ۰: آماده‌سازی و تقسیم دیتا

ابتدا، کل دیتاست (۸۰ تصویر) بارگذاری شد و با نسبت ۸۰-۲۰ به دو بخش آموزشی (۶۴ تصویر) و تست (۱۶ تصویر) تقسیم شد.



شکل ۲: یک نمونه تصویر از دیتاست آموزشی به همراه برچسب آن.

۲.۹ Q۹.۱: طراحی و «آموزش» معیار اول (میانگین رنگ آبی)

ایده: اولین معیار، بر اساس این فرض ساده‌لوحانه بود که آسمان «صاف» آبی است و آسمان «ابری» آبی نیست. **ویژگی:** میانگین کانال رنگی آبی (Blue) در کل تصویر. **«آموزش»:** ما با تست تمام آستانه‌های ممکن (۰ تا ۲۵۵) روی مجموعه‌ی آموزشی، به دنبال آستانه‌ای گشتیم که بهترین دقت را بدهد.

نتیجه‌ی آموزش معیار ۱:

- **بهترین آستانه:** Best Threshold = 0
- **دقت روی داده‌های آموزشی:** Train Accuracy = 54.69%

تحلیل: این معیار یک شکست کامل بود. آستانه‌ی '0' به این معناست که مدل یاد گرفت همه‌چیز را «صاف» (s) پیش‌بینی کند. دقت 54.69% نیز صرفاً درصدِ کلاس غالب (تصاویر «صاف») در مجموعه‌ی آموزشی ما بود.

۳.۹ Q۹.۲: تست معیار اول (رنگ آبی)

این مدل شکست‌خورده (با آستانه‌ی ۰) سپس روی مجموعه‌ی تست (۱۶ تصویر) اجرا شد.

- **دقت نهایی:** Test Accuracy = 31.25%

ماتریس درهم‌ریختگی (Confusion Matrix):

- (ابری واقعی): ۰ درست، ۱۱ خطا
- (صاف واقعی): ۰ خطا، ۵ درست

گزارش دسته‌بندی:

support	-scoref1	recall	precision	
11	00.0	00.0	00.0	(c) Cloudy
5	48.0	00.1	31.0	(s) Clear

تحلیل: نتایج تست تأیید کرد که این مدل فقط کلاس «صاف» را پیش‌بینی می‌کرد.

۴.۹ Q۹.۳: طراحی و «آموزش» معیار دوم (اشباع رنگ)

ایده: شکست معیار اول نشان داد که آسمان صاف همیشه آبی نیست. اما مشاهده‌ی دقیق‌تر نشان داد که آسمان «ابری» تقریباً همیشه «بی‌رنگ» (سفید یا خاکستری) است. **ویژگی:** استفاده از کانال **«اشباع» **(Saturation) در فضای رنگی HSV. **«آموزش»:** دوباره به دنبال بهترین آستانه روی مجموعه‌ی آموزشی گشتیم. قانون این بود: if (avg_sat < threshold) then 'c'.

نتیجه‌ی آموزش معیار ۲:

- **بهترین آستانه‌ی اشباع:** Best Saturation Threshold = 85
- **دقت روی داده‌های آموزشی:** Train Accuracy = 85.94%

تحلیل: این دقت بسیار بالا نشان داد که «اشباع رنگ» یک ویژگی بسیار قوی است.

۵.۹ Q۹.۴: تست و تحلیل خطای معیار دوم (اشباع رنگ)

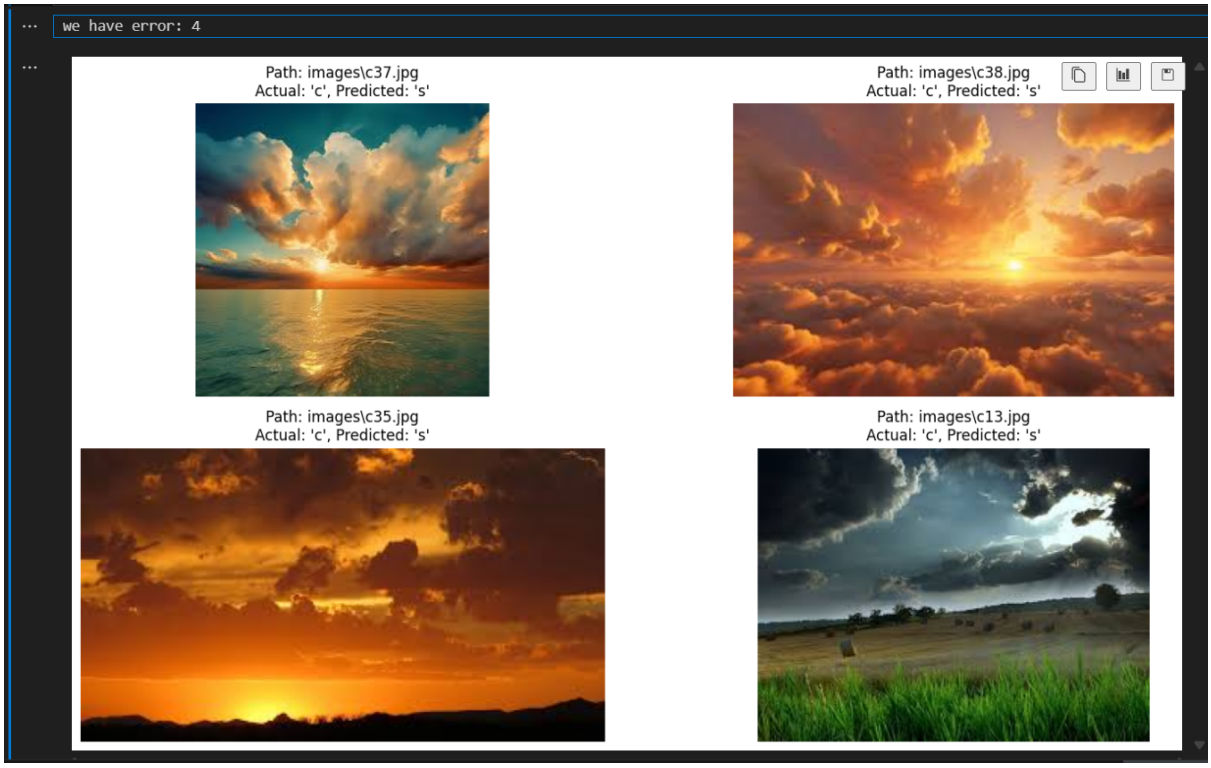
مدل دوم (مبتنی بر اشباع) روی مجموعه‌ی تست اجرا شد:

- **دقت نهایی:** Test Accuracy = 75.00%

گزارش دسته‌بندی:

support	-scoref1	recall	precision	
11	80.0	75.0	86.0	(c) Cloudy
5	67.0	75.0	60.0	(s) Clear

تحلیل خطاها: این مدل بسیار بهتر بود، اما همچنان در ۴ مورد از ۱۶ تصویر تست دچار خطا شد (شکل ۳).



شکل ۳: ۴ تصویری که توسط معیار ۲ (اشباع) اشتباه دسته‌بندی شدند.

الگوی خطا در همه‌ی تصاویر واضح است: **غروب و طلوع آفتاب**. منطق مدل ما این بود که ابرها «بی‌رنگ» (اشباع کم) هستند. اما در هنگام غروب، ابرها نور خورشید را منعکس کرده و به رنگ‌های بسیار **اشباع** (نارنجی و قرمز) در می‌آیند. مدل ما این اشباع بالا را دید و به اشتباه آن‌ها را «صاف» (s) تشخیص داد، در حالی که برچسب واقعی آن‌ها «ابری» (c) بود.

۶.۹ Q۹.۵: مقایسه‌ی نهایی مدل‌ها

جدول ۳ دو معیار طراحی شده را با هم مقایسه می‌کند:

مدل	معیار (Criterion)	دقت آموزشی	دقت تست
مدل ۱	میانگین رنگ آبی (RGB)	54.69%	31.25%
مدل ۲	**میانگین اشباع (HSV)**	**85.94%**	**75.00%**

جدول ۳: مقایسه‌ی عملکرد دو معیار طراحی شده.

نتیجه‌گیری: مدل ۲ (مبتنی بر اشباع رنگ) به طور قابل توجهی بهتر از مدل ۱ (مبتنی بر رنگ آبی) عمل کرد. این ثابت می‌کند که مهاجرت از فضای رنگی RGB به HSV و تمرکز بر ویژگی «اشباع» به جای «رنگ»، یک تصمیم طراحی بسیار مؤثر برای این مسئله بوده است.

مراجع

در این تمرین، برای حل مسائل تئوری و اثبات‌های ریاضی (مانند قانون بیز، تخمین بیشینه درست‌نمایی (MLE) و مرزهای تصمیم گوسی) از منابع اصلی کلاس، شامل جزوات و ویدئوهای درسی جناب آقای دکتر ابوالقاسمی و جناب آقای دکتر بهرک استفاده کردم. برای بخش‌های پیاده‌سازی (سوالات ۸ و ۹) و حل مسائل برنامه‌نویسی، از مستندات رسمی (Documentation) کتابخانه‌های استاندارد پایتون و منابع آنلاین معتبر استفاده شد:

- **[۱] کتابخانه‌های پایتون (ابزارهای پیاده‌سازی):**
  - مستندات کتابخانه‌ی NumPy: برای محاسبات برداری و آماری.
  - مستندات کتابخانه‌ی Matplotlib: برای رسم نمودارها.
  - مستندات کتابخانه‌ی OpenCV (cv2): برای خواندن تصاویر و تبدیل فضای رنگی (HSV) در سوال ۹.
  - مستندات کتابخانه‌ی Scikit-learn: برای تقسیم داده (train_test_split) و محاسبه‌ی متریک‌های ارزیابی (مانند confusion_matrix).
- **[۲] منابع آنلاین (Online Resources):** برای درک بهتر برخی مفاهیم و رفع اشکالات پیاده‌سازی، از منابع آنلاین عمومی مانند Wikipedia (برای تعاریف فرمول‌ها مانند توزیع پواسون) و Stack Overflow (برای رفع اشکالات برنامه‌نویسی و LaTeX) کمک گرفته شده است.