

دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

یادگیری ماشین

تمرین شماره ۲

نام و نام خانوادگی

محمدمهدی یاری

شماره دانشجویی

۸۱۰۱۰۲۵۳۲

۱ آذر ۱۴۰۴

فهرست مطالب

چکیده ۱

۱ **Question 1: Line Search Optimization Problem** ۲

۱.۱ (a) General Form and Roles ۲

۲.۱ (b) Descent Direction ۳

۳.۱ (c) Methods for Step Length ۳

۴.۱ (d) Quadratic Function Example ۴

۲ **Question 2: Support Vector Machine (SVM)** ۶

۱.۲ (a) Hard-Margin Primal Problem ۶

۲.۲ (b) Lagrangian & Stationarity ۷

۳.۲ (c) Dual Problem ۷

۴.۲ (d) KKT & Support Vectors ۸

۵.۲ (e) Soft Margin ۹

۶.۲ (f) Kernelization ۹

۳ **Question 3: Bilevel Optimization** ۱۰

۱.۳ (a) Bilevel Formulation ۱۰

۲.۳ (b) Solve Follower Problem ۱۱

۳.۳ (c) Reduce to One Variable ۱۱

۴.۳ (d) Find (x^*, y^*) ۱۱

۵.۳ (e) Discuss Regularity ۱۲

۴ **Question 4: Multi-Objective Optimization** ۱۳

۱.۴ (a) Pareto Optimality Definition ۱۳

۲.۴ (b) Weighted-sum Scalarization ۱۳
۳.۴ (c) Pareto Front Expression ۱۴
۴.۴ (d) Epsilon-constraint KKT ۱۵
۵.۴ (e) Numerical Computation ۱۶

۵ Question 5: Genetic Algorithm - Jigsaw Puzzle Solver **۱۶**
۱.۵ (a) Fit Score Design ۱۶
۲.۵ (b, c, d) Implementation Details ۱۷
۳.۵ Results Comparison ۱۷

۶ Question 6: Simulated Annealing for TSP **۱۸**
۱.۶ (a) Neighbor Operators: Swap vs 2-Opt ۱۹
۲.۶ (b) Cooling Schedules ۱۹
۳.۶ (c) Initialization ۱۹

۷ Question 7: Batch vs. Stochastic Gradient Descent **۲۱**
۱.۷ (a) Computational Load per Iteration ۲۱
۲.۷ (b) Noise (Variance) in Gradient Estimation ۲۱
۳.۷ (c) Stability and Convergence ۲۲

۸ Question 8: Steepest Descent Direction via Taylor **۲۲**

۹ Question 9: Pseudoinverse Solution is Least-Squares Minimizer **۲۳**
۱.۹ (a) Expansion of the Objective Function ۲۴
۲.۹ (b) First-Order Condition (Gradient) ۲۴
۳.۹ (c) Second-Order Condition (Convexity) ۲۵

۱۰ Question 10: Newton and Quasi-Newton Methods **۲۵**
۱.۱۰ (a) Computing the Newton Step ۲۵
۲.۱۰ (b) Failure of Newton's Method ۲۶
۳.۱۰ (c) Non-Descent Direction ۲۶
۴.۱۰ (d) Main Idea of Quasi-Newton ۲۶

۵.۱۰ (e) Hessian Approximation (Secant Equation) ۲۶

۱۱ Question 11: Quadratic Convergence of Newton's Method ۲۷

۱.۱۱ (a) Definition of Convergence Rates ۲۷

۲.۱۱ (b) Newton Step Approximates Exact Displacement ۲۸

۱۲ Question 12: Rosenbrock Function (GD vs. Newton) ۲۹

۱.۱۲ (a) Gradient and Hessian Computation ۲۹

۲.۱۲ (b, c, d) Implementation Details ۳۰

۳.۱۲ (e) Visualization and Analysis ۳۱

۱۳ Question 13: Equality-Constrained Optimization ۳۲

۱.۱۳ (a) Lagrangian ۳۲

۲.۱۳ (b) Optimal Solution (Analytical) ۳۳

۳.۱۳ (c) Nonlinear System F(w) ۳۳

۴.۱۳ (d) Newton-Raphson Jacobian ۳۴

۵.۱۳ (e) Implementation and Convergence Analysis ۳۵

۱۴ Question 14: Step-Size Strategies in Gradient Descent ۳۵

۱.۱۴ (a) Description of Step-Size Methods ۳۵

۲.۱۴ (b, c) Implementation and Results ۳۶

مراجع ۳۸

فهرست تصاویر

۱ نمودار همگرایی ۴ سناریو. محور عمودی نشان‌دهنده خطا (معکوس برازش) است. ۱۷
۲ نتیجه نهایی بازسازی تصویر در ۴ سناریوی مختلف. ۱۸
۴ مقایسه استراتژی‌های خنک‌کاری (Geometric vs. Linear) ۲۰
۳ مقایسه همگرایی عملگرها و روش‌های مقداردهی اولیه. ۲۰
۵ بهترین مسیر یافت شده توسط الگوریتم (طول: 630.9). مسیر بدون تقاطع است که نشان‌دهنده بهینگی نسبی جواب است. ۲۰
۶ مسیر حرکت الگوریتم‌های بهینه‌سازی بر روی منحنی تراز تابع روزنبروک. خط قرمز (GD) در کف دره گرفتار شده است، در حالی که خط آبی (Newton) مستقیماً به هدف می‌رسد. ۳۱
۷ نرخ همگرایی (لگاریتم خطا بر حسب تکرار). سقوط عمودی نمودار آبی نشان‌دهنده همگرایی مربعی روش نیوتن است. ۳۲
۸ مقایسه روند همگرایی روش Backtracking (قرمز) و RMSProp (سبز). ۳۷

فهرست جداول

۱ محاسبه نقاط جبهه پارتو برای وزن‌های مختلف. ۱۶

چکیده

در این تکلیف، مجموعه‌ای جامع از روش‌های بهینه‌سازی در یادگیری ماشین مورد بررسی و پیاده‌سازی قرار گرفت. تمرکز اصلی بر روی درک عمیق مبانی ریاضی روش‌های مبتنی بر گرادیان (مانند Steepest Descent و Newton's Method)، بهینه‌سازی مقید (روش ضرایب لاگرانژ و KKT) و الگوریتم‌های فرا-ابتکاری بود. در بخش‌های عملی، کارایی روش‌های مختلف بر روی توابع چالش‌برانگیز (مانند تابع روزنبروک) مقایسه شد و نشان داده شد که روش‌های مرتبه دوم و تطبیقی (Adaptive) در مسائل بد-رفتار (Ill-conditioned) عملکرد بسیار بهتری نسبت به روش‌های ساده دارند. همچنین الگوریتم‌های ژنتیک (GA) و شبیه‌سازی تبرید (SA) برای حل مسائل گسسته و ترکیبیاتی نظیر حل پازل تصویری و مسئله فروشنده دوره‌گرد (TSP) پیاده‌سازی شدند که نتایج نشان‌دهنده‌ی قدرت این روش‌ها در فرار از بهینه‌های محلی است.

Question 1: Line Search Optimization Problem

۱.۱ (a) General Form and Roles

سوال: فرم کلی مسئله‌ی بهینه‌سازی که الگوریتم‌های Line Search حل می‌کنند را بنویسید و به طور خلاصه نقش direction search و length step را توضیح دهید

پاسخ:

بسیاری از مسائل بهینه‌سازی بدون قید، با استفاده از الگوریتم‌های تکراری (Iterative) حل می‌شوند. در هر تکرار t، اگر موقعیت فعلی ما $x^{(t)}$ باشد، نقطه‌ی جدید $x^{(t+1)}$ با استفاده از رابطه‌ی بازگشتی زیر محاسبه می‌شود:

$$x^{(t+1)} = x^{(t)} + \alpha^{(t)} p^{(t)} \qquad (۱)$$

در این رابطه، هدف پیدا کردن یک طول گام مناسب با حل یک مسئله‌ی تک‌بعدی به فرم $\min_{\alpha>0} f(x^{(t)} + \alpha p^{(t)})$ است. دو مؤلفه‌ی اصلی در این فرمول نقش‌های زیر را ایفا می‌کنند:

- **جهت جستجو (Search Direction) که با $p^{(t)}$ نمایش داده می‌شود:** این بردار تعیین می‌کند که در فضای چندبعدی پارامترها، باید به کدام «سمت» حرکت کنیم. برای اینکه تابع هزینه کاهش یابد، $p^{(t)}$ حتماً باید یک «جهت کاهشی» (Descent Direction) باشد؛ یعنی زاویه‌ی آن با گرادیان تابع باز باشد (مانند جهت منفی گرادیان).
- **طول گام (Step Length) که با $\alpha^{(t)}$ نمایش داده می‌شود:** این پارامتر یک عدد اسکالر مثبت ($\alpha > 0$) است که مشخص می‌کند «چه مقدار» (چه مسافتی) باید در جهت انتخاب شده پیش برویم. انتخاب دقیق α بسیار حیاتی است؛ زیرا اگر بسیار کوچک باشد همگرایی کند می‌شود و اگر بسیار بزرگ باشد ممکن است الگوریتم واگرا شود.

۲.۱ (b) Descent Direction

سوال: مفهوم direction descent را در Line Search تعریف کنید و شرط لازم برای اینکه بردار p در نقطه‌ی x یک direction descent باشد را بیان کنید.

پاسخ:

۱. **تعریف:** یک بردار p در نقطه‌ی x، یک «جهت کاهشی» (Descent Direction) نامیده می‌شود اگر حرکت در امتداد آن (حتی با گامی بسیار کوچک)، باعث کاهش مقدار تابع هدف شود. به بیان دیگر، مشتق جهتی تابع f در جهت p باید منفی باشد.

۲. **شرط لازم:** بر اساس بسط تیلور مرتبه اول، تغییرات تابع حول نقطه‌ی x به صورت $f(x+\alpha p) \approx f(x) + \alpha \nabla f(x)^T p$ تقریب زده می‌شود. برای اینکه مقدار تابع کاهش یابد (جمله‌ی دوم منفی شود)، با توجه به اینکه $\alpha > 0$ است، شرط لازم و کافی به صورت زیر است:

$$\nabla f(x)^T p < 0 \qquad (۲)$$

این نامساوی به این معنی است که زاویه‌ی بین بردار گرادیان ($\nabla f(x)$) و بردار جهت (p) باید بین ۹۰ تا ۲۷۰ درجه باشد (زاویه‌ی باز)؛ چرا که گرادیان همواره به سمت بیشترین افزایش تابع اشاره می‌کند و ما برای کاهش تابع باید در خلاف جهت کلی آن حرکت کنیم.

۳.۱ (c) Methods for Step Length

سوال: حداقل سه روش متداول برای تعیین طول گام α را نام برده و توضیح دهید (شامل روش‌های ذکر شده در صورت سوال).

پاسخ:

- **جستجوی خطی دقیق (Exact Line Search):** طول گام α با حل تحلیلی معادله‌ی $\frac{d\phi}{d\alpha} = 0$ طوری انتخاب می‌شود که تابع در جهت جستجو به مینیمم مطلق برسد. این روش دقیق اما پرهزینه است و بیشتر برای توابع کوادراتیک کاربرد دارد.
- **روش پس‌گرد یا آرمیجو (Backtracking / Armijo):** یک روش تکراری و کم‌هزینه است. با یک α بزرگ شروع می‌کند و آن را کوچک می‌کند (مثلاً $\alpha \leftarrow \beta\alpha$) تا زمانی که شرط «کاهش کافی» (Sufficient Decrease) در تابع هدف مشاهده شود.

- **شرایط وولف (Wolfe Conditions):** برای تضمین پایداری و سرعت، دو شرط را چک می‌کند: ۱) شرط آرمیجو (برای جلوگیری از گام خیلی بزرگ) و ۲) شرط انحنا یا Curvature (برای جلوگیری از گام خیلی کوچک، با تضمین اینکه شیب در نقطه‌ی جدید صاف‌تر شده باشد).

- **گام ثابت (Fixed Step Size):** ساده‌ترین روش است که در آن α یک مقدار ثابت (مثلاً 0.01) در نظر گرفته می‌شود و در طول تکرارها تغییر نمی‌کند. پیاده‌سازی آن آسان است اما انتخاب مقدار مناسب دشوار است (کوچک بودن باعث کندی و بزرگ بودن باعث واگرایی می‌شود).

- **روش بارزیلای–بوروین (Barzilai-Borwein):** یک روش هوشمندانه که بدون محاسبه‌ی ماتریس هسین، انحنای تابع را تخمین می‌زند. این روش با استفاده از اطلاعات گام قبلی (تغییرات مکان $s_k = x_k - x_{k-1}$ و تغییرات گرادیان $y_k = \nabla f_k - \nabla f_{k-1}$)، طول گام را محاسبه می‌کند (مثلاً $\alpha = \frac{s^T s}{s^T y}$). این روش معمولاً همگرایی بسیار سریع‌تری نسبت به گرادیان کاهشی معمولی دارد.

۴.۱ (d) Quadratic Function Example

صورت سوال: تابع درجه دوم زیر را در نظر بگیرید:

$$f(x_1, x_2) = 2x_1^2 + x_1x_2 + 4x_2^2$$

در تکرار t، نقطه فعلی و جهت جستجو به صورت زیر هستند:

$$x^{(t)} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad p^{(t)} = \begin{pmatrix} 1 \\ -2 \end{pmatrix}$$

1. Show that $p^{(t)}$ is a descent direction

برای نشان دادن اینکه $p^{(t)}$ یک جهت کاهشی است، باید ثابت کنیم حاصل‌ضرب داخلی گرادیان در این جهت منفی است ($\nabla f(x^{(t)})^\top p^{(t)} < 0$).

ابتدا گرادیان تابع f را به صورت عمومی محاسبه می‌کنیم:

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{pmatrix} = \begin{pmatrix} 4x_1 + x_2 \\ x_1 + 8x_2 \end{pmatrix}$$

مقدار گرادیان در نقطه‌ی فعلی $x^{(t)} = (0, 1)^T$ برابر است با:

$$\nabla f(x^{(t)}) = \begin{pmatrix} 4(0) + 1 \\ 0 + 8(1) \end{pmatrix} = \begin{pmatrix} 1 \\ 8 \end{pmatrix}$$

حالا حاصل‌ضرب داخلی را محاسبه می‌کنیم:

$$\nabla f(x^{(t)})^\top p^{(t)} = \begin{pmatrix} 1 & 8 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix} = (1)(1) + (8)(-2) = 1 - 16 = -15$$

نتیجه: چون $-15 < 0$ است، پس شرط جهت کاهشی برقرار می‌باشد.

2. Form the one-dimensional function $\phi(\alpha)$

تابع تک‌بعدی $\phi(\alpha)$ مقدار تابع f را روی خط جستجو نشان می‌دهد:

$$\phi(\alpha) = f(x^{(t)} + \alpha p^{(t)})$$

ابتدا مختصات نقطه‌ی جدید را بر حسب α می‌نویسیم:

$$x_{new} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} + \alpha \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \begin{pmatrix} \alpha \\ 1 - 2\alpha \end{pmatrix}$$

این مقادیر را ($x_1 = \alpha$ و $x_2 = 1 - 2\alpha$) در معادله‌ی اصلی تابع f جایگذاری می‌کنیم:

$$\phi(\alpha) = 2(\alpha)^2 + (\alpha)(1 - 2\alpha) + 4(1 - 2\alpha)^2$$

عبارت را بسط می‌دهیم و ساده می‌کنیم:

$$\begin{aligned}\phi(\alpha) &= 2\alpha^2 + (\alpha - 2\alpha^2) + 4(1 - 4\alpha + 4\alpha^2) \\ &= 2\alpha^2 + \alpha - 2\alpha^2 + 4 - 16\alpha + 16\alpha^2 \\ &= (2 - 2 + 16)\alpha^2 + (1 - 16)\alpha + 4 \\ &= 16\alpha^2 - 15\alpha + 4\end{aligned}$$

بنابراین فرم ساده شده‌ی کوادراتیک تابع به صورت زیر است:

$$\phi(\alpha) = 16\alpha^2 - 15\alpha + 4 \qquad (۳)$$

3. Compute $\alpha^* > 0$ (Exact Line Search)

برای یافتن طول گام بهینه (مینیمم کردن $\phi(\alpha)$)، از این تابع نسبت به α مشتق گرفته و برابر صفر قرار می‌دهیم:

$$\frac{d\phi}{d\alpha} = 32\alpha - 15 = 0$$

$$32\alpha = 15 \implies \alpha^* = \frac{15}{32}$$

Question 2: Support Vector Machine (SVM)

در این سوال، مراحل استخراج فرمول‌های (SVM) را از فرم اولیه تا فرم دوگان و کرنل‌سازی بررسی می‌کنیم. فرض می‌کنیم مجموعه‌داده به صورت $\{(x_i, y_i)\}_{i=1}^n$ باشد که $y_i \in \{+1, -1\}$.

۱.۲ (a) Hard-Margin Primal Problem

سوال: فرمول بهینه‌سازی اولیه (Primal) برای Hard-Margin SVM را بنویسید.

پاسخ: هدف ما یافتن ابرصفحه‌ای با پارامترهای w و b است که حاشیه‌ی جداسازی (که

متناسب با $\frac{1}{||w||}$ است) را ماکزیمم کند، به شرطی که تمام داده‌ها به درستی و در سمت صحیح حاشیه دسته‌بندی شوند. فرمول ریاضی به صورت زیر است:

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2}||w||^2 \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1, \quad \forall i = 1, \ldots, n \end{aligned} \tag{۴}$$

۲.۲ (b) Lagrangian & Stationarity

سوال: تابع لاگرانژ را تشکیل دهید و با مشتق‌گیری، شرایط ایستایی را بدست آورید.

پاسخ: برای حل این مسئله‌ی مقید، ضرایب لاگرانژ $\alpha_i \geq 0$ را معرفی می‌کنیم. تابع لاگرانژ $\mathcal{L}$ برابر است با تابع هدف منهای مجموع قیود وزن‌دار شده:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2}||w||^2 - \sum_{i=1}^{n} \alpha_i \left[y_i(w^T x_i + b) - 1 \right] \tag{۵}$$

برای یافتن نقطه‌ی بهینه، مشتقات جزئی $\mathcal{L}$ نسبت به متغیرهای اصلی (w و b) باید برابر صفر باشند:

۱. **مشتق نسبت به w:**

$$\nabla_w \mathcal{L} = w - \sum_{i=1}^{n} \alpha_i y_i x_i = 0 \implies w = \sum_{i=1}^{n} \alpha_i y_i x_i$$

۲. **مشتق نسبت به b:**

$$\frac{\partial \mathcal{L}}{\partial b} = -\sum_{i=1}^{n} \alpha_i y_i = 0 \implies \sum_{i=1}^{n} \alpha_i y_i = 0$$

۳.۲ (c) Dual Problem

سوال: مسئله‌ی دوگان (Dual) را استخراج کنید (فقط بر حسب α).

پاسخ: با جایگذاری رابطه‌ی بدست آمده برای w در تابع لاگرانژ و ساده‌سازی آن، متغیرهای w و b حذف می‌شوند و به مسئله‌ی دوگان می‌رسیم که هدف آن ماکزیمم کردن مقدار نسبت به α است:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^{n} \alpha_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \alpha_i \alpha_j y_i y_j (x_i^T x_j) \\ \text{s.t.} \quad & \alpha_i \geq 0, \quad \forall i \\ & \sum_{i=1}^{n} \alpha_i y_i = 0 \end{aligned} \tag{۶}$$

نکته مهم این است که در فرم دوگان، داده‌های ورودی فقط به صورت ضرب داخلی $(x_i^T x_j)$ ظاهر می‌شوند.

۴.۲ (d) KKT & Support Vectors

سوال: شرط لغزندگی مکمل KKT را بیان کنید، بردارهای پشتیبان را توضیح دهید و نحوه‌ی بازیابی (w, b) را بنویسید.

پاسخ: ۱. شرط لغزندگی مکمل (Complementary Slackness): یکی از شرایط KKT بیان می‌کند که حاصل‌ضرب ضریب لاگرانژ در مقدار قید باید صفر باشد:

$$\alpha_i \left[y_i (w^T x_i + b) - 1 \right] = 0, \quad \forall i$$

۲. بردارهای پشتیبان (Support Vectors): از شرط بالا نتیجه می‌گیریم که برای هر داده i:

- یا $\alpha_i = 0$: داده تاثیری در مدل ندارد (خارج از مرز حاشیه است).
- یا $y_i(w^T x_i + b) = 1$: داده دقیقاً روی مرز حاشیه قرار دارد. به این داده‌ها که $\alpha_i > 0$ دارند، «بردار پشتیبان» می‌گویند.

۳. بازیابی پارامترها:

- w^* از رابطه $w^* = \sum_{i=1}^{n} \alpha_i y_i x_i$ بدست می‌آید.

- b^* با استفاده از هر بردار پشتیبان دلخواه (x_k که $0 < \alpha_k$) بدست می‌آید:

$$b^* = y_k - w^{*T} x_k$$

۵.۲ (e) Soft Margin

سوال: فرم اولیه Soft-Margin (با متغیرهای کمکی) و فرم دوگان آن را بنویسید.

پاسخ: وقتی داده‌ها به صورت خطی جداپذیر نباشند، از متغیرهای کمکی $\xi_i \geq 0$ (Slack Variables) استفاده می‌کنیم تا اجازه دهیم برخی داده‌ها با جریمه‌ی C وارد حریم حاشیه شوند.

فرم اولیه (Primal):

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2}||w||^2 + C\sum_{i=1}^{n} \xi_i \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \end{aligned} \tag{۷}$$

فرم دوگان (Dual): تابع هدف دقیقاً مشابه حالت Hard-Margin است، اما محدودیت روی α_i تغییر می‌کند (سقف‌دار می‌شود):

$$\begin{aligned} \max_{\alpha} \quad & \ldots \quad \text{(همان تابع هدف قبلی)} \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^{n} \alpha_i y_i = 0 \end{aligned} \tag{۸}$$

۶.۲ (f) Kernelization

سوال: توضیح دهید چگونه فرم دوگان امکان استفاده از کرنل‌ها را فراهم می‌کند و تابع تصمیم کرنلی را بنویسید.

پاسخ: در فرم دوگان (بخش c)، مشاهده کردیم که بردار ویژگی x تنها به صورت حاصل‌ضرب داخلی $x_i^T x_j$ ظاهر می‌شود. اگر بخواهیم داده‌ها را به فضای ویژگی با ابعاد بالاتر $\phi(x)$ ببریم تا جداپذیر شوند، نیازی به محاسبه‌ی مستقیم $\phi(x)$ نیست. ما می‌توانیم ضرب داخلی را با یک تابع کرنل جایگزین کنیم: $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$. به این تکنیک Kernel Trick می‌گویند.

تابع تصمیم نهایی (Decision Function) با کرنل به صورت زیر خواهد بود:

$$f(x) = \text{sign}\left(\sum_{i=1}^{n} \alpha_i y_i K(x_i, x) + b\right) \tag{۹}$$

Question 3: Bilevel Optimization

بهینه‌سازی دوسطحی (Bilevel Optimization) مدلی است که در آن یک رهبر (Leader) متغیرهای خود را با پیش‌بینی پاسخ بهینه‌ی یک پیرو (Follower) انتخاب می‌کند.

۱.۳ (a) Bilevel Formulation

سوال: فرمول‌بندی دوسطحی (سطح بالا و پایین) را بنویسید.

پاسخ: در این مسئله، رهبر متغیر x و پیرو متغیر y را انتخاب می‌کند. فرم استاندارد مسئله به صورت زیر است که در آن مسئله‌ی پیرو به عنوان یک قید برای مسئله‌ی رهبر عمل می‌کند:

مسئله سطح بالا (رهبر):

$$\begin{aligned} \min_{x} \quad & F(x, y) = (x-2)^2 + (y-3)^2 \\ \text{s.t.} \quad & x \geq 0 \\ & y \in \arg\min_{y' \geq 0} f(x, y') \end{aligned} \tag{۱۰}$$

مسئله سطح پایین (پیرو):

$$\begin{aligned} \min_{y} \quad & f(x, y) = (y - x^2)^2 + y \\ \text{s.t.} \quad & y \geq 0 \end{aligned} \tag{۱۱}$$

۲.۳ (b) Solve Follower Problem

سوال: برای یک x ثابت، مسئله پیرو را حل کرده و $y^*(x)$ را بدست آورید.

پاسخ: برای x ثابت، باید تابع $f(y) = (y - x^2)^2 + y$ را با شرط $y \geq 0$ کمینه کنیم. از تابع نسبت به y مشتق می‌گیریم:

$$\frac{\partial f}{\partial y} = 2(y - x^2) + 1 = 0$$

$$2y - 2x^2 + 1 = 0 \implies y_{\text{unconstrained}} = x^2 - 0.5$$

با اعمال قید $y \geq 0$، پاسخ بهینه‌ی پیرو به صورت زیر خواهد بود:

$$y^*(x) = \max(0, x^2 - 0.5) \tag{۱۲}$$

۳.۳ (c) Reduce to One Variable

سوال: $y^*(x)$ را در تابع هدف رهبر جایگذاری کنید و مسئله را تک‌متغیره کنید.

پاسخ: رهبر می‌داند که هدفش نزدیک کردن x به ۲ و y به ۳ است. اگر x نزدیک ۲ باشد، مقدار $x^2 - 0.5$ (حدود 3.5) مثبت خواهد بود، بنابراین می‌توانیم فرض کنیم که در شاخه‌ی مثبت قرار داریم ($y^* = x^2 - 0.5$). با جایگذاری در تابع $F(x, y)$:

$$F(x) = (x - 2)^2 + ((x^2 - 0.5) - 3)^2$$

$$F(x) = (x - 2)^2 + (x^2 - 3.5)^2 \tag{۱۳}$$

۴.۳ (d) Find (x^*, y^*)

سوال: نقطه بهینه (x^*, y^*) را بیابید.

پاسخ: از تابع کاهش‌یافته‌ی رهبر نسبت به x مشتق می‌گیریم:

$$F'(x) = 2(x - 2) + 2(x^2 - 3.5)(2x)$$

$$F'(x) = 2x - 4 + 4x(x^2 - 3.5)$$

$$F'(x) = 2x - 4 + 4x^3 - 14x$$

$$F'(x) = 4x^3 - 12x - 4$$

برای یافتن مینیمم، $F'(x) = 0$ قرار می‌دهیم (تقسیم بر ۴):

$$x^3 - 3x - 1 = 0 \qquad (۱۴)$$

این یک معادله درجه ۳ است. با استفاده از روش‌های عددی، ریشه‌ی مثبت در بازه‌ی معقول (نزدیک ۲) برابر است با:

$$x^* \approx 1.879$$

حال مقدار y^* را محاسبه می‌کنیم:

$$y^* = (x^*)^2 - 0.5 \approx (1.879)^2 - 0.5 \approx 3.532 - 0.5 = 3.032$$

بنابراین نقطه تعادل بازی برابر است با:

$$(x^*, y^*) \approx (1.88, 3.03)$$

۵.۳ (e) Discuss Regularity

سوال: در مورد نظم مسئله (تحدب پیرو، یکتایی و صحت جایگذاری) بحث کنید.

پاسخ: برای بررسی صحت جایگذاری $y^*(x)$ در مسئله رهبر، باید مطمئن شویم که پیرو برای هر x، یک پاسخ **یکتا** دارد. تابع هدف پیرو $f(y)$ را در نظر می‌گیریم و مشتق دوم آن را محاسبه می‌کنیم:

$$\frac{\partial^2 f}{\partial y^2} = \frac{\partial}{\partial y}(2y - 2x^2 + 1) = 2$$

چون مشتق دوم همواره مثبت ($2 > 0$) است، مسئله‌ی پیرو **اکیداً محدب** (Strictly Convex) می‌باشد. تحدب اکید تضمین می‌کند که برای هر x داده شده، دقیقاً یک y^* منحصربه‌فرد وجود دارد. بنابراین، تابع واکنش $y^*(x)$ خوش‌تعریف (Well-defined) و تک‌مقدار است و جایگذاری آن در تابع رهبر (کاهش به مسئله تک‌سطحی) از نظر ریاضی معتبر می‌باشد.

Question 4: Multi-Objective Optimization

در این سوال، مسئله‌ی بهینه‌سازی چندهدفه با دو تابع هدف متضاد زیر بررسی می‌شود:

$$f_1(x,y) = (x-2)^2 + y^2, \quad f_2(x,y) = x^2 + (y-3)^2$$

هدف اول سعی می‌کند ما را به نقطه $P_1(2,0)$ بکشاند و هدف دوم به سمت $P_2(0,3)$.

۱.۴ (a) Pareto Optimality Definition

سوال: بهینگی پارتو را برای نقطه (x^*, y^*) تعریف کنید.

پاسخ: نقطه (x^*, y^*) یک نقطه «بهینه پارتو» (Pareto Optimal) نامیده می‌شود اگر هیچ نقطه دیگری مانند (x, y) در فضای شدنی وجود نداشته باشد که:

۱. در تمام اهداف حداقل به خوبیِ نقطه فعلی باشد: $f_i(x,y) \leq f_i(x^*,y^*)$ برای همه i.

۲. حداقل در یکی از اهداف اکیداً بهتر باشد: $f_j(x,y) < f_j(x^*,y^*)$ برای حداقل یک j.

به بیان ساده، نمی‌توانیم هیچ‌یک از اهداف را بهبود ببخشیم مگر اینکه حداقل یکی از اهداف دیگر را بدتر کنیم (مفهوم Trade-off).

۲.۴ (b) Weighted-sum Scalarization

سوال: با تعریف تابع اسکالر $F_w(x,y) = wf_1 + (1-w)f_2$، مختصات بهینه $(x(w), y(w))$ را بیابید و مسیر پارتو را نشان دهید.

پاسخ: تابع مجموع وزن‌دار را تشکیل می‌دهیم:

$$F_w(x,y) = w\left[(x-2)^2 + y^2\right] + (1-w)\left[x^2 + (y-3)^2\right]$$

برای مینیمم کردن، از F_w نسبت به x و y مشتق گرفته و برابر صفر قرار می‌دهیم:

۱. مشتق نسبت به x:

$$\frac{\partial F_w}{\partial x} = w(2(x-2)) + (1-w)(2x) = 0$$

$$2wx - 4w + 2x - 2wx = 0 \implies 2x = 4w \implies x(w) = 2w$$

۲. مشتق نسبت به y:

$$\frac{\partial F_w}{\partial y} = w(2y) + (1-w)(2(y-3)) = 0$$

$$2wy + 2y - 6 - 2wy + 6w = 0 \implies 2y = 6(1-w) \implies y(w) = 3(1-w)$$

بنابراین مکان هندسی نقاط بهینه پارتو بر حسب پارامتر $w \in [0,1]$ عبارت است از:

$$(x(w), y(w)) = (2w,\ 3(1-w)) \qquad (۱۵)$$

این معادله نشان‌دهنده‌ی پاره‌خط مستقیمی است که دو مینیمم مطلق $P_1(2,0)$ (وقتی $w=1$) و $P_2(0,3)$ (وقتی $w=0$) را به هم وصل می‌کند.

۳.۴ (c) Pareto Front Expression

سوال: رابطه‌ی پارامتری جبهه پارتو ($\mathcal{P}$) و رابطه‌ی بسته بین $u = f_1$ و $v = f_2$ را بیابید.

پاسخ: مقادیر بهینه $x(w)$ و $y(w)$ را در توابع هدف جایگذاری می‌کنیم:

$$f_1(w) = (2w-2)^2 + (3(1-w))^2 = 4(w-1)^2 + 9(1-w)^2 = 13(1-w)^2$$

$$f_2(w) = (2w)^2 + (3(1-w)-3)^2 = 4w^2 + (-3w)^2 = 13w^2$$

بنابراین مجموعه‌ی جبهه پارتو به صورت پارامتری عبارت است از:

$$\mathcal{P} = \{(13(1-w)^2,\ 13w^2) \mid w \in [0,1]\}$$

برای یافتن رابطه‌ی بسته بین $u = f_1$ و $v = f_2$:

$$\sqrt{u} = \sqrt{13}(1 - w), \quad \sqrt{v} = \sqrt{13}w$$

با جمع کردن دو عبارت بالا، پارامتر w حذف می‌شود:

$$\sqrt{u} + \sqrt{v} = \sqrt{13}(1 - w + w) = \sqrt{13}$$

بنابراین معادله‌ی منحنی جبهه پارتو در فضای اهداف عبارت است از:

$$\sqrt{f_1} + \sqrt{f_2} = \sqrt{13} \qquad (۱۶)$$

۴.۴ (d) Epsilon-constraint KKT

سوال: مسئله را با روش ϵ-constraint حل کنید و ضریب لاگرانژ λ را به w ربط دهید.

پاسخ: در روش محدودیت اپسیلون، مسئله به صورت زیر فرمول‌بندی می‌شود:

$$\min f_1(x, y) \quad \text{s.t.} \quad f_2(x, y) \leq t$$

لاگرانژ این مسئله عبارت است از: $L = f_1 + \lambda(f_2 - t)$. شرط ایستایی گرادیان ($\nabla L = 0$) می‌دهد:

$$\nabla f_1 + \lambda \nabla f_2 = 0$$

از طرف دیگر، در روش مجموع وزن‌دار (بخش b) داشتیم:

$$w\nabla f_1 + (1 - w)\nabla f_2 = 0 \implies \nabla f_1 + \frac{1 - w}{w}\nabla f_2 = 0$$

با مقایسه‌ی ضرایب ∇f_2 در دو معادله، رابطه‌ی بین ضریب لاگرانژ و وزن اسکالرسازی بدست می‌آید:

$$\lambda = \frac{1 - w}{w} \qquad (۱۷)$$

این رابطه نشان می‌دهد که ضریب لاگرانژ (λ) در واقع نرخ مبادله (Trade-off Rate) بین دو هدف

در نقطه بهینه پارتو است.

۵.۴ (e) Numerical Computation

سوال: مقادیر (x, y) و (f_1, f_2) را برای وزن‌های داده شده محاسبه کنید.

پاسخ: با استفاده از فرمول‌های استخراج شده ($x = 2w, y = 3(1-w)$ و $f_1 = 13(1-w)^2, f_2 = 13w^2$):

f_2	f_1	$y(w)$	$x(w)$	w
0.0000	13.0000	3	0	0
0.8125	7.3125	2.25	0.5	0.25
3.2500	3.2500	1.5	1.0	0.5
7.3125	0.8125	0.75	1.5	0.75
13.0000	0.0000	0	2	1

جدول ۱: محاسبه نقاط جبهه پارتو برای وزن‌های مختلف.

Question 5: Genetic Algorithm - Jigsaw Puzzle Solver

در این تمرین، یک سیستم حل پازل مبتنی بر الگوریتم ژنتیک طراحی و پیاده‌سازی شد. هدف اصلی، بررسی تأثیر روش‌های مختلف «انتخاب» (Selection) و «توابع برازش» (Fitness Function) بر سرعت و دقت حل مسئله بود.

۱.۵ (a) Fit Score Design

برای سنجش کیفیت اتصال دو قطعه، از معیار "تفاوت لبه‌ها" استفاده شد. اگر قطعه A در سمت چپ قطعه B قرار گیرد، تفاوت پیکسلی بین ستون آخر A و ستون اول B محاسبه می‌شود. دو معیار پیاده‌سازی شد:

۱. **L1 Norm:** مجموع قدرمطلق تفاضل‌ها ($\sum |p_A - p_B|$).

۲. **L2 Norm:** جذر مجموع مربعات تفاضل‌ها ($\sqrt{\sum (p_A - p_B)^2}$).

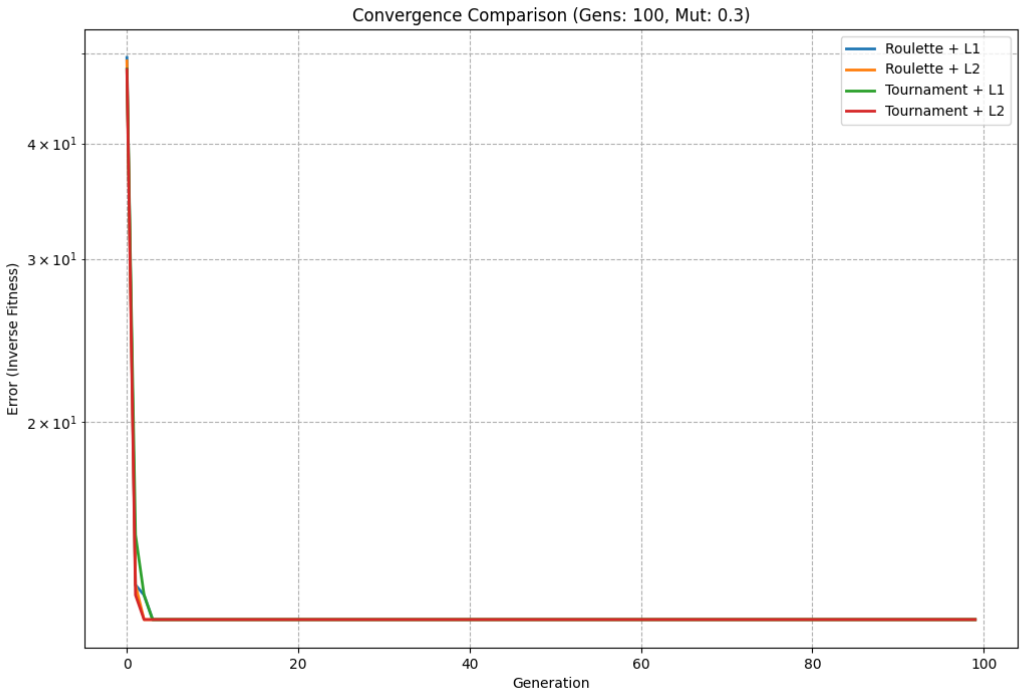
۲.۵ (b, c, d) Implementation Details

الگوریتم با جمعیت اولیه تصادفی شروع به کار می‌کند. در هر نسل:

- **نخبه‌گرایی (Elitism):** ۵٪ از بهترین افراد مستقیماً به نسل بعد منتقل می‌شوند.
- **انتخاب:** دو روش Roulette Wheel و Tournament (با سایز ۵) مقایسه شدند.
- **ترکیب (Crossover):** از روشی استفاده شد که ترتیب قطعات را حفظ کرده و از تکرار جلوگیری می‌کند.
- **جهش (Mutation):** با احتمال ۵٪، جای دو قطعه در پازل با هم عوض می‌شود.

۳.۵ Results Comparison

چهار سناریوی مختلف (ترکیب دو روش انتخاب و دو روش برازش) روی تصویر `pillars.jpg` (که به ۶۴ قطعه تقسیم شده بود) اجرا شدند.

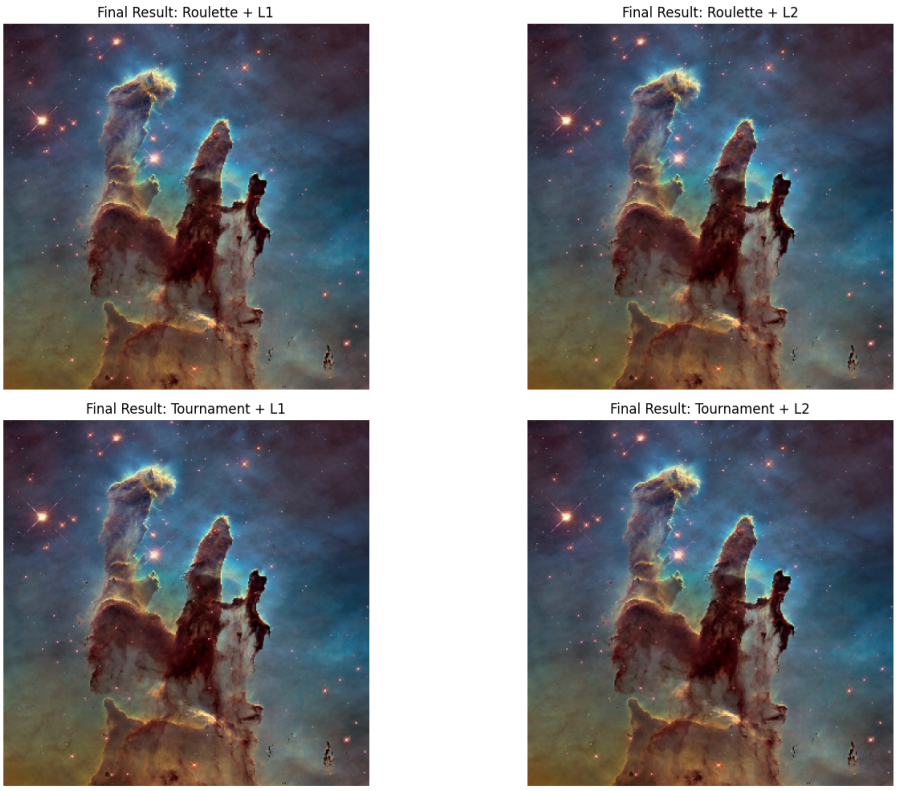


شکل ۱: نمودار همگرایی ۴ سناریو. محور عمودی نشان‌دهنده خطا (معکوس برازش) است.

تحلیل نتایج: همانطور که در نمودار شکل ۱ پیداست:

- روش **Tournament Selection** (خطوط سبز و قرمز) سرعت همگرایی بسیار بالاتری نسبت به Roulette داشت و در کمتر از ۱۰ نسل به جواب پایدار رسید.
- تابع برازش **L2 Norm** عملکردی مشابه L1 داشت، اما در ترکیب با تورنمنت کمی پایدارتر ظاهر شد.

تصاویر نهایی بازسازی شده در شکل زیر نشان داده شده‌اند که همگی موفق به حل کامل پازل شده‌اند.



شکل ۲: نتیجه نهایی بازسازی تصویر در ۴ سناریوی مختلف.

Question 6: Simulated Annealing for TSP

در این سوال، الگوریتم شبیه‌سازی تبرید (Simulated Annealing) برای حل مسئله فروشنده دوره‌گرد (TSP) با $N = 50$ شهر که مختصات آن‌ها به صورت تصادفی تولید شده، پیاده‌سازی گردید. هدف مینیمم کردن تابع انرژی (طول کل تور) است.

۱.۶ (a) Neighbor Operators: Swap vs 2-Opt

دو نوع عملگر همسایگی پیاده‌سازی و مقایسه شدند:

- **Swap:** انتخاب دو شهر تصادفی و جابجایی آن‌ها.
- **2-Opt:** انتخاب یک زیر_بازه از مسیر و معکوس کردن ترتیب شهرها در آن بازه.

همانطور که در نمودار شکل ۳ مشاهده می‌شود، عملگر 2-Opt (خط نارنجی) عملکرد بسیار بهتری نسبت به Swap (خط آبی) دارد. دلیل این امر این است که 2-Opt توانایی باز کردن گره‌ها (Untangling Crossings) در مسیر را دارد که منجر به کاهش سریع‌تر طول تور می‌شود.

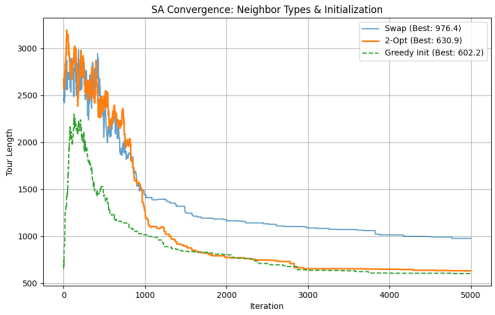
۲.۶ (b) Cooling Schedules

تأثیر برنامه خنک‌کاری بر همگرایی در شکل ۴ نمایش داده شده است:

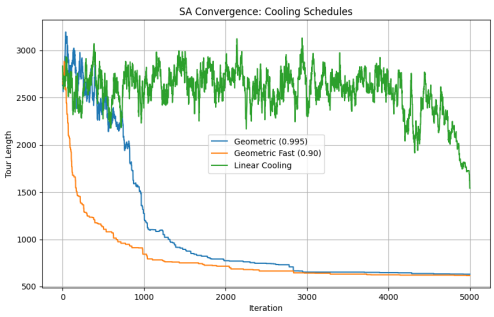
- **Geometric ($\alpha = 0.995$):** کاهش تدریجی دما (خط آبی) باعث می‌شود الگوریتم فرصت کافی برای جستجو (Exploration) داشته باشد و به بهترین جواب برسد.
- **Linear:** کاهش خطی (خط سبز) در دماهای بالا زمان زیادی را هدر می‌دهد و در دماهای پایین خیلی سریع سرد می‌شود (”انجماد سریع”) که منجر به گیر افتادن در مینیمم‌های محلی و نوسان زیاد می‌شود.

۳.۶ (c) Initialization

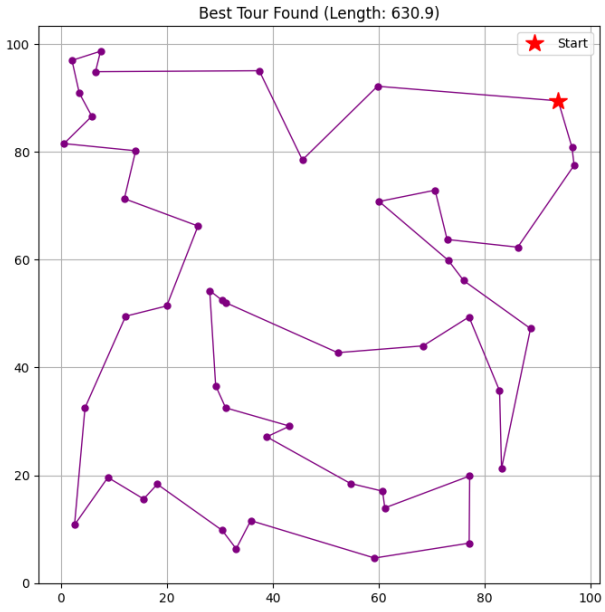
شروع الگوریتم با یک جواب اولیه Greedy (نزدیک‌ترین همسایه) باعث می‌شود الگوریتم از نقطه‌ای بسیار بهتر (خط سبز در شکل ۳) شروع کند. با این حال، الگوریتم SA با شروع کاملاً تصادفی نیز توانست در نهایت به جوابی بسیار نزدیک به روش حریصانه همگرا شود که قدرت آن در جستجوی سراسری را نشان می‌دهد.



شکل ۳: مقایسه همگرایی عملگرها و روش‌های مقداردهی اولیه.



شکل ۴: مقایسه استراتژی‌های خنک‌کاری (Geometric vs. Linear).



شکل ۵: بهترین مسیر یافت شده توسط الگوریتم (طول: 630.9). مسیر بدون تقاطع است که نشان‌دهنده بهینگی نسبی جواب است.

Question 7: Batch vs. Stochastic Gradient Descent

در این سوال، دو روش اصلی گرادیان کاهشی یعنی Batch Gradient Descent (BGD) و Stochastic Gradient Descent (SGD) از سه منظر مقایسه می‌شوند. فرض کنید N تعداد کل داده‌های آموزشی باشد.

۱.۷ (a) Computational Load per Iteration

سوال: بار محاسباتی در هر تکرار را مقایسه کنید.

پاسخ:

- **Batch GD:** در هر تکرار، گرادیان تابع هزینه باید روی **تمام** N **نمونه‌ی آموزشی** محاسبه و جمع‌بندی شود. بنابراین اگر مجموعه‌داده بزرگ باشد، بار محاسباتی هر گام بسیار سنگین است ($O(N)$).
- **SGD:** در هر تکرار، گرادیان تنها بر اساس **یک نمونه‌ی تصادفی** محاسبه می‌شود. بنابراین بار محاسباتی هر گام بسیار ناچیز و مستقل از اندازه‌ی کل دیتاست است ($O(1)$).

۲.۷ (b) Noise (Variance) in Gradient Estimation

سوال: نویز و واریانس در تخمین گرادیان را بررسی کنید.

پاسخ:

- **Batch GD:** از آنجایی که از میانگین واقعی گرادیان روی کل جامعه‌ی آماری (داده‌ها) استفاده می‌کند، تخمین گرادیان دقیق و بدون نویز است (واریانس صفر در جهت حرکت). حرکت به سمت مینیمم قطعی (Deterministic) است.
- **SGD:** چون گرادیان واقعی با گرادیان یک نمونه‌ی تکی تقریب زده می‌شود، نویز و واریانس بسیار بالایی دارد. جهت حرکت در هر مرحله ممکن است با جهت واقعی کاهش خطا متفاوت باشد.

۳.۷ (c) Stability and Convergence

سوال: پایداری و ماهیت همگرایی به مینیمم را شرح دهید.

پاسخ:

- **Batch GD:** مسیر همگرایی بسیار هموار، پایدار و مستقیم است. این روش تضمین می‌کند که (برای توابع محدب) به مینیمم سراسری و (برای توابع غیرمحدب) به یک مینیمم محلی همگرا شود و در آنجا متوقف شود. عیب آن این است که احتمال گیر افتادن در مینیمم‌های محلی ضعیف (Bad Local Minima) یا نقاط زینی (Saddle Points) بیشتر است.
- **SGD:** مسیر همگرایی پرنوسان (Fluctuating) و زیگ‌زاگی است. این روش معمولاً دقیقاً در نقطه مینیمم متوقف نمی‌شود، بلکه در حوالی آن نوسان می‌کند. با این حال، همین نویز و ناپایداری می‌تواند مفید باشد و به الگوریتم کمک کند تا از چاله‌های کم‌عمق (مینیمم‌های محلی) فرار کند و شانس رسیدن به جواب‌های بهتر را افزایش دهد.

Question 8: Steepest Descent Direction via Taylor

سوال: با استفاده از بسط تیلور مرتبه اول، ثابت کنید که جهت منفی گرادیان ($p_k = -\nabla f(x_k)$)، جهت تندترین کاهش (Steepest Descent) در همسایگی محلی x_k است.

پاسخ: فرض کنیم در نقطه x_k هستیم و می‌خواهیم یک گام کوچک $\alpha > 0$ در جهت بردار واحد p (با شرط $||p|| = 1$) برداریم. هدف ما یافتن جهت p است که مقدار تابع $f(x_k + \alpha p)$ را کمینه کند.

بسط تیلور با استفاده از بسط تیلور مرتبه اول حول نقطه x_k داریم:

$$f(x_k + \alpha p) \approx f(x_k) + \alpha \nabla f(x_k)^T p \qquad (۱۸)$$

تعریف مسئله مینیمم‌سازی برای اینکه $f(x_k + \alpha p)$ مینیمم شود، باید جمله‌ی تغییرات یعنی $\alpha \nabla f(x_k)^T p$ مینیمم گردد. از آنجا که $f(x_k)$ و α مقادیر ثابتی هستند، مسئله تبدیل به

مینیمم‌سازی ضرب داخلی زیر می‌شود:

$$\min_{p} \quad \nabla f(x_k)^T p \quad \text{s.t.} \quad ||p|| = 1 \tag{۱۹}$$

استفاده از فرمول هندسی ضرب داخلی طبق تعریف ضرب داخلی، داریم:

$$\nabla f(x_k)^T p = ||\nabla f(x_k)|| \cdot ||p|| \cdot \cos(\theta)$$

که در آن θ زاویه‌ی بین بردار گرادیان و بردار جهت p است. چون $||p|| = 1$ و $||\nabla f(x_k)||$ مقداری ثابت و غیرمنفی است، برای مینیمم کردن کل عبارت، باید مقدار $\cos(\theta)$ را مینیمم کنیم.

نتیجه‌گیری کمترین مقدار ممکن برای تابع کسینوس برابر -1 است که در زاویه‌ی $\theta = 180°$ (یا π) رخ می‌دهد. این یعنی زاویه‌ی بین p و $\nabla f(x_k)$ باید ۱۸۰ درجه باشد، به عبارت دیگر p باید دقیقاً در خلاف جهت گرادیان باشد:

$$p = -\frac{\nabla f(x_k)}{||\nabla f(x_k)||} \tag{۲۰}$$

بنابراین ثابت شد که جهت منفی گرادیان $(-\nabla f)$، جهت تندترین کاهش تابع است.

Question 9: Pseudoinverse Solution is Least-Squares Minimizer

سوال: برای یک دستگاه بیش‌ازحد معین (Overdetermined) $Ax = b$ که در آن A دارای رتبه ستونی کامل است، ثابت کنید نامزد $x^* = (A^\top A)^{-1} A^\top b$ (که در معادلات نرمال صدق می‌کند)، مینیمم‌کننده‌ی یکتای سراسری برای تابع $L(x) = ||Ax - b||_2^2$ است.

پاسخ:

برای اثبات این موضوع، ابتدا تابع هزینه $L(x)$ را بسط می‌دهیم، سپس گرادیان آن را محاسبه کرده و برابر صفر قرار می‌دهیم، و در نهایت با استفاده از ماتریس هسین نشان می‌دهیم که این نقطه یک مینیمم سراسری است.

۱.۹ (a) Expansion of the Objective Function

تابع هدف، مربع نرم اقلیدسی خطاست. با استفاده از خاصیت $||v||^2 = v^\top v$ داریم:

$$\begin{aligned} L(x) &= ||Ax - b||_2^2 \\ &= (Ax - b)^\top (Ax - b) \\ &= (x^\top A^\top - b^\top)(Ax - b) \\ &= x^\top A^\top Ax - x^\top A^\top b - b^\top Ax + b^\top b \end{aligned}$$

از آنجا که حاصل عبارت $b^\top Ax$ یک عدد اسکالر است، ترانهاده‌ی آن با خودش برابر است ($(b^\top Ax)^\top = x^\top A^\top b$). بنابراین دو جمله‌ی میانی با هم برابرند:

$$L(x) = x^\top (A^\top A)x - 2(A^\top b)^\top x + b^\top b \qquad (۲۱)$$

۲.۹ (b) First-Order Condition (Gradient)

برای یافتن نقاط اکسترمم، از تابع $L(x)$ نسبت به بردار x گرادیان می‌گیریم. با توجه به قواعد مشتق‌گیری ماتریسی ($\nabla_x(x^\top Qx) = 2Qx$ برای ماتریس متقارن Q و $\nabla_x(c^\top x) = c$):

$$\nabla L(x) = 2(A^\top A)x - 2A^\top b$$

برای یافتن نقطه بهینه، گرادیان را برابر صفر قرار می‌دهیم:

$$2(A^\top A)x - 2A^\top b = 0$$

$$A^\top Ax = A^\top b$$

این همان **معادله نرمال** (Normal Equation) است. چون فرض شده A رتبه ستونی کامل دارد، ماتریس $A^\top A$ معکوس‌پذیر است و جواب یکتا برابر است با:

$$x^* = (A^\top A)^{-1} A^\top b \qquad (۲۲)$$

۳.۹ (c) Second-Order Condition (Convexity)

برای اثبات اینکه x^* یک مینیمم سراسری است، ماتریس هسین (مشتق دوم) $L(x)$ را محاسبه می‌کنیم:

$$\nabla^2 L(x) = \frac{\partial}{\partial x}(2A^\top Ax - 2A^\top b) = 2A^\top A$$

طبق صورت سوال، ماتریس A دارای رتبه ستونی کامل (Full Column Rank) است. در جبر خطی ثابت می‌شود که در این حالت، ماتریس $A^\top A$ یک ماتریس متقارن و **معین مثبت** (Positive Definite) است. از آنجا که هسین تابع همواره معین مثبت است ($\nabla^2 L(x) \succ 0$)، تابع $L(x)$ یک تابع **اکیداً محدب** (Strictly Convex) می‌باشد. در توابع اکیداً محدب، هر نقطه‌ی سکون (که گرادیان در آن صفر است)، **مینیمم سراسری یکتا** (Unique Global Minimizer) است.

نتیجه: x^* تنها نقطه مینیمم‌کننده‌ی تابع خطای کمترین مربعات است.

Question 10: Newton and Quasi-Newton Methods

۱.۱۰ (a) Computing the Newton Step

سوال: گام نیوتن چگونه محاسبه می‌شود؟

پاسخ: روش نیوتن تابع $f(x)$ را در همسایگی نقطه فعلی x_k با یک چندجمله‌ای درجه دوم (سری تیلور مرتبه دوم) تقریب می‌زند:

$$f(x_k + p) \approx f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T \nabla^2 f(x_k) p$$

با مشتق‌گیری از این تقریب نسبت به p و برابر صفر قرار دادن آن، گام بهینه نیوتن به دست می‌آید:

$$p_k = -[\nabla^2 f(x_k)]^{-1} \nabla f(x_k) = -H_k^{-1} g_k \qquad (۲۳)$$

این گام مستقیماً ما را به مینیمِم تقریبِ درجه دوم می‌برد.

۲.۱۰ (b) Failure of Newton's Method

سوال: چه زمانی روش نیوتن ممکن است همگرا نشود (یا به نقطه زینی/ماکزیمم برود)؟

پاسخ: روش نیوتن تنها به دنبال نقطه‌ای است که گرادیان صفر باشد (Stationary Point).

- اگر ماتریس هسین H_k **معین مثبت** (Positive Definite) نباشد (یعنی انحنای تابع رو به بالا نباشد)، تقریب درجه دوم به جای یک «کاسه»، شبیه یک «تپه» یا «زین اسب» می‌شود. در این حالت نیوتن ممکن است به سمت ماکزیمم یا نقطه زینی جذب شود.
- اگر نقطه شروع x_0 بسیار دور از جواب باشد، تقریب درجه دوم معتبر نیست و گام‌های نیوتن ممکن است بسیار بزرگ و واگرا باشند.

۳.۱۰ (c) Non-Descent Direction

سوال: چه زمانی جهت نیوتن یک جهت کاهشی (Descent Direction) نیست؟

پاسخ: شرط جهت کاهشی این است که $\nabla f^T p < 0$. برای گام نیوتن داریم:

$$\nabla f^T p = \nabla f^T(-H^{-1}\nabla f) = -\nabla f^T H^{-1}\nabla f$$

این عبارت تنها زمانی تضمین شده است که منفی باشد که H^{-1} (و در نتیجه H) معین مثبت باشد. اگر H دارای مقادیر ویژه منفی باشد، ممکن است $-\nabla f^T H^{-1}\nabla f > 0$ شود که یعنی حرکت در جهت سربالایی (افزایش تابع).

۴.۱۰ (d) Main Idea of Quasi-Newton

سوال: ایده اصلی روش‌های شبه‌ـنیوتن چیست؟

پاسخ: ایده اصلی این است که به جای محاسبه‌ی پرهزینه‌ی هسین واقعی (H) و معکوس کردن آن (که $O(n^3)$ زمان می‌برد)، یک ماتریس تقریبی B_k ساخته شود که خواص هسین را تقلید کند. این ماتریس در هر تکرار با استفاده از اطلاعات گرادیان‌های قبلی به‌روزرسانی می‌شود (معمولاً با هزینه $O(n^2)$) تا به تدریج به هسین واقعی نزدیک شود.

۵.۱۰ (e) Hessian Approximation (Secant Equation)

سوال: آنها چگونه هسین را بدون مشتقات دوم صریح تقریب می‌زنند؟ (معادله سکانت).

پاسخ: این روش‌ها بر اساس اصل «سکانت» کار می‌کنند. در فضای یک‌بعدی، شیب خط قاطع (سکانت) بین دو نقطه، تقریبی از مشتق دوم است. در فضای چندبعدی، اگر تغییرات مکان را $s_k = x_{k+1} - x_k$ و تغییرات گرادیان را $y_k = \nabla f_{k+1} - \nabla f_k$ بنامیم، ماتریس تقریبی هسین B_{k+1} باید در معادله زیر صدق کند:

$$B_{k+1} s_k = y_k \qquad (۲۴)$$

این معادله (معادله سکانت) تضمین می‌کند که ماتریس تقریبی، رفتار تغییرات گرادیان را در گام آخر به درستی مدل می‌کند.

Question 11: Quadratic Convergence of Newton's Method

۱.۱۱ (a) Definition of Convergence Rates

سوال: همگرایی مربعی را با استفاده از خطای $e_k = x_k - x^*$ تعریف کنید و تفاوت آن را با همگرایی خطی بیان نمایید.

پاسخ: فرض کنیم $e_k = ||x_k - x^*||$ نشان‌دهنده‌ی خطای (فاصله تا جواب بهینه) در تکرار k باشد.

- **همگرایی خطی (Linear Convergence):** یک دنباله دارای نرخ همگرایی خطی است اگر خطا در هر مرحله با یک ضریب ثابت کاهش یابد:

$$\lim_{k \to \infty} \frac{||e_{k+1}||}{||e_k||} = c, \quad \text{where} 0 < c < 1$$

این یعنی تعداد ارقام دقیق جواب در هر مرحله تقریباً به صورت خطی افزایش می‌یابد (مثلاً در هر ۵ تکرار یک رقم اعشار دقیق می‌شود).

- **همگرایی مربعی (Quadratic Convergence):** یک دنباله دارای نرخ همگرایی مربعی

است اگر خطا در مرحله بعد متناسب با **توان دوم** خطای فعلی باشد:

$$\lim_{k\to\infty} \frac{||e_{k+1}||}{||e_k||^2} = M, \quad \text{where} M > 0$$

در این حالت، اگر خطا کوچک باشد (مثلاً 10^{-2})، در مرحله بعد به 10^{-4} و سپس 10^{-8} می‌رسد. به عبارت دیگر، تعداد ارقام دقیق در هر تکرار تقریباً **دو برابر** می‌شود که بسیار سریع‌تر از همگرایی خطی است.

۲.۱۱ (b) Newton Step Approximates Exact Displacement

سوال: نشان دهید اگر x_k به حد کافی به مینیمم محلی x^* نزدیک باشد، جهت نیوتن p_k تقریب خوبی از جابجایی دقیق $(x^* - x_k)$ است.

پاسخ: می‌دانیم که در نقطه مینیمم محلی x^*، گرادیان تابع صفر است:

$$\nabla f(x^*) = 0$$

حال از بسط تیلور مرتبه اول برای تابع گرادیان $\nabla f(x)$ حول نقطه‌ی فعلی x_k استفاده می‌کنیم:

$$\nabla f(x^*) \approx \nabla f(x_k) + \nabla^2 f(x_k)(x^* - x_k)$$

با توجه به اینکه $\nabla f(x^*) = 0$ است، داریم:

$$0 \approx \nabla f(x_k) + H_k(x^* - x_k)$$

که در آن $H_k = \nabla^2 f(x_k)$ ماتریس هسین در تکرار k است. رابطه را برای بدست آوردن ترم جابجایی $(x^* - x_k)$ بازنویسی می‌کنیم:

$$H_k(x^* - x_k) \approx -\nabla f(x_k)$$

با ضرب کردن معکوس هسین (H_k^{-1}) در طرفین (با فرض معکوس‌پذیر بودن هسین در همسایگی

:(x^*

$$(x^* - x_k) \approx -H_k^{-1}\nabla f(x_k)$$

سمت راست این معادله، دقیقاً تعریف گام نیوتن (p_k) است:

$$x^* - x_k \approx p_k \qquad (۲۵)$$

بنابراین ثابت شد که وقتی به جواب نزدیک هستیم، گام نیوتن تقریب بسیار دقیقی از بردار جابجایی لازم برای رسیدن به نقطه بهینه x^* است.

Question 12: Rosenbrock Function (GD vs. Newton)

تابع روزنبروک (Rosenbrock) که به دلیل شکل منحنی تراز خود به تابع موز (Banana Function) مشهور است، یک تابع غیرمحدب استاندارد برای ارزیابی عملکرد الگوریتم‌های بهینه‌سازی است:

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

این تابع دارای یک دره‌ی باریک، طولانی و منحنی‌شکل است که مینیمم سراسری آن در نقطه $x^* = [1, 1]^\top$ با مقدار $f(x^*) = 0$ قرار دارد.

۱.۱۲ (a) Gradient and Hessian Computation

سوال: گرادیان $\nabla f(x)$ و ماتریس هسین $H(x)$ را محاسبه کنید.

پاسخ: ابتدا مشتقات جزئی مرتبه اول را نسبت به x_1 و x_2 محاسبه می‌کنیم:

$$\frac{\partial f}{\partial x_1} = 100 \cdot 2(x_2 - x_1^2)(-2x_1) + 2(1 - x_1)(-1) = -400x_1(x_2 - x_1^2) - 2(1 - x_1)$$
$$\frac{\partial f}{\partial x_2} = 100 \cdot 2(x_2 - x_1^2)(1) = 200(x_2 - x_1^2)$$

بنابراین بردار گرادیان به صورت زیر است:

$$\nabla f(x) = \begin{bmatrix} -400x_1(x_2 - x_1^2) - 2(1 - x_1) \\ 200(x_2 - x_1^2) \end{bmatrix} \tag{۲۶}$$

سپس مشتقات مرتبه دوم را برای تشکیل ماتریس هسین $H(x)$ محاسبه می‌کنیم:

$$f_{11} = \frac{\partial^2 f}{\partial x_1^2} = -400x_2 + 1200x_1^2 + 2$$
$$f_{12} = \frac{\partial^2 f}{\partial x_1 \partial x_2} = -400x_1$$
$$f_{21} = f_{12} = -400x_1$$
$$f_{22} = \frac{\partial^2 f}{\partial x_2^2} = 200$$

بنابراین ماتریس هسین عبارت است از:

$$H(x) = \begin{bmatrix} 1200x_1^2 - 400x_2 + 2 & -400x_1 \\ -400x_1 & 200 \end{bmatrix} \tag{۲۷}$$

۲.۱۲ (b, c, d) Implementation Details

سه الگوریتم زیر در محیط Python پیاده‌سازی شدند و از نقطه شروع دشوار $x_0 = [-1.2, 1]^\top$ اجرا گردیدند:

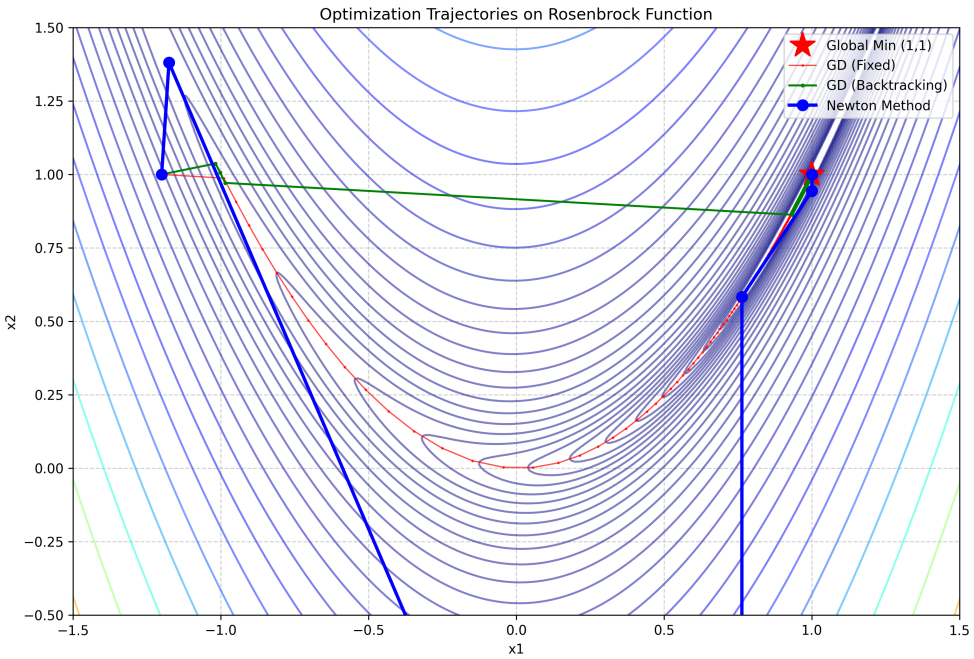
۱. **گرادیان کاهشی با گام ثابت (GD Fixed Step):** با نرخ یادگیری بسیار کوچک $\alpha = 0.001$ (طبق صورت سوال).

۲. **گرادیان کاهشی با Backtracking (بخش امتیازی):** از شرط Armijo برای تنظیم هوشمند نرخ یادگیری در هر مرحله استفاده شد.

۳. **روش نیوتن (Newton's Method):** با گام کامل $\alpha = 1.0$. جهت حرکت با حل دستگاه معادلات $Hd = -g$ محاسبه شد.

۳.۱۲ (e) Visualization and Analysis

نتایج حاصل از اجرای الگوریتم‌ها در نمودارهای زیر نمایش داده شده است.

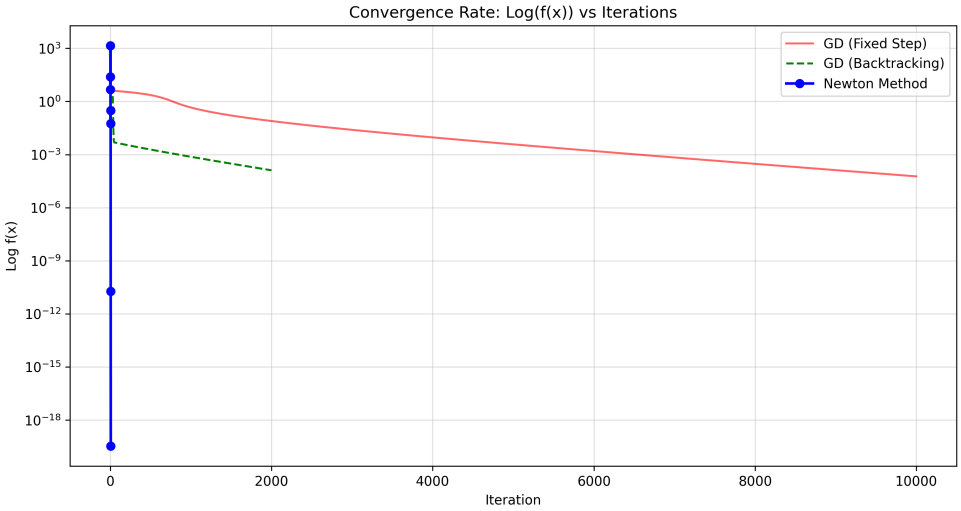


شکل ۶: مسیر حرکت الگوریتم‌های بهینه‌سازی بر روی منحنی تراز تابع روزنبروک. خط قرمز (GD) در کف دره گرفتار شده است، در حالی که خط آبی (Newton) مستقیماً به هدف می‌رسد.

تحلیل نتایج: همانطور که در شکل ۶ مشاهده می‌شود، تابع روزنبروک دارای یک دره‌ی منحنی‌شکل است که گرادیان‌ها در دیواره‌های آن بسیار بزرگ و در کف آن بسیار کوچک هستند.

- **گرادیان کاهشی (Steepest Descent):** این روش (خط قرمز) با موفقیت وارد دره می‌شود، اما به دلیل نوسانات شدید بین دیواره‌ها (Zig-zagging) و کوچک بودن گام، حرکت آن در کف دره بسیار کند است. حتی پس از ۱۰،۰۰۰ تکرار (در حالت گام ثابت)، هنوز به نقطه بهینه نرسیده است. این رفتار نشان‌دهنده‌ی **همگرایی خطی** است (شیب ثابت و ملایم در نمودار شکل ۷).

- **روش نیوتن (Newton's Method):** این روش (خط آبی) با استفاده از ماتریس هسین، اطلاعات انحنای دره را درک می‌کند. به جای نوسان بین دیواره‌ها، مسیر خود را اصلاح کرده و تنها در **۶ تکرار** با دقتی بسیار بالا (10^{-16}) به مینیمم سراسری می‌رسد. سقوط



شکل ۷: نرخ همگرایی (لگاریتم خطا بر حسب تکرار). سقوط عمودی نمودار آبی نشان‌دهنده همگرایی مربعی روش نیوتن است.

ناگهانی در نمودار همگرایی، نشان‌دهنده‌ی **همگرایی مربعی** (Quadratic Convergence) است که در نزدیکی نقطه بهینه رخ می‌دهد.

نتیجه‌گیری: برای توابعی مانند روزنبروک که دارای "دره‌های باریک" و بدـرفتار (Ill-conditioned) هستند، روش‌های مرتبه اول مانند GD عملکرد ضعیفی دارند، در حالی که روش‌های مرتبه دوم مانند نیوتن بسیار کارآمد عمل می‌کنند.

Question 13: Equality-Constrained Optimization

در این سوال، مسئله‌ی بهینه‌سازی مقید زیر را حل می‌کنیم:

$$\min_{x,y} f(x,y) = e^{x^2+y^2} \quad \text{s.t.} \quad g(x,y) = x + y - 1 = 0$$

۱.۱۳ (a) Lagrangian

سوال: تابع لاگرانژ $L(x, y, \lambda)$ را بنویسید.

پاسخ: تابع لاگرانژ برابر است با تابع هدف به اضافه‌ی حاصل‌ضرب ضریب لاگرانژ در قید:

$$L(x, y, \lambda) = e^{x^2+y^2} + \lambda(x + y - 1) \tag{۲۸}$$

۲.۱۳ (b) Optimal Solution (Analytical)

سوال: با حل $\nabla L = 0$، جواب بهینه (x^*, y^*, λ^*) را بیابید.

پاسخ: مشتقات جزئی را محاسبه کرده و برابر صفر قرار می‌دهیم:

$$\frac{\partial L}{\partial x} = 2xe^{x^2+y^2} + \lambda = 0 \tag{۲۹}$$

$$\frac{\partial L}{\partial y} = 2ye^{x^2+y^2} + \lambda = 0 \tag{۳۰}$$

$$\frac{\partial L}{\partial \lambda} = x + y - 1 = 0 \tag{۳۱}$$

از دو معادله‌ی اول داریم:

$$\lambda = -2xe^{x^2+y^2} = -2ye^{x^2+y^2}$$

چون ترم نمایی همواره مثبت است، نتیجه می‌گیریم $x = y$. با جایگذاری در معادله قید ($x + y - 1 = 0$):

$$x + x - 1 = 0 \implies 2x = 1 \implies x^* = 0.5, \quad y^* = 0.5$$

حال λ^* را محاسبه می‌کنیم:

$$\lambda^* = -2(0.5)e^{(0.5)^2+(0.5)^2} = -1 \cdot e^{0.5} = -\sqrt{e} \approx -1.6487$$

بنابراین نقطه بهینه تحلیلی: $w^* = [0.5, 0.5, -1.6487]^\top$.

۳.۱۳ (c) Nonlinear System F(w)

سوال: سیستم غیرخطی 3×3 به نام $F(w) = 0$ را بنویسید.

پاسخ: بردار متغیرها را $w = [x, y, \lambda]^\top$ تعریف می‌کنیم. سیستم معادلات $F(w)$ همان گرادیان لاگرانژ است:

$$F(w) = \nabla L = \begin{bmatrix} 2xe^{x^2+y^2} + \lambda \\ 2ye^{x^2+y^2} + \lambda \\ x + y - 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \tag{۳۲}$$

۴.۱۳ (d) Newton-Raphson Jacobian

سوال: روش نیوتن–رافسون را اعمال کرده و ماتریس ژاکوبین $J_F(w)$ را محاسبه کنید.

پاسخ: رابطه تکرار نیوتن–رافسون برای یافتن ریشه $F(w) = 0$ به صورت زیر است:

$$w_{k+1} = w_k - J_F(w_k)^{-1} F(w_k)$$

ماتریس ژاکوبین $J_F(w)$ شامل مشتقات جزئی F نسبت به x, y, λ است:

$$J_F(w) = \begin{bmatrix} \frac{\partial F_1}{\partial x} & \frac{\partial F_1}{\partial y} & \frac{\partial F_1}{\partial \lambda} \\ \frac{\partial F_2}{\partial x} & \frac{\partial F_2}{\partial y} & \frac{\partial F_2}{\partial \lambda} \\ \frac{\partial F_3}{\partial x} & \frac{\partial F_3}{\partial y} & \frac{\partial F_3}{\partial \lambda} \end{bmatrix}$$

با محاسبه مشتقات (با استفاده از قاعده ضرب برای ترم‌های اول):

$$\frac{\partial F_1}{\partial x} = 2e^{x^2+y^2} + 2x(2x)e^{x^2+y^2} = (2 + 4x^2)e^{x^2+y^2}$$
$$\frac{\partial F_1}{\partial y} = 2x(2y)e^{x^2+y^2} = 4xye^{x^2+y^2}$$

ماتریس کامل ژاکوبین برابر است با:

$$J_F(w) = \begin{bmatrix} (2 + 4x^2)e^{x^2+y^2} & 4xye^{x^2+y^2} & 1 \\ 4xye^{x^2+y^2} & (2 + 4y^2)e^{x^2+y^2} & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

۵.۱۳ (e) Implementation and Convergence Analysis

سوال: روش نیوتن را پیاده‌سازی کنید و همگرایی آن را از نقطه شروع $w_0 = [0, 0, 0]^\top$ به جواب تحلیلی نشان دهید.

پاسخ: الگوریتم نیوتن–رافسون برای حل دستگاه معادلات غیرخطی $F(w) = 0$ در پایتون پیاده‌سازی شد. نتایج اجرا نشان می‌دهد که این روش نرخ همگرایی بسیار بالایی دارد.

- **نقطه شروع:** $w_0 = [0, 0, 0]^\top$. در این نقطه مقدار تابع معادلات $|F(w_0)| = 1.0$ است.
- **روند همگرایی:** تنها پس از **۲ تکرار**، الگوریتم به جواب دقیق همگرا شد:

$$w^* \approx [0.5000,\ 0.5000,\ -1.6487]^\top$$

این مقادیر دقیقاً با جواب‌های تحلیلی بدست آمده در بخش (b) مطابقت دارند ($x = y = 0.5$ و $\lambda = -\sqrt{e}$).

- **نتیجه‌گیری:** سرعت همگرایی در اینجا نیز مربعی است، زیرا در هر گام تعداد ارقام دقیق جواب تقریباً دو برابر شده و خطا به سرعت به سمت صفر میل کرده است.

Question 14: Step-Size Strategies in Gradient Descent

انتخاب نرخ یادگیری مناسب یکی از چالش‌های اصلی در بهینه‌سازی است. در این بخش، دو استراتژی متفاوت پیاده‌سازی و مقایسه می‌شوند.

۱.۱۴ (a) Description of Step-Size Methods

سوال: دو روش انتخاب گام را توضیح دهید.

پاسخ:

۱. **روش پس‌گرد (Backtracking Line Search):** این روش (معروف به شرط Armijo) یک استراتژی کلاسیک و تضمین‌کننده است. در هر تکرار، ابتدا یک گام بزرگ پیشنهاد می‌شود. سپس شرط «کاهش کافی» بررسی می‌شود:

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f_k^T p_k$$

اگر شرط برقرار نباشد، گام به صورت تکراری کوچک می‌شود ($\alpha \leftarrow \rho\alpha$) تا در نهایت شرط ارضا شود. این روش از واگرایی جلوگیری می‌کند.

۲. **روش تطبیقی (RMSProp):** این روش برای حل مشکل نوسانات گرادیان طراحی شده است. به جای یک نرخ یادگیری ثابت، گام حرکت برای هر بُعد جداگانه تنظیم می‌شود. ایده اصلی تقسیم گرادیان بر "جذر میانگین متحرک مربعات گرادیان‌های پیشین" است:

$$x_{k+1} = x_k - \frac{\eta}{\sqrt{E[g^2]_k + \epsilon}} g_k$$

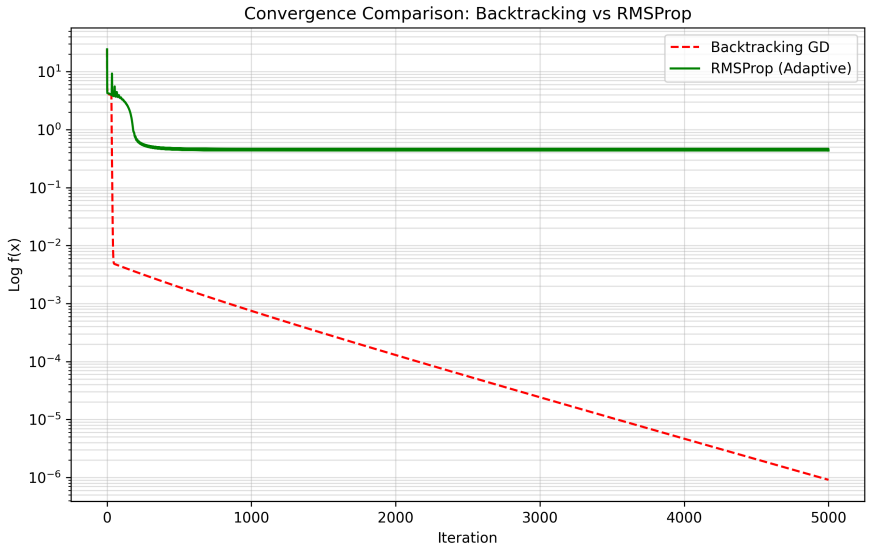
این کار باعث می‌شود در ابعادی که شیب تند و نوسانی است، گام‌ها کوچک شوند و در ابعادی که شیب ملایم است (مانند کف دره روزنبروک)، گام‌ها بزرگتر شوند.

۲.۱۴ (b, c) Implementation and Results

هر دو الگوریتم روی تابع روزنبروک از نقطه شروع $x_0 = [-1.2, 1]^\top$ اجرا شدند. نتایج در نمودار زیر قابل مشاهده است.

تحلیل نتایج:

- **عملکرد Backtracking (خط قرمز):** این روش عملکردی بسیار پایدار و مطمئن دارد. همانطور که در نمودار لگاریتمی پیداست، خطا به صورت خطی و پیوسته کاهش یافته و پس از ۵۰۰۰ تکرار به دقت بسیار بالا (10^{-6}) رسیده است. این نشان می‌دهد که استراتژی کاهش گام در مواجهه با انحنای تابع به درستی عمل کرده است.
- **عملکرد RMSProp (خط سبز):** این روش در ابتدا بسیار سریع عمل کرده و با شیب تندی خطا را کاهش داده است، اما در ادامه (حدود تکرار ۵۰۰) در مقدار خطای تقریبی



شکل ۸: مقایسه روند همگرایی روش Backtracking (قرمز) و RMSProp (سبز).

0.4 متوقف شده (Stagnation) و نتوانسته به مینیمم سراسری دقیق (0) برسد.

- **نتیجه‌گیری:** اگرچه روش‌های تطبیقی مانند RMSProp پتانسیل سرعت بالاتری دارند، اما به شدت به تنظیم دقیق هایپرپارامترها (مانند نرخ یادگیری اولیه و نرخ نزول) حساس هستند. در مقابل، روش Backtracking با اینکه ساده‌تر است، پایداری بیشتری روی توابع بد_قلق مانند روزنبروک از خود نشان می‌دهد.

مراجع

در این تمرین، برای حل مسائل تئوری و اثبات‌های ریاضی (مانند روش‌های نیوتن، شرایط KKT، دوگانگی در SVM و بهینه‌سازی چندهدفه) از منابع اصلی کلاس، شامل جزوات و ویدئوهای درسی اساتید محترم استفاده شده است. برای بخش‌های پیاده‌سازی (سوالات ۵، ۶، ۱۲، ۱۳ و ۱۴) و حل مسائل برنامه‌نویسی، از مستندات رسمی کتابخانه‌های استاندارد پایتون و منابع معتبر آنلاین بهره گرفته شد:

- **[۱] کتابخانه‌های پایتون (ابزارهای پیاده‌سازی):**
  - مستندات کتابخانه‌ی NumPy: برای محاسبات برداری، جبری و پیاده‌سازی الگوریتم‌های بهینه‌سازی.
  - مستندات کتابخانه‌ی Matplotlib: برای رسم نمودارهای همگرایی، مسیر حرکت الگوریتم‌ها و نمایش تصاویر.
  - مستندات کتابخانه‌ی OpenCV (cv2): برای پردازش تصاویر در مسئله حل پازل ژنتیک.
  - پروژه متن‌باز gaps (در گیت‌هاب): به عنوان مرجع و هسته اصلی برای پیاده‌سازی الگوریتم ژنتیک در حل پازل (سوال ۵).
- **[۲] منابع آنلاین (Online Resources):** برای درک عمیق‌تر مفاهیم و رفع اشکالات پیاده‌سازی، از منابع آنلاین عمومی مانند Wikipedia (برای مبانی الگوریتم Simulated Annealing و Genetic Algorithm) و Stack Overflow (برای رفع چالش‌های کدنویسی و خطاهای LaTeX) استفاده شده است.