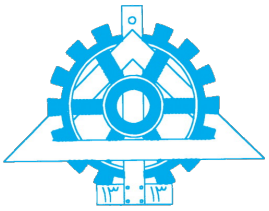


دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۳

نام و نام خانوادگی

محمدمهدی یاری

شماره دانشجویی

۸۱۰۱۰۲۵۳۲

۱۸ آذر ۱۴۰۴

فهرست مطالب

چکیده ۱

۱ Question 1: SVM Fundamentals Kernels ۲

۱.۱ 1. Why Dual Formulation? ۲

۲.۱ 2. Influence of Support Vectors ۳

۳.۱ 3. Kernel Trick in Infinite Dimensions ۳

۴.۱ 4. Effect of Kernel Choice ۴

۲ Question 2: RBF Kernel Feature Space Intuition ۵

۳ Question 3: SVM Dual Symmetric Example ۶

۴ Question 4: Explicit Cubic Feature Map ۹

۵ Question 5: The Mechanics of Splitting (ID3) ۱۱

۶ Question 6: Optimization Geometry & Jensen's Inequality ۱۳

۷ Question 7: The Failure of Greedy Search (XOR) ۱۵

۸ Question 8: Diabetes Classification Using SVM ۱۷

۱.۸ Part 1: Data Preprocessing ۱۷

۲.۸ Part 2: Linear SVM Classification ۱۸

۳.۸ Part 3: Comparison of Different Kernels ۱۸

۴.۸ Part 4: Hyperparameter Tuning ۱۸

۵.۸ Part 5: Dimensionality Reduction (PCA) ۱۹

٦.٨ Part 6: Class Imbalance Analysis ٢٠

٩ Question 9: The QP-SVM Primal Challenge ٢٠

١.٩ Methodology ٢١

٢.٩ Results Visualization ٢٢

١٠ Question 10: Decision Tree Classifier Project ٢٣

١.١٠ Part 1 & 2: Feature Analysis ٢٣

٢.١٠ Part 3 & 4: Implementation & Evaluation ٢٣

٣.١٠ Part 5: Overfitting Pruning Analysis ٢٣

فهرست تصاویر

۱ مقایسه ماتریس درهم‌ریختگی برای داده‌های نرمال‌شده و خام (کرنل خطی) ۱۸
۲ ماتریس درهم‌ریختگی برای سه کرنل مختلف ۱۹
۳ یافتن بهترین پارامترها با Grid Search ۱۹
۴ مرز تصمیم SVM روی داده‌های کاهش‌یافته با PCA ۲۰
۵ مقایسه گزارش دسته‌بندی در حالت استاندارد و متوازن ۲۱
۶ خروجی حل‌کننده QP و پارامترهای بهینه ۲۲
۷ مرز تصمیم QP-SVM روی داده‌های استاندارد شده (دقت تست: ۸۶.۰) . ۲۲
۸ محاسبه بهره اطلاعات و انتخاب ریشه ۲۳
۹ عملکرد مدل روی داده‌های تست (دقت: ۹۱.۰) ۲۴
۱۰ تأثیر پیچیدگی مدل (تعداد برگ‌ها) بر دقت در حضور نویز ۲۴

فهرست جداول

۱ جدول مقایسه عملکرد کرنل‌های مختلف ۱۸

چکیده

این گزارش به تشریح و حل مسائل نظری و عملی مرتبط با درس یادگیری ماشین، با تمرکز بر دو الگوریتم کلیدی ماشین‌های بردار پشتیبان (SVM) و درخت‌های تصمیم (Decision Trees) می‌پردازد. در بخش نظری، مفاهیم بنیادین SVM از جمله فرمول‌بندی دوگان، شرایط KKT، ترفند کرنل و تفسیر هندسی فضای ویژگی با ابعاد نامتناهی (کرنل RBF) مورد تحلیل قرار گرفته است. همچنین مکانیسم انتخاب ویژگی و شاخص‌های آنتروپی و بهره اطلاعات در درخت‌های تصمیم بررسی شده‌اند. در بخش عملی، سه پروژه پیاده‌سازی شده است:

۱. طبقه‌بندی بیماران دیابتی با استفاده از SVM و تحلیل اثر کرنل‌ها و تنظیم فراپارامترها.

۲. حل مسئله Primal SVM به صورت یک مسئله بهینه‌سازی درجه دوم (QP) بدون استفاده از کتابخانه‌های آماده.

۳. پیاده‌سازی کامل الگوریتم ID3 از پایه با قابلیت مدیریت ویژگی‌های پیوسته و تحلیل اثر نویز و هرس کردن بر بیش‌برازش.

نتایج حاصل نشان‌دهنده اهمیت پیش‌پردازش داده‌ها، انتخاب صحیح مدل و تنظیم پیچیدگی مدل برای دستیابی به تعمیم‌پذیری مناسب است.

Question 1: SVM Fundamentals Kernels

در این بخش به پرسش‌های تشریحی پیرامون ساختار ریاضیاتی SVM و دلایل استفاده از روش‌های کرنلی پاسخ داده می‌شود.

۱.۱ 1. Why Dual Formulation?

سوال: چرا فرمول‌بندی دوگان (Dual) در SVM هنگام استفاده از کرنل‌ها ترجیح داده می‌شود؟
پاسخ: استفاده از فرم دوگان دو مزیت اصلی و حیاتی دارد:

۱. **استقلال از ابعاد ویژگی‌ها:** در فرم اولیه (Primal)، پیچیدگی محاسبات و تعداد متغیرها مستقیماً به تعداد ابعاد ویژگی‌ها (d) بستگی دارد. اگر بخواهیم با استفاده از یک نگاشت ویژگی (ϕ) داده‌ها را به فضایی با ابعاد بسیار بالا (یا حتی بی‌نهایت) ببریم، حل مسئله در فرم اولیه غیرممکن یا بسیار پرهزینه می‌شود. اما در فرم دوگان، تعداد متغیرهای بهینه‌سازی (ضرایب لاگرانژ α) تنها برابر با تعداد داده‌های آموزشی (N) است و مستقل از ابعاد فضای ویژگی می‌باشد.

۲. **امکان استفاده از ترفند کرنل (Kernel Trick):** در تابع هدفِ فرم دوگان، بردارهای ویژگی تنها به صورت حاصل‌ضرب داخلی ($\mathbf{x}_i \cdot \mathbf{x}_j$) ظاهر می‌شوند. این ساختار ریاضی به ما اجازه می‌دهد تا بدون نیاز به محاسبه مستقیم بردارها در فضای ویژگی ($\phi(x)$)، حاصل‌ضرب آن‌ها را با استفاده از یک تابع کرنل جایگزین کنیم:

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j) \qquad (۱)$$

این ویژگی کلیدی، محاسبات را در فضاهای پیچیده ممکن می‌سازد.

۲.۱ 2. Influence of Support Vectors

سوال: تفسیر جمله «فقط بردارهای پشتیبان در دسته‌بند نهایی SVM تأثیر دارند» چیست؟ چرا ضرایب دوگان سایر داده‌ها صفر است؟

پاسخ: در الگوریتم SVM، بردار وزن نهایی w به صورت ترکیب خطی از داده‌های آموزشی تعریف می‌شود:

$$w = \sum_{i=1}^{N} \alpha_i y_i x_i$$

طبق شرایط بهینه‌سازی **KKT** (شرط لغزش مکمل یا Complementary Slackness)، رابطه زیر باید همواره برقرار باشد:

$$\alpha_i [y_i (w \cdot x_i + b) - 1] = 0 \qquad (۲)$$

این معادله نتایج زیر را به همراه دارد:

- برای داده‌هایی که به درستی و با حاشیه مطمئن دسته‌بندی شده‌اند (یعنی $y_i(w \cdot x_i + b) > 1$)، عبارت داخل براکت غیرصفر است؛ بنابراین طبق معادله بالا، الزاماً ضریب دوگان آن‌ها باید صفر باشد ($\alpha_i = 0$). این نقاط هیچ تأثیری در محاسبه w و مرز تصمیم نهایی ندارند.

- تنها برای داده‌هایی که دقیقاً روی مرز حاشیه قرار دارند (یعنی $y_i(w \cdot x_i + b) = 1$)، مقدار α_i می‌تواند غیرصفر باشد. این داده‌ها همان **بردارهای پشتیبان** (Support Vectors) هستند که مرز تصمیم را تعیین می‌کنند.

۳.۱ 3. Kernel Trick in Infinite Dimensions

سوال: چگونه ترفند کرنل اجازه فعالیت در فضاهای بی‌نهایت بعدی را می‌دهد؟ (تفسیر ریاضی)

پاسخ: هدف اصلی در SVM کرنلی، محاسبه ضرب داخلی داده‌ها پس از نگاشت به یک فضای ویژگی با ابعاد بالا ($\mathcal{H}$) است، یعنی محاسبه مقدار $\langle \phi(x), \phi(z) \rangle$. اگر فضای ویژگی ابعاد بی‌نهایت داشته باشد (مانند فضای حاصل از کرنل گوسی RBF)، محاسبه مستقیم بردار $\phi(x)$ و سپس ضرب داخلی آن برای کامپیوتر غیرممکن است.

ترفند کرنل یک راهکار ریاضی است که تابعی مانند $K(x, z)$ را معرفی می‌کند. این تابع

در فضای ورودی اصلی (که ابعاد کمی دارد) محاسبه می‌شود، اما خروجی آن دقیقاً برابر با حاصل‌ضرب داخلی در آن فضای پیچیده است:

$$K(x, z) = \langle \phi(x), \phi(z) \rangle \qquad (۳)$$

بنابراین، الگوریتم بدون اینکه هرگز نیاز داشته باشد ماهیت صریح $\phi(x)$ را بداند یا آن را ذخیره کند، از مزایای هندسی فضای بی‌نهایت بعدی بهره‌مند می‌شود.

۴.۱ 4. Effect of Kernel Choice

سوال: انتخاب کرنل (خطی، چندجمله‌ای، RBF) چه تأثیری بر مرز تصمیم، ظرفیت مدل و بیش‌برازش دارد؟

پاسخ:

- **کرنل خطی (Linear):** مرز تصمیم حاصل یک خط راست (در دو بعد) یا یک ابرصفحه تخت است. این مدل کمترین ظرفیت (Capacity) را دارد. اگر داده‌ها ذاتاً غیرخطی باشند، مدل دچار کم‌برازش (Underfitting) می‌شود (بایاس بالا)، اما در برابر بیش‌برازش مقاوم‌تر است.
- **کرنل چندجمله‌ای (Polynomial):** این کرنل مرزهای تصمیم منحنی (مانند سهمی یا دایره) ایجاد می‌کند. با افزایش درجه چندجمله‌ای (d)، انعطاف‌پذیری و ظرفیت مدل افزایش می‌یابد. درجات بسیار بالا می‌تواند باعث پیچ‌خوردگی‌های غیرضروری مرز تصمیم و در نتیجه بیش‌برازش (Overfitting) روی نویزها شود (واریانس بالا).
- **کرنل گوسی (RBF):** این کرنل منعطف‌ترین مرزها را ایجاد می‌کند و می‌تواند نواحی بسته‌ای دور دسته‌های داده (به صورت جزیره‌ای) شکل دهد. RBF متناظر با فضایی با ابعاد بی‌نهایت است، بنابراین ظرفیت مدل بسیار بالاست. پارامتر کلیدی آن γ (یا σ) است؛ اگر پهنای باند خیلی کوچک در نظر گرفته شود (γ بزرگ)، مدل تک‌تک داده‌های آموزشی را حفظ کرده و به شدت دچار بیش‌برازش می‌شود.

Question 2: RBF Kernel Feature Space Intuition

سوال: توضیح دهید چرا کرنل گوسی (RBF) با فرمول زیر می‌تواند به عنوان یک ضرب داخلی در فضای هیلبرت با ابعاد بی‌نهایت تفسیر شود:

$$K(x,z) = \exp\left(-\frac{||x-z||^2}{2\sigma^2}\right)$$

پاسخ: برای درک این موضوع، فرمول کرنل را بسط می‌دهیم و از سری تیلور تابع نمایی استفاده می‌کنیم تا نشان دهیم این کرنل معادل ضرب داخلی دو بردار با بی‌نهایت مؤلفه است.

1. Decomposition of Euclidean Norm

ابتدا عبارت توان را با استفاده از اتحاد مربع دوجمله‌ای باز می‌کنیم:

$$||x-z||^2 = ||x||^2 + ||z||^2 - 2x^T z$$

با جایگذاری در فرمول کرنل و استفاده از خواص تابع نمایی، جملات را تفکیک می‌کنیم:

$$\begin{aligned} K(x,z) &= \exp\left(-\frac{||x||^2 + ||z||^2 - 2x^T z}{2\sigma^2}\right) \\ &= \underbrace{\exp\left(-\frac{||x||^2}{2\sigma^2}\right)}_{C(x)} \cdot \underbrace{\exp\left(-\frac{||z||^2}{2\sigma^2}\right)}_{C(z)} \cdot \exp\left(\frac{x^T z}{\sigma^2}\right) \end{aligned}$$

در اینجا $C(x)$ ضریبی است که تنها به نرم بردار x بستگی دارد. بخش اصلی که تعامل خطی x و z را نشان می‌دهد، جمله سوم است.

2. Taylor Series Expansion

می‌دانیم بسط مک‌لوران برای تابع نمایی e^u به صورت سری نامتناهی همگراست:

$$e^u = \sum_{n=0}^{\infty} \frac{u^n}{n!} = 1 + u + \frac{u^2}{2!} + \frac{u^3}{3!} + \dots$$

با قرار دادن $u = \frac{x^T z}{\sigma^2}$ در رابطه بالا داریم:

$$\exp\left(\frac{x^T z}{\sigma^2}\right) = \sum_{n=0}^{\infty} \frac{1}{n!} \left(\frac{x^T z}{\sigma^2}\right)^n = \sum_{n=0}^{\infty} \frac{1}{n! \sigma^{2n}} (x^T z)^n \qquad (۴)$$

3. Interpretation of Infinite Dimensions

رابطه فوق نشان می‌دهد که کرنل RBF مجموع بی‌نهایت جمله است که هر جمله شامل توان‌های مختلفی از حاصل‌ضرب داخلی $x^T z$ است. اگر نگاشت ویژگی $\phi(x)$ را به صورت برداری تعریف کنیم که شامل تمام تک‌جمله‌ای‌های ممکن از درجه 0 تا ∞ باشد (با ضرایب مناسب)، آنگاه خواهیم داشت:

$$K(x, z) = \langle \phi(x), \phi(z) \rangle$$

از آنجا که سری تیلور تا بی‌نهایت ادامه دارد، بردار $\phi(x)$ باید دارای تعداد نامتناهی مؤلفه باشد. بنابراین، استفاده از کرنل RBF معادل تصویر کردن داده‌ها به یک فضای ویژگی با ابعاد بی‌نهایت (فضای هیلبرت) است.

Question 3: SVM Dual Symmetric Example

سوال: با استفاده از Hard-margin SVM و کرنل خطی، مسئله دوگان را برای داده‌های زیر حل کرده، مقادیر بهینه α_i و سپس پارامترهای اصلی w و b را بیابید.

$$x_1 = (1, 1)^T, \qquad y_1 = +1$$
$$x_2 = (1, -1)^T, \qquad y_2 = +1$$
$$x_3 = (-1, 1)^T, \qquad y_3 = -1$$
$$x_4 = (-1, -1)^T, \qquad y_4 = -1$$

پاسخ:

1. Formulating the Dual Problem

تابع هدف دوگان که باید ماکزیمم شود عبارت است از:

$$\max_{\alpha} \quad L(\alpha) = \sum_{i=1}^{4} \alpha_i - \frac{1}{2} \sum_{i=1}^{4} \sum_{j=1}^{4} \alpha_i \alpha_j y_i y_j (x_i^T x_j) \qquad (۵)$$

با توجه به تقارن هندسی داده‌ها (قرارگیری روی رئوس یک مستطیل و تقارن برچسب‌ها)، می‌توان فرض کرد که تمام ضرایب لاگرانژ در نقطه بهینه برابرند:

$$\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = \alpha$$

همچنین شرط قید تساوی SVM نیز با این فرض برقرار می‌ماند:

$$\sum \alpha_i y_i = \alpha(1) + \alpha(1) + \alpha(-1) + \alpha(-1) = 0 \quad \checkmark$$

2. Computing the Kernel Matrix (Q)

برای محاسبه ترم دوم تابع هدف، ماتریس Q با درایه‌های $Q_{ij} = y_i y_j (x_i^T x_j)$ را تشکیل می‌دهیم.
به عنوان نمونه برای سطر اول:

- $Q_{11} = (+1)(+1)(1+1) = 2$
- $Q_{12} = (+1)(+1)(1-1) = 0$
- $Q_{13} = (+1)(-1)(-1+1) = 0$
- $Q_{14} = (+1)(-1)(-1-1) = 2$

با محاسبه سایر درایه‌ها، ماتریس Q به صورت زیر خواهد بود:

$$Q = \begin{bmatrix} 2 & 0 & 0 & 2 \\ 0 & 2 & 2 & 0 \\ 0 & 2 & 2 & 0 \\ 2 & 0 & 0 & 2 \end{bmatrix}$$

حال مقدار جمله دوم تابع هدف را محاسبه می‌کنیم (مجموع تمام درایه‌های ماتریس ضرب‌در α^2):

$$\sum_{i,j} \alpha_i \alpha_j Q_{ij} = \alpha^2 \sum_{i,j} Q_{ij} = \alpha^2(2+2+2+2+2+2+2+2) = 16\alpha^2$$

3. Optimizing α

تابع هدف بر حسب تک‌متغیر α بازنویسی می‌شود:

$$L(\alpha) = \sum_{i=1}^{4} \alpha - \frac{1}{2}(16\alpha^2) = 4\alpha - 8\alpha^2$$

برای یافتن ماکزیمم، از L نسبت به α مشتق گرفته و برابر صفر قرار می‌دهیم:

$$\frac{dL}{d\alpha} = 4 - 16\alpha = 0 \implies 16\alpha = 4 \implies \alpha^* = 0.25$$

بنابراین جواب بهینه دوگان: $\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0.25$.

4. Recovering Primal Parameters (w, b)

بردار وزن w ترکیب خطی داده‌های پشتیبان است:

$$w = \sum_{i=1}^{4} \alpha_i y_i x_i = 0.25 \left[(+1)\begin{pmatrix}1\\1\end{pmatrix} + (+1)\begin{pmatrix}1\\-1\end{pmatrix} + (-1)\begin{pmatrix}-1\\1\end{pmatrix} + (-1)\begin{pmatrix}-1\\-1\end{pmatrix} \right]$$
$$= 0.25 \left[\begin{pmatrix}1\\1\end{pmatrix} + \begin{pmatrix}1\\-1\end{pmatrix} + \begin{pmatrix}1\\-1\end{pmatrix} + \begin{pmatrix}1\\1\end{pmatrix} \right]$$
$$= 0.25 \begin{pmatrix}4\\0\end{pmatrix} = \begin{pmatrix}1\\0\end{pmatrix}$$

برای محاسبه بایاس b، از رابطه $y_k(w^T x_k + b) = 1$ برای داده‌ی x_1 استفاده می‌کنیم:

$$1\left(\begin{pmatrix}1 & 0\end{pmatrix}\begin{pmatrix}1\\1\end{pmatrix} + b\right) = 1 \implies (1+0) + b = 1 \implies b = 0$$

نتیجه نهایی: دسته‌بند نهایی خط $x_1 = 0$ است و پارامترها عبارتند از:

$$w = \begin{pmatrix}1\\0\end{pmatrix}, \quad b = 0$$

Question 4: Explicit Cubic Feature Map

سوال: بسط چندجمله‌ای کرنل درجه ۳ با بایاس $K(x,z) = (1 + x^\top z)^3$، تعیین ابعاد فضای ویژگی و یافتن نگاشت ویژگی صریح $\phi(x)$.

پاسخ:

1. Expanding the Kernel

اول باید ببینیم فرمول کرنل وقتی باز میشه چه شکلیه. عبارت $x^\top z$ در فضای دو بعدی میشه $x_1z_1+x_2z_2$. پس قراره $(1+x_1z_1+x_2z_2)^3$ رو بسط بدیم. از قضیه چندجمله‌ای (Multinomial Theorem) استفاده می‌کنیم. جملات رو بر اساس توان‌هاشون مرتب می‌کنم:

$$\begin{aligned}K(x,z) = {} & \mathbf{1} \\ & + \mathbf{3}(x_1z_1) + \mathbf{3}(x_2z_2) \\ & + \mathbf{3}(x_1z_1)^2 + \mathbf{3}(x_2z_2)^2 + \mathbf{6}(x_1z_1)(x_2z_2) \\ & + \mathbf{1}(x_1z_1)^3 + \mathbf{1}(x_2z_2)^3 + \mathbf{3}(x_1z_1)^2(x_2z_2) + \mathbf{3}(x_1z_1)(x_2z_2)^2\end{aligned}$$

اگه جملات رو بشماریم، می‌بینیم که ۱۰ تا جمله متمایز داریم. پس ابعاد فضای ویژگی میشه:

$$\text{Dimensionality} = 10$$

2. Finding the Feature Map $\phi(x)$

حالا باید بردار $\phi(x)$ رو جوری بسازیم که وقتی در $\phi(z)$ ضرب داخلی میشه، دقیقاً همون عبارت بالا رو بده. برای این کار، کافیه جذر ضرایب عددی (مثل ۳ و ۶) رو بگیریم و بذاریم کنار متغیرها. بردار ویژگی ما این شکلی میشه:

$$\phi(x) = \begin{pmatrix} 1 \\ \sqrt{3}x_1 \\ \sqrt{3}x_2 \\ \sqrt{3}x_1^2 \\ \sqrt{3}x_2^2 \\ \sqrt{6}x_1x_2 \\ x_1^3 \\ x_2^3 \\ \sqrt{3}x_1^2x_2 \\ \sqrt{3}x_1x_2^2 \end{pmatrix} \tag{۶}$$

3. Verification

برای اینکه مطمئن بشیم، بیایم ضرب داخلی $\phi(x)^\top\phi(z)$ رو حساب کنیم ببینیم همون میشه یا نه:

$$\begin{aligned}\phi(x)^\top\phi(z) = 1\cdot 1 &+ (\sqrt{3}x_1)(\sqrt{3}z_1) + (\sqrt{3}x_2)(\sqrt{3}z_2) \\ &+ (\sqrt{3}x_1^2)(\sqrt{3}z_1^2) + (\sqrt{3}x_2^2)(\sqrt{3}z_2^2) + (\sqrt{6}x_1x_2)(\sqrt{6}z_1z_2) \\ &+ (x_1^3)(z_1^3) + (x_2^3)(z_2^3) + (\sqrt{3}x_1^2x_2)(\sqrt{3}z_1^2z_2) + (\sqrt{3}x_1x_2^2)(\sqrt{3}z_1z_2^2)\end{aligned}$$

حالا اگه ضرایب رو ساده کنیم:

$$= 1 + 3x_1z_1 + 3x_2z_2 + 3x_1^2z_1^2 + 3x_2^2z_2^2 + 6x_1z_1x_2z_2$$
$$+ x_1^3z_1^3 + x_2^3z_2^3 + 3x_1^2z_1^2x_2z_2 + 3x_1z_1x_2^2z_2^2$$

این دقیقاً همون بسط $(1+x^\top z)^3$ هست که اول کار حساب کردیم. پس نگاشتمون درسته.

$$\phi(x)^\top\phi(z) = K(x,z) \quad \checkmark$$

Question 5: The Mechanics of Splitting (ID3)

سوال: با توجه به جدول داده‌های باینری، مراحل الگوریتم ID3 را برای ساخت درخت تصمیم انجام دهید.

پاسخ:

1. Entropy of the Root Node

اول باید ببینیم وضعیت اولیه دیتاست چطوره. کلاً ۶ تا نمونه داریم که ۳ تا کلاس 0 دارن و ۳ تا کلاس 1. پس توزیع احتمالشون دقیقاً ۵۰-۵۰ هست:

- $p_- = \frac{3}{6} = 0.5$ (کلاس ۰)
- $p_+ = \frac{3}{6} = 0.5$ (کلاس ۱)

آنتروپی کل دیتاست (S) با فرمول شانون اینجوری حساب میشه:

$$H(S) = -0.5\log_2(0.5) - 0.5\log_2(0.5) = 1\text{bit}$$

این یعنی بیشترین بی‌نظمی ممکن رو داریم.

2. Calculating Information Gain

حالا باید ببینیم کدوم ویژگی (X_1 یا X_2) بهتر می‌تونه این بی‌نظمی رو کم کنه. برای هر کدوم $Gain$ رو حساب می‌کنیم.

الف) بررسی ویژگی X_1: این ویژگی دو حالت A و B داره:

- اگه $X_1 = A$ باشه (۳ نمونه): دو تا کلاس 0 داریم و یکی 1. آنتروپیش میشه:

$$H(S_A) = -\left(\frac{2}{3}\log_2\frac{2}{3} + \frac{1}{3}\log_2\frac{1}{3}\right) \approx 0.918$$

- اگه $X_1 = B$ باشه (۳ نمونه): یکی کلاس 0 داریم و دو تا 1. آنتروپیش دقیقا مثل بالاییه:

$$H(S_B) \approx 0.918$$

پس بهره اطلاعات برای X_1 میشه:

$$Gain(S, X_1) = 1 - \left[\frac{3}{6}(0.918) + \frac{3}{6}(0.918)\right] = 1 - 0.918 = 0.082$$

ب) بررسی ویژگی X_2: این ویژگی هم دو حالت C و D داره:

- اگه $X_2 = C$ باشه (۳ نمونه): هر ۳ تا کلاسشون 0 هست. یعنی خالصِ خالص! پس آنتروپی صفره ($H(S_C) = 0$).
- اگه $X_2 = D$ باشه (۳ نمونه): هر ۳ تا کلاسشون 1 هست. اینم کاملاً خالصه ($H(S_D) = 0$).

بهره اطلاعات برای X_2 میشه:

$$Gain(S, X_2) = 1 - \left[\frac{3}{6}(0) + \frac{3}{6}(0)\right] = 1$$

نتیجه: تابلوئه که باید X_2 رو انتخاب کنیم چون $Gain = 1$ داره و بیشترین اطلاعات رو بهمون میده.

3. Building the Tree

خوبیِ انتخاب X_2 این بود که تمام شاخه‌هاش به خلوص کامل (آنتروپی صفر) رسیدن. پس دیگه لازم نیست ادامه بدیم و درخت همینجا تموم میشه:

- **ریشه درخت:** ویژگی X_2
  - شاخه C: همه نمونه‌ها 0 هستن ← برگ ۰
  - شاخه D: همه نمونه‌ها 1 هستن ← برگ ۱

چون همه داده‌ها درست دسته‌بندی شدن، خطای آموزش (Training Error) برابر صفر هست.

4. Top-down vs. Bottom-up Approach

سوال اینه که اگه برعکس (پایین به بالا) درخت رو می‌ساختیم همین می‌شد؟ لزوماً نه. الگوریتم ID3 یه روش بالا به پایین و حریصانه هست. یعنی اون بالا وایمیسه و نگاه می‌کنه کدوم ویژگی همون لحظه کارو بهتر راه میندازه و انتخابش می‌کنه. ولی روش‌های "پایین به بالا" معمولاً کل داده‌ها رو اول می‌بینن (مثل خوشه‌بندی) و بعد سعی می‌کنن گروه‌ها رو ترکیب کنن. این ممکنه باعث بشه ساختار نهایی درخت فرق کنه، چون دیدگاه کلی‌تری دارن و ممکنه به خاطر جلوگیری از بیش‌برازش، درخت ساده‌تری بسازن که دقیقاً منطبق بر انتخاب‌های حریصانه ID۳ نباشه.

Question 6: Optimization Geometry & Jensen's Inequality

سوال: اثبات مقعر بودن آنتروپی، نامنفی بودن بهره اطلاعات با نابرابری ینسن و مشکل بهینه‌سازی محلی در ID3.

پاسخ:

1. Concavity of Entropy

برای اینکه نشون بدیم تابع آنتروپی مقعر (Concave) هست، کافیه ازش دو بار مشتق بگیریم و علامت مشتق دوم رو بررسی کنیم. تابع آنتروپی برای یک احتمال p به صورت زیره (از لگاریتم

طبیعی استفاده می‌کنیم چون فقط ضریب ثابت با مبنای ۲ فرق داره):

$$H(p) = -\frac{1}{\ln 2}\left(p \ln p + (1-p)\ln(1-p)\right)$$

اول مشتق مرتبه اول رو نسبت به p حساب می‌کنیم:

$$\begin{aligned} H'(p) &= -\frac{1}{\ln 2}\left[(1 \cdot \ln p + p \cdot \frac{1}{p}) + (-1 \cdot \ln(1-p) + (1-p) \cdot \frac{-1}{1-p})\right] \\ &= -\frac{1}{\ln 2}\left[\ln p + 1 - \ln(1-p) - 1\right] \\ &= \frac{1}{\ln 2}\left(\ln(1-p) - \ln p\right) \end{aligned}$$

حالا میریم سراغ مشتق دوم:

$$H''(p) = \frac{1}{\ln 2}\left[\frac{-1}{1-p} - \frac{1}{p}\right] = -\frac{1}{\ln 2}\left[\frac{p + (1-p)}{p(1-p)}\right] = \frac{-1}{\ln 2 \cdot p(1-p)}$$

همونطور که می‌بینیم، برای هر p بین ۰ و ۱، مخرج کسر یعنی $p(1-p)$ همواره مثبته. چون صورت کسر منفیه، پس کل عبارت همیشه منفی میشه ($H''(p) < 0$). و می‌دونیم وقتی مشتق دوم اکیداً منفی باشه، یعنی تابع اکیداً مقعر هست.

2. Why Information Gain is Non-negative?

اینجا از نابرابری ینسن (Jensen's Inequality) استفاده می‌کنیم. این نابرابری برای توابع مقعر میگه که «میانگین وزن‌دار مقادیر تابع» همیشه کوچکتر یا مساوی «مقدار تابع در میانگین ورودی‌ها» هست:

$$\sum \lambda_i f(x_i) \leq f\left(\sum \lambda_i x_i\right)$$

توی بحث درخت تصمیم:

- تابع f همون آنتروپی H هست (که بالا ثابت کردیم مقعره).
- وزن‌ها (λ_i) همون نسبت داده‌ها توی هر شاخه ($\frac{|S_v|}{|S|}$) هستن.

پس طبق ینسن، جمع وزن‌دار آنتروپی بچه‌ها (عبارت سمت چپ) همیشه کمتر یا مساوی

آنتروپی کل دیتاست (عبارت سمت راست) میشه:

$$\sum_{v} \frac{|S_v|}{|S|} H(S_v) \leq H(S)$$

حالا فرمول Information Gain چیه؟ دقیقاً تفاضل همین دوتاست:

$$Gain = H(S) - \sum \frac{|S_v|}{|S|} H(S_v)$$

چون طبق رابطه بالا مقدار کسرشونده همیشه کوچیکتره، پس حاصل تفریق همیشه بزرگتر یا مساوی صفر میشه. یعنی بهره اطلاعات هیچ‌وقت منفی نمیشه.

3. The Problem with Greedy Search (Hill Climbing)

الگوریتم ID3 ذاتاً حریصانه (Greedy) عمل می‌کنه؛ یعنی توی هر مرحله فقط جلوی پاش رو نگاه می‌کنه و ویژگی‌ای رو انتخاب می‌کنه که همون لحظه آنتروپی رو کم کنه (تپه‌نوردی). مشکل اینه که ممکنه تو یه بهینه محلی گیر کنه.

یک مثال کلاسیک، مسئله XOR هست ($Y = X_1 \oplus X_2$). توی این حالت، اگه فقط روی X_1 اسپلیت بزنیم، توزیع کلاس‌ها توی فرزندان همچنان ۵۰-۵۰ می‌مونه و هیچ اطلاعاتی کسب نمی‌کنیم ($Gain = 0$). برای X_2 هم همینطوره. الگوریتم ID3 چون می‌بینه هیچکدوم از ویژگی‌ها به تنهایی اوضاع رو بهتر نمی‌کنن، ممکنه فکر کنه کار تمومه یا رندوم انتخاب کنه. در حالی که اگه "دو مرحله" جلوتر رو می‌دید، متوجه می‌شد که ترکیب این دوتا ویژگی مسئله رو کاملاً حل می‌کنه. این نشون میده ID۳ نمی‌تونه تعاملات بین ویژگی‌ها (Feature Interactions) رو درک کنه و ممکنه توی یه حالت غیربهینه متوقف بشه.

Question 7: The Failure of Greedy Search (XOR)

سوال: با داده‌های مسئله XOR، نشون بدید چرا ID3 اول کار گیج میشه و بعد مفهوم Induc-tive Bias رو بررسی کنید.

پاسخ:

1. The Greedy Trap

بریم سراغ محاسبات. کلاً ۴ تا داده داریم (دو تا ۰، دو تا ۱). پس آنتروپی کل دیتاست دقیقاً ۱ میشه (بیشترین بی‌نظمی). حالا بیایم Information Gain رو برای ویژگی X_1 حساب کنیم:

- اگه $X_1 = 0$ باشه: دو تا نمونه داریم (یکی ۰، یکی ۱). پس آنتروپی این شاخه هنوز ۱ هست.
- اگه $X_1 = 1$ باشه: باز هم دو تا نمونه داریم (یکی ۱، یکی ۰). آنتروپی اینم ۱ هست.

نتیجه چی میشه؟ آنتروپی قبل و بعد از تقسیم هیچ فرقی نکرد!

$$Gain(S, X_1) = 1 - 1 = 0$$

به خاطر تقارن مسئله، برای X_2 هم دقیقاً همین اتفاق می‌افته ($Gain = 0$).
نتیجه: الگوریتم ID3 که حریصه، می‌بینه هیچکدوم از ویژگی‌ها به تنهایی هیچ کمکی نمی‌کنن (بهره اطلاعات صفر). برای همین ممکنه فکر کنه این ویژگی‌ها بی‌ارزشن و متوقف بشه یا شانسی یکی رو انتخاب کنه. در حالی که ترکیبشون مهمه که ID۳ اون رو نمی‌بینه.

2. Existence of a Correct Tree

با اینکه ID۳ گیج میشه، ولی یه درخت خیلی ساده با عمق ۲ وجود داره که کاملاً مسئله رو حل می‌کنه:

- ریشه رو بذاریم X_1.
- اگه رفتیم چپ ($X_1 = 0$): حالا روی X_2 شرط بذاریم. اگه $X_2 = 0$ خروجی ۰، اگه $X_2 = 1$ خروجی ۱.
- اگه رفتیم راست ($X_1 = 1$): باز روی X_2 شرط بذاریم. این دفعه اگه $X_2 = 0$ خروجی ۱، اگه $X_2 = 1$ خروجی ۰.

این درخت دقیقاً همون تابع XOR هست.

3. Inductive Bias

الف) تعریف Preference Bias: بایاس ترجیحی (یا Search Bias) یعنی الگوریتم ما توانایی ساختن درخت درست رو داره (محدودیت نداره)، ولی خودش "ترجیح میده" دنبال یه سری درخت‌های خاص بگرده. مثلاً ID۳ عاشق درخت‌های کوتاه و درختایی هست که همون اول کار Gain Information بالایی داشته باشن.

ب) تحلیل شکست: شکست ID۳ توی مسئله XOR دقیقاً نشون‌دهنده همین بایاس ترجیحیه. ما دیدیم که درخت درست وجود داره (بخش ۲)، پس مشکل از "ناتوانی در نمایش" (Restriction Bias) نیست. مشکل اینه که ID۳ ترجیح میده درختی بسازه که تو همون گام اول سود زیادی بده. چون تو مسئله XOR سود گام اول صفره، ID۳ اون مسیر درست رو ول می‌کنه و گمراه میشه. این یعنی ID۳ کل فضای فرضیه رو نمی‌گرده، بلکه فقط جاهایی رو می‌گرده که "به نظرش" پرسودتر هستن.

Question 8: Diabetes Classification Using SVM

در این بخش، یک خط لوله (Pipeline) کامل یادگیری ماشین با استفاده از الگوریتم SVM روی دیتاست دیابت پیما پیاده‌سازی و تحلیل شده است.

۱.۸ Part 1: Data Preprocessing

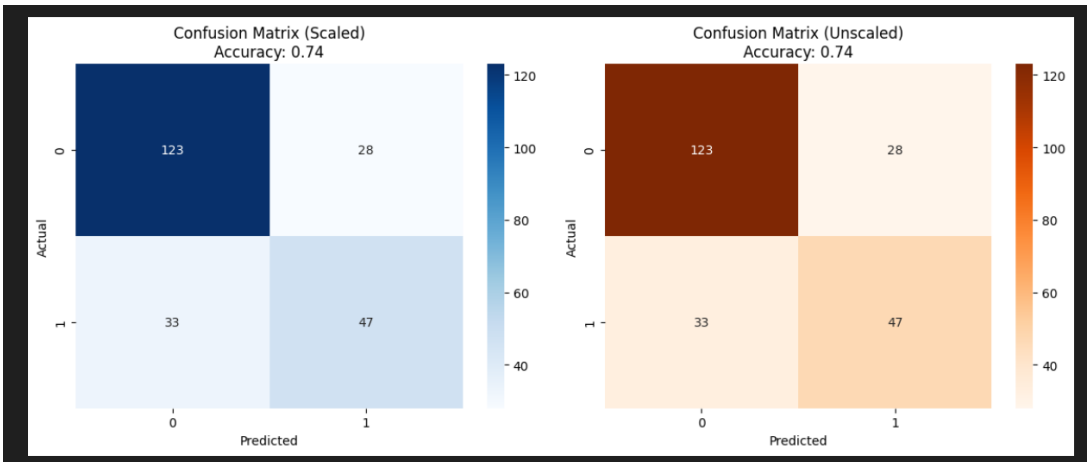
ابتدا داده‌ها بارگذاری شدند. مقادیر صفر نامعتبر در ستون‌های Glucose، BloodPressure، SkinThickness، Insulin و BMI شناسایی و با میانگین همان ستون جایگزین شدند. سپس داده‌ها به نسبت ٪۷۰ آموزش و ٪۳۰ تست تقسیم و با استفاده از StandardScaler نرمال‌سازی شدند.

سوال: چرا مقیاس‌بندی ویژگی‌ها در SVM مهم است؟

پاسخ: الگوریتم SVM بر اساس فاصله اقلیدسی (برای محاسبه حاشیه) کار می‌کند. اگر ویژگی‌ها مقیاس‌های متفاوتی داشته باشند (مثلاً یکی در بازه ۰ تا ۱ و دیگری ۰ تا ۱۰۰۰)، ویژگی‌های بزرگتر بر تابع هزینه مسلط می‌شوند و مدل نمی‌تواند به درستی همگرا شود. نرمال‌سازی باعث می‌شود تمام ویژگی‌ها وزن یکسانی در تعیین مرز تصمیم داشته باشند.

۲.۸ Part 2: Linear SVM Classification

یک مدل SVM با کرنل خطی آموزش داده شد. همچنین برای بررسی اثر نرمال‌سازی، مدل روی داده‌های خام نیز اجرا گردید.



شکل ۱ : مقایسه ماتریس درهم‌ریختگی برای داده‌های نرمال‌شده و خام (کرنل خطی)

تحلیل: همان‌طور که در شکل ۱ مشاهده می‌شود، در این مورد خاص دقت مدل تغییر چشمگیری نکرده است (حدود ٪۷۴)، اما نرمال‌سازی سرعت همگرایی را افزایش می‌دهد و از مشکلات عددی در بهینه‌سازی جلوگیری می‌کند.

۳.۸ Part 3: Comparison of Different Kernels

سه کرنل Linear، RBF و Polynomial مقایسه شدند. نتایج حاصله به شرح زیر است:

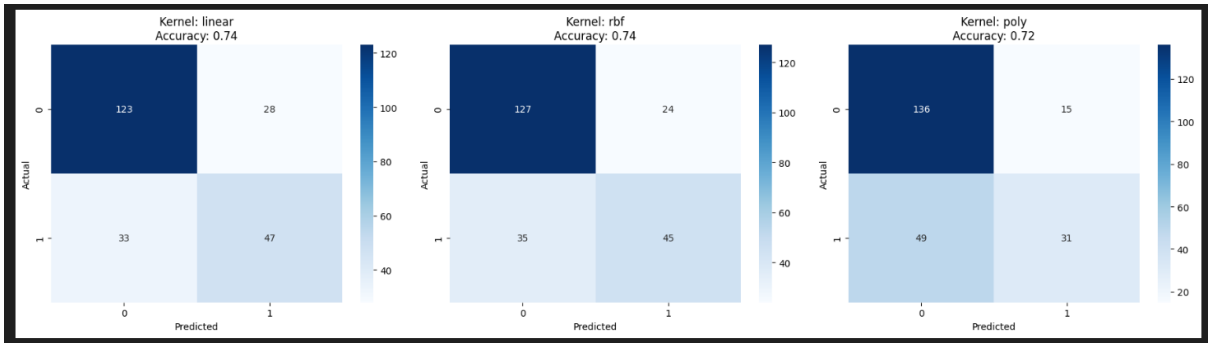
F۱-score	Recall	Precision	Accuracy	Kernel
۶۰۶.۰	۵۸۷.۰	۶۲۶.۰	۷۳۵۹.۰	Linear
۶۰۴.۰	۵۶۲.۰	۶۵۲.۰	۷۴۴۵.۰	RBF
۴۹۲.۰	۳۸۷.۰	۶۷۳.۰	۷۲۲۹.۰	Polynomial

جدول ۱ : جدول مقایسه عملکرد کرنل‌های مختلف

تحلیل: کرنل RBF بهترین دقت کلی را داشت. کرنل چندجمله‌ای بدترین عملکرد (به‌ویژه در Recall) را نشان داد که احتمالاً ناشی از عدم تنظیم دقیق درجه یا بیش‌برازش است.

۴.۸ Part 4: Hyperparameter Tuning

با استفاده از GridSearchCV بهترین پارامترها برای کرنل RBF جستجو شد.



شکل ۲: ماتریس درهم‌ریختگی برای سه کرنل مختلف

```
Best Parameters found: {'C': 10, 'gamma': 0.001, 'kernel': 'rbf'}
Best Cross-Validation Accuracy: 0.7747

Test Set Accuracy with Best Parameters: 0.7489

Classification Report (Best Model):

              precision    recall  f1-score   support

           0       0.79      0.84      0.81       151
           1       0.66      0.57      0.61        80

    accuracy                           0.75       231
   macro avg       0.72      0.71      0.71       231
weighted avg       0.74      0.75      0.74       231
```

شکل ۳: یافتن بهترین پارامترها با Grid Search

بهترین پارامترها: $C = 10$ و $\gamma = 0.001$.

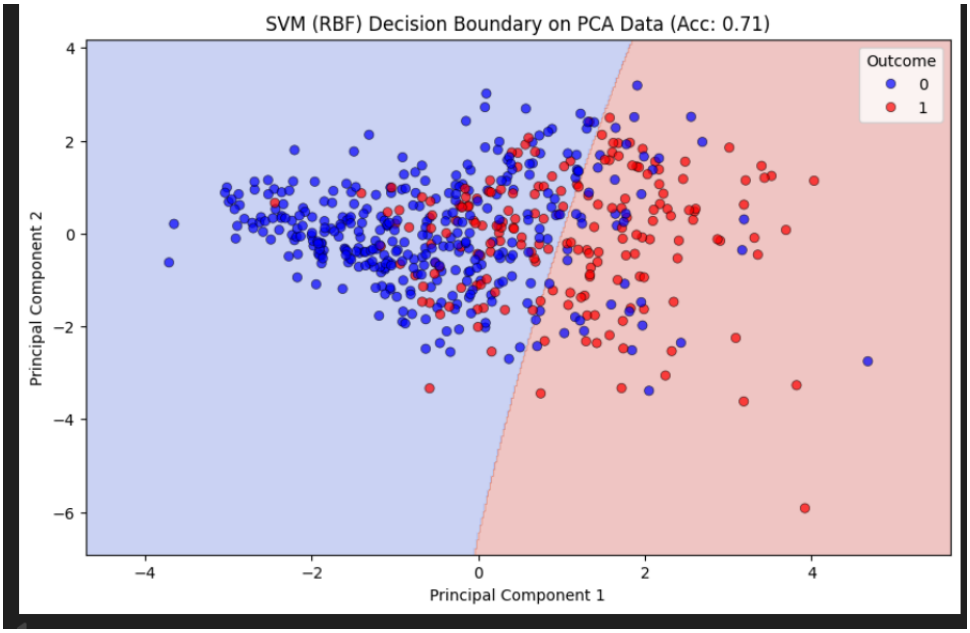
سوال: اثر مقادیر بسیار بزرگ C چیست؟

پاسخ: مقدار C بزرگ جریمه خطای دسته‌بندی را افزایش می‌دهد (Hard Margin). این کار باعث می‌شود مدل سعی کند تمام داده‌های آموزشی را درست دسته‌بندی کند که منجر به مرز تصمیم پیچیده و **بیش‌برازش** (Overfitting) می‌شود (واریانس بالا).

۵.۸ Part 5: Dimensionality Reduction (PCA)

ابعاد داده‌ها با PCA از ۸ به ۲ کاهش یافت و مرز تصمیم رسم شد.

تحلیل: دقت مدل از حدود ٪۷۵ به ٪۷۱ کاهش یافت. دلیل این افت، از دست رفتن اطلاعات هنگام فشرده‌سازی ۸ ویژگی به ۲ ویژگی است. همان‌طور که در شکل پیداست، کلاس‌ها



شکل ۴: مرز تصمیم SVM روی داده‌های کاهش‌یافته با PCA

در فضای دو بعدی تداخل زیادی دارند.

۶.۸ Part 6: Class Imbalance Analysis

به دلیل نامتوازن بودن کلاس‌ها (٪۳۵ بیمار، ٪۶۵ سالم)، از پارامتر class_weight='balanced' استفاده شد.

نتیجه‌گیری: استفاده از وزن‌دهی متوازن باعث شد **Recall** کلاس بیماران (کلاس ۱) از **۵۷.۰** به **۶۶.۰** افزایش یابد. اگرچه دقت کلی کمی کاهش یافت، اما در کاربردهای پزشکی شناسایی بیماران (کاهش منفی کاذب) اولویت دارد، بنابراین مدل متوازن عملکرد مطلوب‌تری دارد.

Question 9: The QP-SVM Primal Challenge

در این چالش، به جای استفاده از کتابخانه‌های آماده، فرمول اولیه (Primal) ماشین بردار پشتیبان به صورت یک مسئله برنامه‌ریزی درجه دوم (QP) فرمول‌بندی و حل شد.

```
Percentage of Class 0 (No Diabetes): 64.99%
Percentage of Class 1 (Diabetes): 35.01%

--- Standard SVM (Best Tuned) ---
              precision    recall  f1-score   support

           0       0.79      0.84      0.81       151
           1       0.66      0.57      0.61        80

    accuracy                           0.75       231
   macro avg       0.72      0.71      0.71       231
weighted avg       0.74      0.75      0.74       231


--- Balanced SVM (class_weight='balanced') ---
              precision    recall  f1-score   support

           0       0.80      0.72      0.76       151
           1       0.56      0.66      0.61        80

    accuracy                           0.70       231
   macro avg       0.68      0.69      0.68       231
weighted avg       0.72      0.70      0.71       231


Recall for Class 1 (Standard): 0.5750
Recall for Class 1 (Balanced): 0.6625
```

شکل ۵: مقایسه گزارش دسته‌بندی در حالت استاندارد و متوازن

۱.۹ Methodology

مسئله بهینه‌سازی زیر با استفاده از کتابخانه cvxpy پیاده‌سازی گردید:

$$\begin{aligned} \min_{w,b,\xi} \quad & \frac{1}{2}||w||^2 + C\sum_{i=1}^{n}\xi_i \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \forall i \\ & \xi_i \geq 0, \quad \forall i \end{aligned}$$

پس از حل مسئله، مقادیر بهینه w^* و b^* استخراج شدند.

۲.۹ Results Visualization

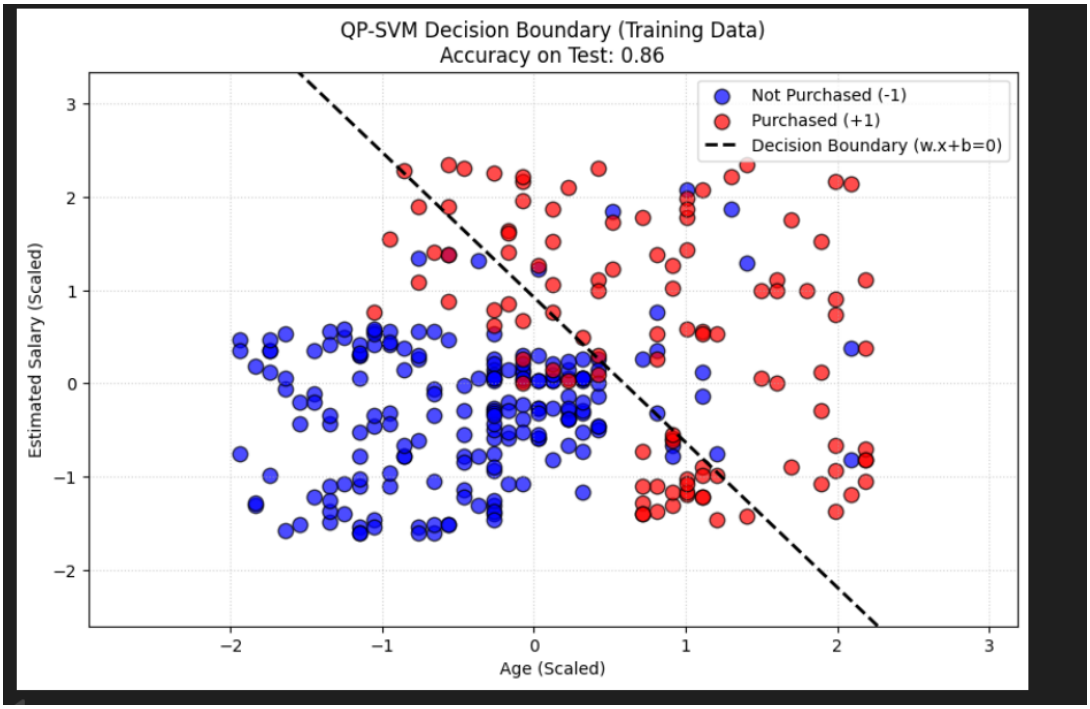
حل‌کننده وضعیت مسئله را Optimal گزارش کرد که نشان‌دهنده یافتن کمینه سراسری است.

```
Solving QP problem...

Step 2 Completed.
Status: optimal
Optimal w: [1.37454417 0.8839677 ]
Optimal b: -0.8152973370252864
```

شکل ۶: خروجی حل‌کننده QP و پارامترهای بهینه

سپس مرز تصمیم $w^* \cdot x + b^* = 0$ روی داده‌های آموزشی رسم شد و مدل روی داده‌های تست ارزیابی گردید.



شکل ۷: مرز تصمیم QP-SVM روی داده‌های استاندارد شده (دقت تست: ۸۶.۰)

نتیجه‌گیری: مدل پیاده‌سازی شده توانست با دقت ٪۸۶ روی داده‌های تست عمل کند که نشان‌دهنده صحت فرمول‌بندی ریاضی و عملکرد صحیح الگوریتم در جداسازی کلاس‌ها است.

Question 10: Decision Tree Classifier Project

در این پروژه، یک طبقه‌بند درخت تصمیم با استفاده از الگوریتم ID3 از پایه پیاده‌سازی شد. هدف بررسی عملکرد الگوریتم روی داده‌های تنیس و تحلیل پدیده بیش‌برازش بود.

۱.۱۰ Part 1 & 2: Feature Analysis

ابتدا پدیده «تله کاردینالیتی» (High Cardinality Trap) بررسی شد. محاسبات نشان داد که ویژگی Day_ID با وجود داشتن بیشترین بهره اطلاعات ممکن (برابر با آنتروپی سیستم)، به دلیل عدم توانایی در تعمیم‌دهی (Generalization) باید حذف شود. سپس با پیاده‌سازی موتور آنتروپی، ویژگی Outlook به عنوان ریشه درخت انتخاب گردید.

```
Root Node Selection Analysis:
Feature: Outlook    | Information Gain: 0.3431
Feature: Humidity   | Information Gain: 0.0539
Feature: Wind       | Information Gain: 0.0382

Best feature for Root Node: Outlook
```

شکل ۸: محاسبه بهره اطلاعات و انتخاب ریشه

۲.۱۰ Part 3 & 4: Implementation & Evaluation

کلاس DecisionTreeID3 توسعه داده شد که قابلیت مدیریت ویژگی‌های پیوسته (مانند Temperature) را با یافتن بهترین نقطه برش دارد. مدل روی ٪۸۰ داده‌ها آموزش دید و نتایج زیر روی داده‌های تست حاصل شد:

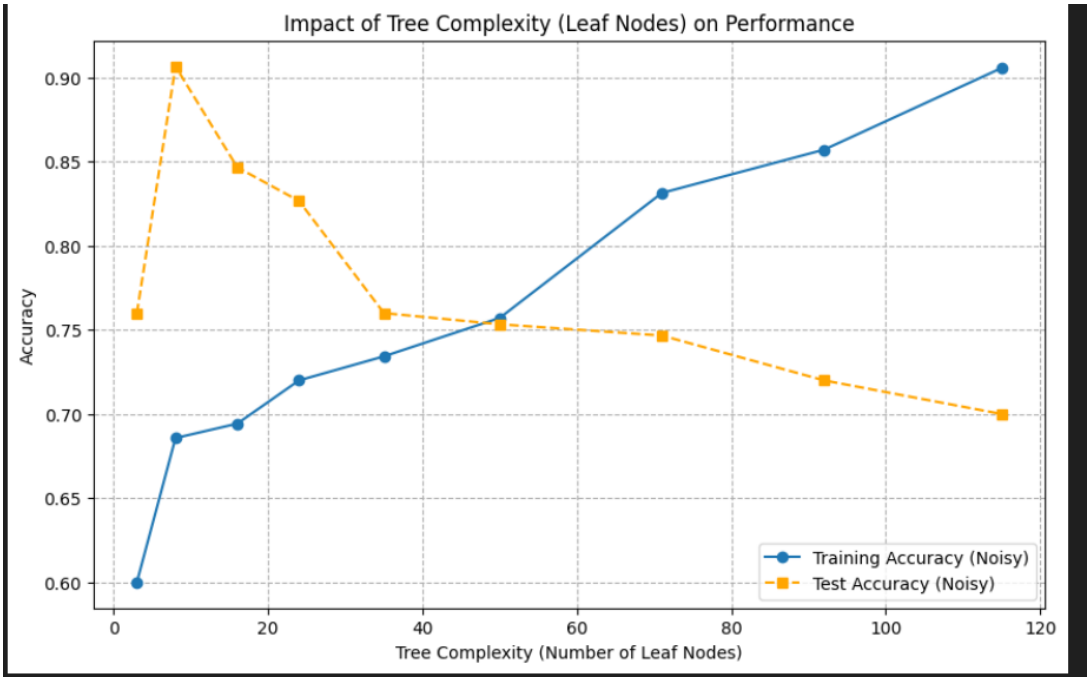
۳.۱۰ Part 5: Overfitting Pruning Analysis

برای تحلیل رفتار درخت در مواجهه با نویز، ٪۲۰ از برچسب‌های داده‌ها تغییر داده شد. آزمایش نشان داد که:

```
Decision Tree Results:
Accuracy: 0.91
Precision: 0.90
Recall: 0.95
```

شکل ۹: عملکرد مدل روی داده‌های تست (دقت: ۹۱.۰)

- با افزودن نویز، الگوریتم برای حفظ داده‌های غلط، شاخه‌های بسیار بیشتری ایجاد کرد (افزایش تعداد برگ‌ها).
- نمودار زیر رابطه بین **پیچیدگی درخت** (تعداد برگ‌ها) و دقت را نشان می‌دهد. همان‌طور که مشخص است، با افزایش تعداد برگ‌ها، دقت آموزش به ٪۱۰۰ میل می‌کند، اما دقت تست پس از یک نقطه بهینه، دچار افت می‌شود که نشانه واضح **بیش‌برازش** است.



شکل ۱۰: تأثیر پیچیدگی مدل (تعداد برگ‌ها) بر دقت در حضور نویز

نتیجه‌گیری: هرس کردن درخت (Pruning) یا محدود کردن تعداد برگ‌ها، با کاهش واریانس مدل، باعث بهبود عملکرد روی داده‌های جدید می‌شود.

مراجع

[1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

[2] Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.

[3] Lecture Notes & Homework Statement, Machine Learning Basics Course, Fall 2025.