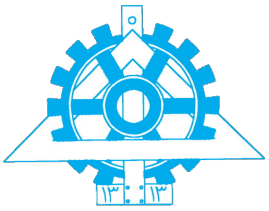


دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۴

نام و نام خانوادگی

محمدمهدی یاری

شماره دانشجویی

۸۱۰۱۰۲۵۳۲

۱۴ بهمن ۱۴۰۴

فهرست مطالب

چکیده ۱

۱ یک تکرار کامل الگوریتم K-Means ۲

۱.۱ داده‌ها و مراکز اولیه ۲

۲.۱ گام اول: تخصیص نقاط به خوشه‌ها ۲

۳.۱ گام دوم: به‌روزرسانی مراکز خوشه‌ها ۳

۴.۱ گزارش نهایی ۳

۲ استراتژی‌های پیوند در خوشه‌بندی سلسله‌مراتبی ۴

۱.۲ مقایسه پیچیدگی محاسباتی ۴

۲.۲ مقاومت در برابر داده‌های پرت (Outliers) ۴

۳.۲ خوشه‌بندی با روش Linkage Complete و رسم دندروگرام ۵

۳ کاهش ابعاد و هندسه داده‌ها ۶

۴ تئوری فرمال LDA و PCA Kernel ۷

۱.۴ اثبات تعداد جهت‌های متمایزساز در LDA ۸

۲.۴ تئوری PCA Kernel ۸

۵ محاسبات دستی تحلیل متمایزساز خطی (LDA) ۹

۱.۵ گام اول: محاسبه میانگین‌ها ۱۰

۲.۵ گام دوم: محاسبه ماتریس‌های پراکندگی (Scatter Matrices) ۱۰

۳.۵ گام سوم: تعیین جهت متمایزساز بهینه (w) ۱۱

۴.۵ گام چهارم: تصویر کردن نقاط (Projection) ۱۱

۶ تحلیل روش‌های انتخاب ویژگی (Feature Selection) ۱۲
۱.۶ عملکرد متدهای انتخاب متوالی (Sequential Selection) ۱۲
۲.۶ تحلیل رفتار حریصانه (Greedy Behavior) ۱۲
۳.۶ مقایسه با روش‌های جایگزین ۱۳

۷ تحلیل عملی کاهش ابعاد روی مجموعه داده‌های Iris و Circles ۱۳
۱.۷ بخش اول: تحلیل PCA روی مجموعه داده Iris ۱۳
۲.۷ بخش دوم: مقایسه PCA و PCA Kernel روی داده‌های غیرخطی . . . ۱۴

۸ تحلیل جامع انتخاب ویژگی و کاهش ابعاد بر روی داده‌های بیماری قلبی ۱۶
۱.۸ تحلیل اکتشافی و بررسی همبستگی خطی ۱۶
۲.۸ رتبه‌بندی ویژگی‌ها بر اساس اطلاعات متقابل (Mutual Information) . . . ۱۶
۳.۸ انتخاب ویژگی بازگشتی با اعتبارسنجی متقاطع (RFECV) ۱۸
۴.۸ کاهش ابعاد با PCA و مقایسه با روش‌های انتخاب ویژگی ۱۸

۹ قطعه‌بندی تصویر با استفاده از ویژگی‌های ۵ـ بعدی: مقایسه K-Means و GMM ۲۰
۱.۹ تحلیل عملکرد الگوریتم K-Means ۲۰
۲.۹ تحلیل عملکرد مدل مخلوط گوسی (GMM) ۲۰

منابع و مراجع ۲۳

فهرست تصاویر

۱ دندروگرام حاصل از خوشه‌بندی Complete Linkage ۶
۲ کاهش ابعاد دیتاست Iris با استفاده از PCA ۱۵
۳ مقایسه عملکرد PCA خطی و Kernel PCA روی داده‌های دایره‌ای ۱۵
۴ ماتریس همبستگی ویژگی‌های دیتاست بیماری قلبی ۱۷
۵ رتبه‌بندی اهمیت ویژگی‌ها با استفاده از Mutual Information ۱۷
۶ نمودار تغییرات دقت مدل بر اساس تعداد ویژگی‌های منتخب (RFECV) . . ۱۹
۷ نمودار واریانس تراکمی مولفه‌های اصلی (PCA) ۱۹
۸ نتایج سگمنتیشن تصویر هواپیما (ردیف اول: K-Means، ردیف دوم: GMM) ۲۲
۹ نتایج سگمنتیشن تصویر عقاب (ردیف اول: K-Means، ردیف دوم: GMM) ۲۲
۱۰ مقایسه الگوریتم‌های خوشه‌بندی برای مقادیر $K \in \{2, 3, 4, 5\}$ ۲۲

فهرست جداول

چکیده

این گزارش به بررسی و حل مسائل تمرین چهارم درس مبانی یادگیری ماشین می‌پردازد. تمرکز اصلی این مجموعه سوالات بر الگوریتم‌های خوشه‌بندی از جمله K-Means و روش‌های خوشه‌بندی سلسله‌مراتب، و همچنین تکنیک‌های کاهش ابعاد مانند PCA، Kernel PCA و LDA است. در بخش‌های عملی، کاربرد این روش‌ها در پیش‌پردازش داده، انتخاب ویژگی و قطعه‌بندی تصاویر مورد تحلیل قرار گرفته است.

یک تکرار کامل الگوریتم K-Means

در این سوال، داده‌های مجموعه D را داریم و می‌خواهیم با دو مرکز اولیه μ_0 و μ_1، یک تکرار کامل الگوریتم را با فاصله اقلیدسی انجام دهیم.

۱.۱ داده‌ها و مراکز اولیه

داده‌ها به شرح زیر هستند:

- $x_1 = (5.5, 3.1)$
- $x_2 = (5.1, 4.8)$
- $x_3 = (6.6, 3.0)$
- $x_4 = (5.5, 4.6)$
- $x_5 = (6.8, 3.8)$

مراکز اولیه:

- $\mu_0 = (5.3, 3.5)$
- $\mu_1 = (5.1, 4.2)$

۲.۱ گام اول: تخصیص نقاط به خوشه‌ها

برای هر نقطه، فاصله اقلیدسی توان دوم را تا هر دو مرکز حساب می‌کنیم تا محاسبات ساده‌تر شود ($d^2(x, \mu) = (x_1 - \mu_1)^2 + (x_2 - \mu_2)^2$):

- **نقطه** x_1: $d^2(x_1, \mu_0) = (5.5 - 5.3)^2 + (3.1 - 3.5)^2 = 0.04 + 0.16 = 0.20$
  $d^2(x_1, \mu_1) = (5.5 - 5.1)^2 + (3.1 - 4.2)^2 = 0.16 + 1.21 = 1.37$ ← نزدیک‌تر به μ_0.

- **نقطه** x_2: $d^2(x_2, \mu_0) = (5.1-5.3)^2 + (4.8-3.5)^2 = 0.04 + 1.69 = 1.73$
  $\rightarrow$ نزدیک‌تر به μ_1: $d^2(x_2, \mu_1) = (5.1-5.1)^2 + (4.8-4.2)^2 = 0 + 0.36 = 0.36$.

- **نقطه** x_3: $d^2(x_3, \mu_0) = (6.6-5.3)^2 + (3.0-3.5)^2 = 1.69 + 0.25 = 1.94$
  $\rightarrow$ نزدیک‌تر به μ_0: $d^2(x_3, \mu_1) = (6.6-5.1)^2 + (3.0-4.2)^2 = 2.25 + 1.44 = 3.69$.

- **نقطه** x_4: $d^2(x_4, \mu_0) = (5.5-5.3)^2 + (4.6-3.5)^2 = 0.04 + 1.21 = 1.25$
  $\rightarrow$ نزدیک‌تر به μ_1: $d^2(x_4, \mu_1) = (5.5-5.1)^2 + (4.6-4.2)^2 = 0.16 + 0.16 = 0.32$.

- **نقطه** x_5: $d^2(x_5, \mu_0) = (6.8-5.3)^2 + (3.8-3.5)^2 = 2.25 + 0.09 = 2.34$
  $\rightarrow$ نزدیک‌تر به μ_0: $d^2(x_5, \mu_1) = (6.8-5.1)^2 + (3.8-4.2)^2 = 2.89 + 0.16 = 3.05$.

توزیع نهایی نقاط:

- خوشه ۰: $\{x_1, x_3, x_5\}$
- خوشه ۱: $\{x_2, x_4\}$

۳.۱ گام دوم: به‌روزرسانی مراکز خوشه‌ها

مرکز جدید هر خوشه، میانگین نقاط تخصیص یافته به آن است:

- **مرکز جدید خوشه ۰**: $\mu_0^{new} = \frac{x_1+x_3+x_5}{3} = \frac{(5.5+6.6+6.8),(3.1+3.0+3.8)}{3} = \frac{18.9,9.9}{3} = (6.3, 3.3)$
- **مرکز جدید خوشه ۱**: $\mu_1^{new} = \frac{x_2+x_4}{2} = \frac{(5.1+5.5),(4.8+4.6)}{2} = \frac{10.6,9.4}{2} = (5.3, 4.7)$

۴.۱ گزارش نهایی

طبق محاسبات انجام شده:

- مرکز جدید خوشه ۰: $(6.3, 3.3)$
- مرکز جدید خوشه ۱: $(5.3, 4.7)$
- تعداد نقاط (کاردینالیتی) خوشه ۰: ۳ نقطه.

استراتژی‌های پیوند در خوشه‌بندی سلسله‌مراتبی

در این سوال به بررسی دو روش Single Linkage و Complete Linkage و مقایسه ویژگی‌های آن‌ها می‌پردازیم.

۱.۲ مقایسه پیچیدگی محاسباتی

پیچیدگی محاسباتی هر دو روش Single Linkage و Complete Linkage در حالت کلی یکسان است. در یک پیاده‌سازی ساده (Naive) که در هر مرحله کل ماتریس فواصل برای یافتن کمترین مقدار جستجو می‌شود، پیچیدگی زمانی از مرتبه $O(N^3)$ است. با این حال، با بهره‌گیری از ساختمان داده‌های بهینه مانند صف اولویت (Heap)، این پیچیدگی برای هر دو روش به $O(N^2 \log N)$ کاهش می‌یابد.

شایان ذکر است که برای روش Single Linkage، الگوریتم‌های تخصصی‌تری (مانند SLINK) وجود دارند که می‌توانند محاسبات را در زمان $O(N^2)$ انجام دهند، اما به طور کلی در مراجع درسی، هر دو روش در یک دسته پیچیدگی مجانبی قرار می‌گیرند.

۲.۲ مقاومت در برابر داده‌های پرت (Outliers)

روش **Complete Linkage** در برابر داده‌های پرت بسیار مقاوم‌تر (Robust) است.

- **دلیل**: در روش Single Linkage، چون ملاک ادغام دو خوشه، «نزدیک‌ترین» نقاط آن‌ها به هم است، پدیده‌ای به نام **Effect Chaining** رخ می‌دهد. یعنی یک داده پرت می‌تواند مانند یک پل عمل کرده و دو خوشه کاملاً مجزا را به هم وصل کند.

- در مقابل، Complete Linkage چون به «دورترین» نقاط نگاه می‌کند، اجازه نمی‌دهد خوشه‌ها به راحتی و فقط به خاطر یک نقطه نزدیک به هم ادغام شوند و تمایل دارد خوشه‌های فشرده و کروی ایجاد کند.

۳.۲ خوشه‌بندی با روش Linkage Complete و رسم دندروگرام

مختصات نقاط استخراج شده از نمودار به شرح زیر است:

نقطه	مختصات	نقطه	مختصات	نقطه	مختصات
p_1	$(1,1)$	p_4	$(3,7)$	p_7	$(4,8)$
p_2	$(3,2)$	p_5	$(7,2)$	p_8	$(8,3)$
p_3	$(9,1)$	p_6	$(9,7)$	p_9	$(1,4)$

مراحل ادغام در روش Complete Linkage (بیشترین فاصله):

۱. **گام اول:** ادغام جفت‌های با کمترین فاصله ($\sqrt{2} \approx 1.41$):

- $d(p_4, p_7) = \sqrt{(4-3)^2 + (8-7)^2} = \sqrt{2}$
- $d(p_5, p_8) = \sqrt{(8-7)^2 + (3-2)^2} = \sqrt{2}$

۲. **گام دوم:** ادغام جفت‌های بعدی با فاصله $\sqrt{5} \approx 2.23$:

- $d(p_1, p_2) = \sqrt{(3-1)^2 + (2-1)^2} = \sqrt{5}$
- ادغام p_3 با خوشه $\{p_5, p_8\}$: $\max(d(p_3, p_5), d(p_3, p_8)) = \sqrt{5}$

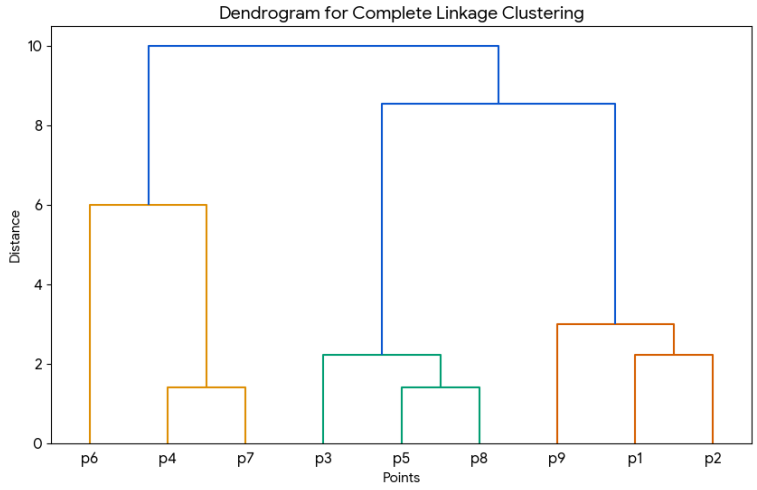
۳. **گام سوم:** الحاق p_9 به خوشه $\{p_1, p_2\}$. بیشترین فاصله:

$$\max(d(p_9, p_1), d(p_9, p_2)) = \max(3, \sqrt{8}) = 3$$

۴. **گام چهارم:** الحاق p_6 به خوشه $\{p_4, p_7\}$. بیشترین فاصله:

$$\max(d(p_6, p_4), d(p_6, p_7)) = \max(6, \sqrt{26}) = 6$$

۵. **گام پنجم:** ادغام دو خوشه $\{p_1, p_2, p_9\}$ و $\{p_3, p_5, p_8\}$ با فاصله تقریبی 8.54.



شکل ۱: دندروگرام حاصل از خوشه‌بندی Complete Linkage

۶. **گام نهایی:** ادغام تمامی نقاط با فاصله نهایی $d(p_1, p_6) = 10$.

کاهش ابعاد و هندسه داده‌ها

در این بخش، بر اساس ویژگی‌های هندسی و توزیع آماری داده‌ها، مناسب‌ترین روش کاهش ابعاد را انتخاب و تحلیل می‌کنیم.

۱. **داده‌های گوسی با همبستگی خطی (Linearly Correlated Gaussian Data):**

- **روش پیشنهادی:** PCA
- **توجیه:** از آنجایی که همبستگی داده‌ها خطی است، مولفه‌های اصلی دقیقا در راستای بردارهای ویژه ماتریس کوواریانس قرار دارند که بیشترین واریانس را پوشش می‌دهند. با توجه به توزیع گوسی، PCA به صورت بهینه اطلاعات (واریانس) را در ابعاد کمتر حفظ می‌کند و نیازی به پیچیدگی روش‌های غیرخطی نیست.

۲. **دو دایره متمرکز (Two Concentric Circles):**

- **روش پیشنهادی:** Kernel PCA

- **توجیه:** این داده‌ها به شدت غیرخطی هستند و در فضای اصلی توسط هیچ خط یا صفحه‌ای جدا نمی‌شوند. PCA کلاسیک در اینجا شکست می‌خورد. با استفاده از Kernel PCA و یک کرنل مناسب (مانند RBF)، داده‌ها به فضایی با ابعاد بالاتر نگاشت می‌شوند که در آنجا ساختار دایره‌ای باز شده و به صورت خطی قابل تفکیک یا فشرده‌سازی می‌گردد.

۳. **داده‌های با ابعاد بالا و هم‌پوشانی شدید کلاس‌ها (High-dimensional, Strong Class Overlap):**

- **روش پیشنهادی:** LDA
- **توجیه:** در این سناریو، هدف اصلی جدا کردن کلاس‌هاست. PCA ممکن است جهتی را انتخاب کند که واریانس کل در آن زیاد باشد اما کلاس‌ها را کاملاً روی هم بیندازد. اما تابع هدف LDA (معیار فیشر) صراحتاً به دنبال جهتی است که فاصله میانگین کلاس‌ها را حداکثر و واریانس درون هر کلاس را حداقل کند تا بیشترین تفکیک ایجاد شود.

۴. **داده‌های حاوی ویژگی‌های نویزی یا بی‌ربط (Irrelevant or Noisy Features):**

- **روش پیشنهادی:** PCA
- **توجیه:** در این سناریو فرض بر این است که «سیگنال» اصلی دارای واریانس بالاتری نسبت به «نویز» است. PCA با مرتب‌سازی مؤلفه‌ها بر اساس مقادیر ویژه، به ما اجازه می‌دهد تا با انتخاب k مؤلفه اول، نویزهای کم‌واریانس را حذف کنیم. در مقابل، LDA ممکن است به دلیل وجود ویژگی‌های نویزی که باعث ناپایداری یا تکین شدن ماتریس پراکندگی درون‌کلاسی می‌شوند، عملکرد ضعیفی داشته باشد.

تئوری فرمال LDA و PCA Kernel

۱.۴ اثبات تعداد جهت‌های متمایزساز در LDA

هدف در LDA حداکثر کردن معیار فیشر است که منجر به حل مسئله مقدار ویژه تعمیم‌یافته زیر می‌شود:

$$S_B w = \lambda S_W w$$

که در آن S_B ماتریس پراکندگی بین‌کلاسی (Between-class scatter matrix) است و به صورت زیر تعریف می‌شود:

$$S_B = \sum_{i=1}^{C} N_i (m_i - m)(m_i - m)^T$$

در اینجا m_i میانگین کلاس i و m میانگین کل داده‌هاست.

اثبات بر اساس رتبه ماتریس:

۱. ماتریس S_B مجموع C ماتریس با رتبه ۱ است (حاصل‌ضرب خارجی بردار در خودش).

۲. اما این C بردار $(m_i - m)$ از نظر خطی مستقل نیستند؛ زیرا مجموع وزن‌دار آن‌ها برابر صفر است: $\sum_{i=1}^{C} N_i (m_i - m) = 0$.

۳. بنابراین، حداکثر $C - 1$ بردار مستقل در ساخت S_B نقش دارند. طبق ویژگی رتبه در جبر خطی:

$$\text{rank}(S_B) \leq C - 1$$

۴. تعداد مقادیر ویژه غیرصفر یک ماتریس حداکثر برابر با رتبه آن ماتریس است. در نتیجه، LDA حداکثر می‌تواند $C - 1$ جهت متمایزساز (بردارهای ویژه متناظر با مقادیر ویژه غیرصفر) تولید کند.

۲.۴ تئوری PCA Kernel

در فضای ویژگی با نگاشت غیرخطی $\phi(x)$، اپراتور کوواریانس به صورت زیر است:

$$C = \frac{1}{N} \sum_{i=1}^{N} \phi(x_i) \phi(x_i)^T$$

۱. **چرا تجزیه مستقیم غیرممکن است؟** اگر ابعاد فضای ویژگی (بعد ϕ) بسیار بالا یا بی‌نهایت باشد (مانند کرنل RBF)، ابعاد ماتریس کوواریانس C به قدری بزرگ می‌شود که امکان ذخیره‌سازی و محاسبات مقدار ویژه روی آن وجود ندارد.

۲. **قضیه نمایش:** هر بردار ویژه v در فضای ویژگی باید در فضای پوش‌یافته توسط داده‌های آموزش باشد:

$$v = \sum_{i=1}^{N} \alpha_i \phi(x_i)$$

۳. **استخراج مسئله مقدار ویژه کرنل:** با جایگذاری در رابطه $Cv = \lambda v$ و ضرب داخلی در $\phi(x_k)^T$، به رابطه زیر می‌رسیم:

$$K^2\alpha = \lambda N K\alpha \implies K\alpha = \gamma\alpha$$

که در آن K ماتریس کرنل ($K_{ij} = \phi(x_i)^T\phi(x_j)$) و $\gamma = N\lambda$ است.

۴. **تصویر کردن نقطه جدید:** برای تصویر کردن یک نقطه تست x روی مولفه v:

$$y(x) = v^T\phi(x) = \sum_{i=1}^{N} \alpha_i \phi(x_i)^T\phi(x) = \sum_{i=1}^{N} \alpha_i K(x_i, x)$$

مشاهده می‌شود که این محاسبه تنها به تابع کرنل K نیاز دارد و نیازی به دانستن صریح نگاشت ϕ نیست.

محاسبات دستی تحلیل متمایزساز خطی (LDA)

ما قصد داریم الگوریتم LDA را روی دو کلاس داده شده اجرا کنیم:

- **کلاس ۱ (C_1):** $\{(4,2), (2,4), (2,3), (3,6), (4,4)\}$
- **کلاس ۲ (C_2):** $\{(9,10), (6,8), (9,5), (8,7), (10,8)\}$

۱.۵ گام اول: محاسبه میانگین‌ها

ابتدا بردار میانگین هر کلاس (μ_1, μ_2) و میانگین کل مجموعه داده (μ) را محاسبه می‌کنیم:

$$\mu_1 = \frac{1}{5}\sum_{x \in C_1} x = \frac{1}{5}(15, 19) = \begin{bmatrix} 3 \\ 3.8 \end{bmatrix}$$

$$\mu_2 = \frac{1}{5}\sum_{x \in C_2} x = \frac{1}{5}(42, 38) = \begin{bmatrix} 8.4 \\ 7.6 \end{bmatrix}$$

$$\mu = \frac{\mu_1 + \mu_2}{2} = \begin{bmatrix} 5.7 \\ 5.7 \end{bmatrix}$$

۲.۵ گام دوم: محاسبه ماتریس‌های پراکندگی (Scatter Matrices)

۱. **ماتریس پراکندگی درون‌کلاسی** (S_W): این ماتریس از مجموع ماتریس‌های کوواریانس هر کلاس $(S_W = S_1 + S_2)$ به دست می‌آید که در آن $S_i = \sum(x - \mu_i)(x - \mu_i)^T$:

برای کلاس ۱ با میانگین $\mu_1 = [3, 3.8]^T$:

$$S_1 = \begin{bmatrix} 1 & -1.8 \\ -1.8 & 3.24 \end{bmatrix} + \begin{bmatrix} 1 & -0.2 \\ -0.2 & 0.04 \end{bmatrix} + \cdots + \begin{bmatrix} 1 & 0.2 \\ 0.2 & 0.04 \end{bmatrix} = \begin{bmatrix} 4.0 & -1.0 \\ -1.0 & 8.8 \end{bmatrix}$$

برای کلاس ۲ با میانگین $\mu_2 = [8.4, 7.6]^T$:

$$S_2 = \begin{bmatrix} 0.36 & 1.44 \\ 1.44 & 5.76 \end{bmatrix} + \cdots + \begin{bmatrix} 2.56 & 0.64 \\ 0.64 & 0.16 \end{bmatrix} = \begin{bmatrix} 9.2 & -0.2 \\ -0.2 & 13.2 \end{bmatrix}$$

در نتیجه ماتریس S_W برابر است با:

$$S_W = \begin{bmatrix} 4.0 & -1.0 \\ -1.0 & 8.8 \end{bmatrix} + \begin{bmatrix} 9.2 & -0.2 \\ -0.2 & 13.2 \end{bmatrix} = \begin{bmatrix} 13.2 & -1.2 \\ -1.2 & 22.0 \end{bmatrix}$$

۲. **ماتریس پراکندگی بین‌کلاسی** (S_B): با توجه به اینکه دو کلاس داریم، S_B متناسب با

حاصل‌ضرب خارجی تفاضل میانگین‌هاست:

$$\mu_1 - \mu_2 = \begin{bmatrix} -5.4 \\ -3.8 \end{bmatrix} \implies S_B \propto (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T = \begin{bmatrix} 29.16 & 20.52 \\ 20.52 & 14.44 \end{bmatrix}$$

۳.۵ گام سوم: تعیین جهت متمایزساز بهینه (w)

هدف ما بیشینه کردن معیار فیشر $J(w) = \frac{w^T S_B w}{w^T S_W w}$ است که برای دو کلاس به رابطه $w \propto S_W^{-1}(\mu_1 - \mu_2)$ ساده می‌شود. ابتدا دترمینان و معکوس S_W را محاسبه می‌کنیم:

$$\det(S_W) = (13.2)(22.0) - (-1.2)(-1.2) = 290.4 - 1.44 = 288.96$$

$$S_W^{-1} = \frac{1}{288.96} \begin{bmatrix} 22.0 & 1.2 \\ 1.2 & 13.2 \end{bmatrix}$$

حساب کردن بردار w:

$$w \propto \begin{bmatrix} 22.0 & 1.2 \\ 1.2 & 13.2 \end{bmatrix} \begin{bmatrix} -5.4 \\ -3.8 \end{bmatrix} = \begin{bmatrix} -118.8 - 4.56 \\ -6.48 - 50.16 \end{bmatrix} = \begin{bmatrix} -123.36 \\ -56.64 \end{bmatrix}$$

با نرمال‌سازی این بردار به طول واحد ($\|w\| \approx 135.74$):

$$w \approx \begin{bmatrix} -0.91 \\ -0.42 \end{bmatrix}$$

۴.۵ گام چهارم: تصویر کردن نقاط (Projection)

با استفاده از رابطه $y = w^T x$، نقاط را به فضای یک‌بعدی انتقال می‌دهیم:

- **تصویر کلاس ۱:** $\{-4.48, -3.50, -3.08, -5.25, -5.32\}$ (بازه: $[-5.3, -3.0]$)
- **تصویر کلاس ۲:** $\{-12.39, -8.82, -10.29, -10.22, -12.46\}$ (بازه: $[-12.5, -8.8]$)

مشاهده می‌شود که دو کلاس در فضای جدید کاملاً از هم جدا شده‌اند.

تحلیل روش‌های انتخاب ویژگی (Feature Selection)

در این بخش به بررسی دقیق مکانیزم‌های انتخاب ویژگی و تحلیل رفتار الگوریتم‌های حریصانه می‌پردازیم.

۱.۶ عملکرد متدهای انتخاب متوالی (Sequential Selection)

این روش‌ها از نوع Wrapper هستند و به صورت زیر عمل می‌کنند

- **انتخاب رو به جلو (SFS):** با یک مجموعه تهی ($S = \emptyset$) شروع می‌شود. در هر تکرار، تمام ویژگی‌های باقی‌مانده ارزیابی شده و ویژگی f^* که بیشترین بهبود را در تابع هدف (J) ایجاد کند، به مجموعه اضافه می‌شود. این روند تا رسیدن به تعداد ویژگی مطلوب یا توقف بهبود عملکرد ادامه می‌یابد.
- **حذف رو به عقب (SBS):** دقیقاً برعکس SFS، با تمام ویژگی‌ها شروع کرده و در هر گام ویژگی‌ای که حذف آن کمترین آسیب را به مدل می‌زند (یا باعث بهبود می‌شود)، کنار گذاشته می‌شود.
- **انتخاب دوطرفه (Bidirectional):** این روش ترکیبی از هر دو حالت است. بعد از هر گام اضافه کردن ویژگی، یک بررسی رو به عقب انجام می‌دهد تا اگر ویژگی‌های قبلی در حضور عضو جدید بی‌استفاده شده‌اند، حذف شوند. این کار به اصلاح «اشتباهات اولیه» الگوریتم کمک می‌کند.

۲.۶ تحلیل رفتار حریصانه (Greedy Behavior)

این الگوریتم‌ها حریصانه هستند چون در هر مرحله فقط بهترین گزینه «موضعی» را می‌بینند و به کل فضای حالت (2^d) نگاه نمی‌کنند.

پیامد رفتار حریصانه و مثال نقض: این روش‌ها تضمینی برای یافتن بهینه سراسری ندارند. *مثال کلاسیک XOR:* فرض کنید خروجی $y = x_1 \oplus x_2$ باشد. به تنهایی نه x_1 و نه x_2 هیچ

همبستگی با y ندارند (دقت ٪۵۰). اگر ویژگی نویزی x_3 همبستگی ٪۵۵ داشته باشد، الگوریتم SFS ابتدا x_3 را انتخاب می‌کند و ممکن است هیچ‌گاه ترکیب طلایی $\{x_1, x_2\}$ را که دقت ٪۱۰۰ می‌دهد پیدا نکند.

۳.۶ مقایسه با روش‌های جایگزین

۱. **حذف ویژگی بازگشتی (RFE):** برخلاف SBS که برای هر حذف باید مدل را بارها بازآموزی کند، RFE یک بار مدل را آموزش داده و ویژگی‌ها را بر اساس وزن (Weights) یا اهمیت رتبه‌بندی و حذف می‌کند. این روش سریع‌تر از SBS است اما همچنان حریصانه عمل می‌کند.

۲. **رگولاریزاسیون L1 (Lasso):** یک روش درونی (Embedded) است که با اضافه کردن جریمه به تابع هزینه، ضرایب ویژگی‌های بی‌آثار را صفر می‌کند.

- **پیچیدگی:** بسیار سریع‌تر از متدهای Wrapper است چون انتخاب ویژگی همزمان با آموزش انجام می‌شود.
- **تعاملات:** Lasso در انتخاب بین ویژگی‌های همبسته (Correlated) به صورت تصادفی عمل می‌کند، در حالی که روش‌های متوالی ممکن است هر دو را نگه دارند.

تحلیل عملی کاهش ابعاد روی مجموعه داده‌های Iris و Circles

۱.۷ بخش اول: تحلیل PCA روی مجموعه داده Iris

در این بخش، مجموعه داده Iris پس از استانداردسازی، توسط الگوریتم PCA از ۴ بعد به ۲ بعد کاهش یافت.

۱. **نتایج واریانس توضیح داده شده:** طبق خروجی کد، نسبت واریانس برای مولفه‌های اصلی به شرح زیر است:

- مولفه اصلی اول (PC1): 73%
- مولفه اصلی دوم (PC2): 23%
- مجموع واریانس حفظ شده: 96%

این نتایج نشان می‌دهد که با تنها ۲ مولفه، تقریباً تمام اطلاعات کلیدی دیتاست حفظ شده است. PC1 به تنهایی بخش اعظمی از پراکندگی را جذب کرده که نشان‌دهنده همبستگی بالای ویژگی‌های اصلی گلبرگ است.

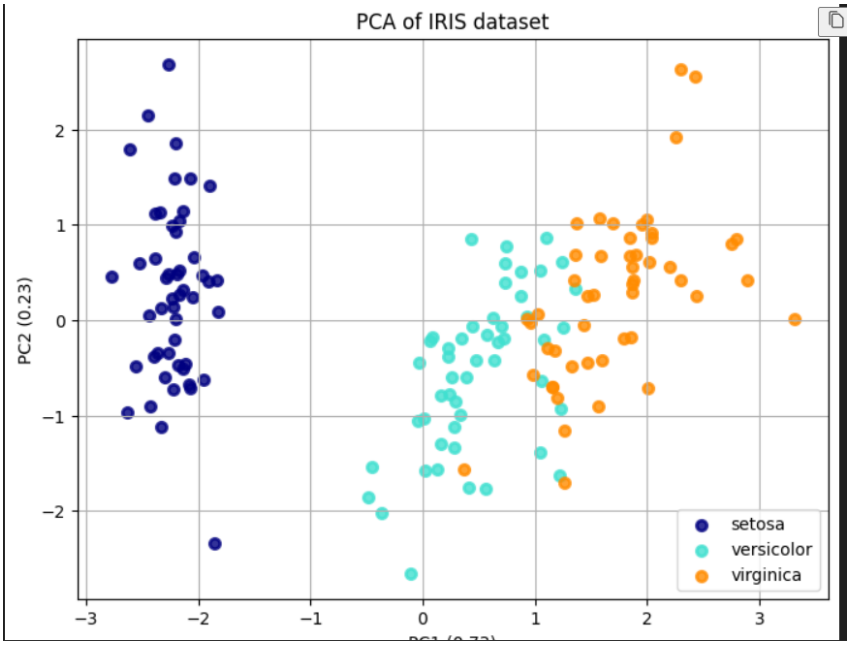
۲. **تحلیل بصری و جداپذیری کلاس‌ها:** با توجه به نمودار خروجی (شکل ۲)، مشاهده می‌شود که کلاس *Setosa* به طور کامل از سایر کلاس‌ها تفکیک شده است. با این حال، کلاس‌های *Versicolor* و *Virginica* دارای هم‌پوشانی جزئی هستند. از آنجا که هدف PCA بیشینه‌سازی واریانس کل است و از برچسب کلاس‌ها استفاده نمی‌کند، این هم‌پوشانی طبیعی است. اگر هدف صرفاً طبقه‌بندی بود، استفاده از LDA می‌توانست مرزهای دقیق‌تری ایجاد کند.

۲.۷ بخش دوم: مقایسه PCA و PCA Kernel روی داده‌های غیرخطی

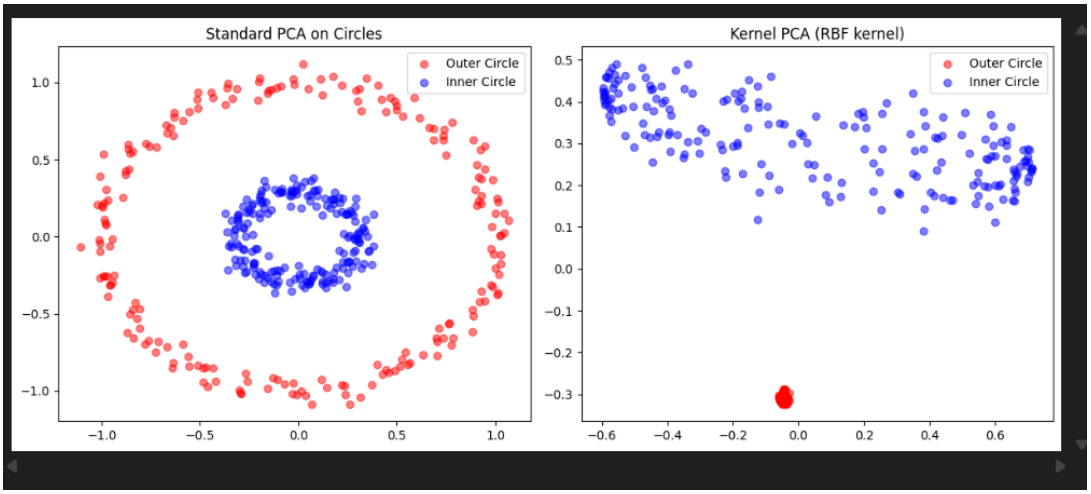
در این آزمایش، از دیتاست make_circles برای بررسی محدودیت‌های روش‌های خطی استفاده شد.

۱. **تحلیل نتایج:**

- **Standard PCA:** همان‌طور که در نمودار مشاهده می‌شود، این متد در جداسازی دایره‌های متداخل کاملاً ناتوان است. دلیل این امر، منطبق بودن مرکز ثقل دو کلاس و ماهیت غیرخطی توزیع داده‌هاست که با هیچ تبدیل خطی (چرخش یا انتقال) جدا نمی‌شوند.
- **Kernel PCA (با کرنل RBF):** این متد با موفقیت دو کلاس را از هم جدا کرده است. با استفاده از نگاشت غیرخطی به فضای ویژگی (Feature Space)، ساختار دایره‌ای داده‌ها باز شده و در فضای جدید به صورت خوشه‌های مجزا نمایش داده می‌شوند.



شکل ۲: کاهش ابعاد دیتاست Iris با استفاده از PCA



شکل ۳: مقایسه عملکرد PCA خطی و Kernel PCA روی داده‌های دایره‌ای

تحلیل جامع انتخاب ویژگی و کاهش ابعاد بر روی داده‌های بیماری قلبی

در این بخش، با استفاده از رویکردهای مختلف فیلتر (Filter)، (Wrapper) و (Embedded)، به شناسایی مهم‌ترین عوامل بیولوژیکی موثر بر بیماری قلبی می‌پردازیم.

۱.۸ تحلیل اکتشافی و بررسی همبستگی خطی

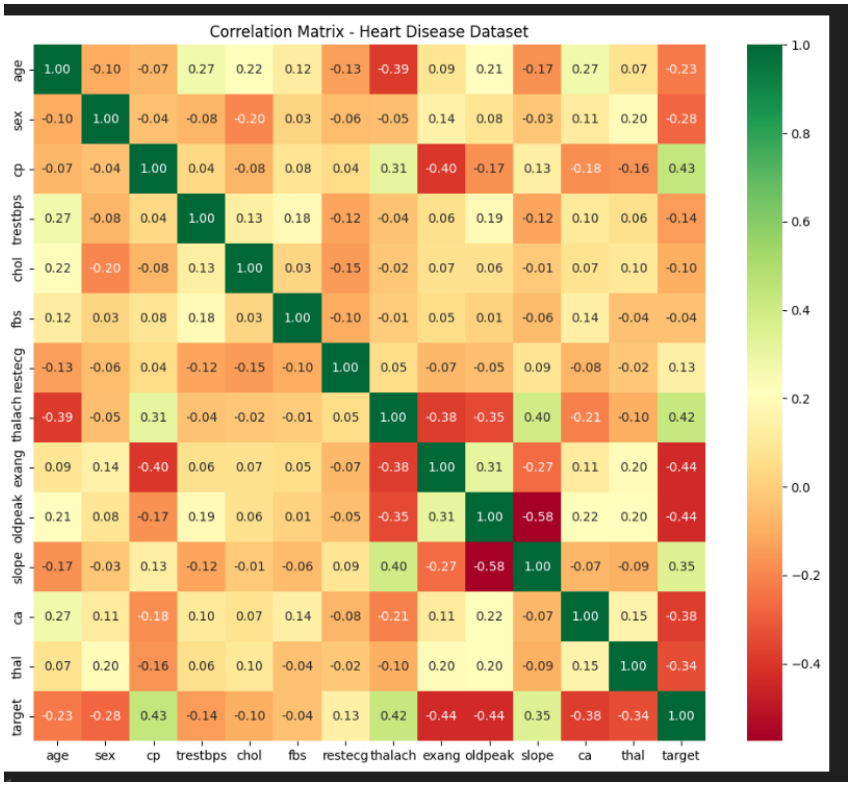
در اولین گام، ماتریس همبستگی ویژگی‌ها محاسبه گردید (شکل ۴). هدف از این کار، شناسایی ویژگی‌های تکراری بود که اطلاعات مشابهی را به مدل تزریق می‌کنند.

- **تحلیل مشاهدات:** بیشترین همبستگی مثبت با متغیر هدف مربوط به نوع درد قفسه سینه (cp) با ضریب 0.43 است. در مقابل، ویژگی‌های thalach (حداکثر ضربان قلب) و oldpeak همبستگی منفی شدیدی با وجود بیماری نشان می‌دهند.
- **نتیجه‌گیری:** از آنجا که هیچ جفت‌ویژگی همبستگی بالاتر از 0.85 نداشت، تمام ۱۳ ویژگی برای مراحل بعدی حفظ شدند؛ زیرا هر کدام جنبه متفاوتی از وضعیت سلامت بیمار را توصیف می‌کنند.

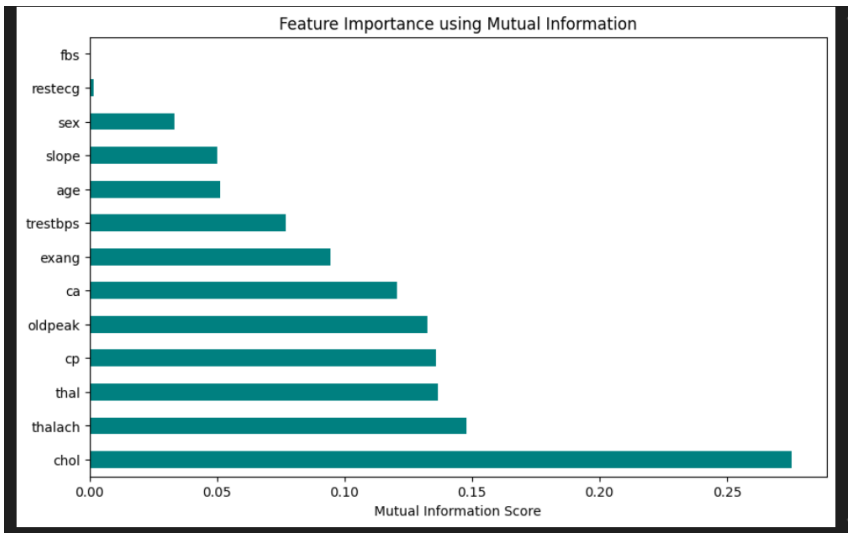
۲.۸ رتبه‌بندی ویژگی‌ها بر اساس اطلاعات متقابل (Mutual Information)

برخلاف همبستگی پیرسون که فقط روابط خطی را می‌سنجد، Mutual Information وابستگی‌های غیرخطی را نیز استخراج می‌کند (شکل ۵).

- **تحلیل نمودار:** در این تحلیل، ویژگی chol (کلسترول) در رده‌های بالا قرار گرفت، در حالی که در تحلیل خطی نقش کم‌رنگ‌تری داشت. این نشان‌دهنده وجود رابطه پیچیده و غیرخطی بین سطح کلسترول و خطر ابتلا به بیماری است.
- ویژگی‌های thalach و thal نیز به عنوان شاخص‌های کلیدی در این متد تایید شدند.



شکل ۴: ماتریس همبستگی ویژگی‌های دیتاست بیماری قلبی



شکل ۵: رتبه‌بندی اهمیت ویژگی‌ها با استفاده از Mutual Information

۳.۸ انتخاب ویژگی بازگشتی با اعتبارسنجی متقاطع (RFECV)

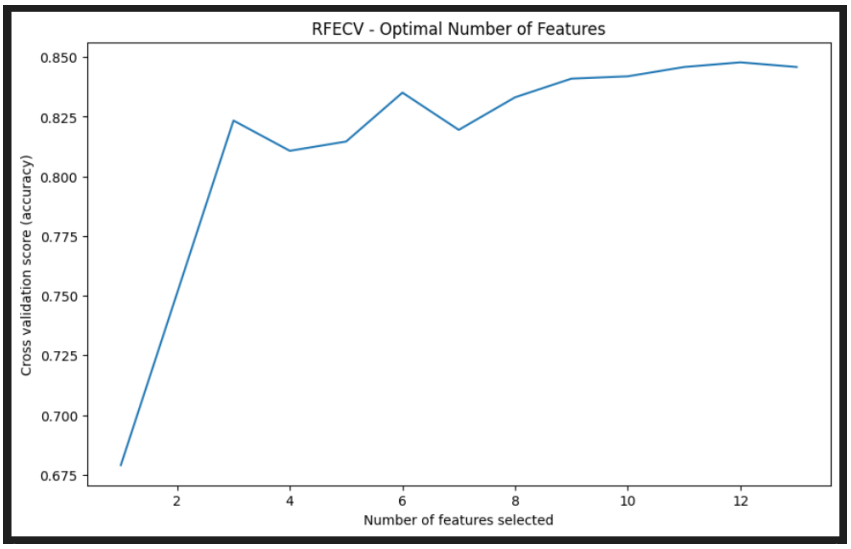
برای یافتن زیرمجموعه بهینه از ویژگی‌ها که بیشترین دقت مدل را تضمین کند، از روش RFECV استفاده شد (شکل ۶).

- **تحلیل نمودار عملکرد:** همان‌طور که در نمودار مشخص است، دقت مدل با اضافه کردن ویژگی‌ها تا عدد ۱۲ افزایش یافته و سپس به ثبات می‌رسد. این موضوع تایید می‌کند که داده‌های بیماری قلبی دارای ابعاد ذاتی بالایی هستند و حذف گسترده ویژگی‌ها منجر به از دست رفتن سیگنال‌های حیاتی می‌شود.
- ۵ ویژگی برتر منتخب این روش شامل sex، cp، thalach، oldpeak و ca می‌باشند که با یافته‌های پزشکی همخوانی بالایی دارند.

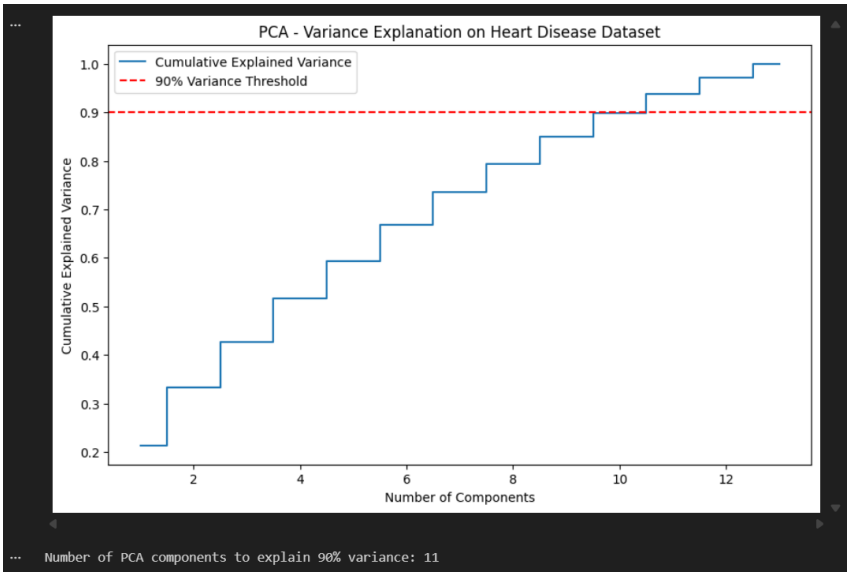
۴.۸ کاهش ابعاد با PCA و مقایسه با روش‌های انتخاب ویژگی

در نهایت، با استفاده از PCA، فضای ویژگی به مولفه‌های اصلی انتقال یافت (شکل ۷).

- **تحلیل واریانس:** نمودار واریانس تراکمی نشان می‌دهد که برای حفظ ٪۹۰ از اطلاعات کل، به ۱۱ مولفه نیاز داریم.
- **تفسیر نهایی:** اگرچه PCA واریانس را به خوبی حفظ می‌کند، اما برخلاف Lasso و RFE، ماهیت فیزیکی ویژگی‌ها را از بین می‌برد. در کاربردهای پزشکی، روش‌های انتخاب ویژگی (Feature Selection) به دلیل حفظ قابلیت تفسیر (Interpretability) برای متخصصین، بر روش‌های استخراج ویژگی (Feature Extraction) ارجحیت دارند.



شکل ۶: نمودار تغییرات دقت مدل بر اساس تعداد ویژگی‌های منتخب (RFECV)



شکل ۷: نمودار واریانس تراکمی مولفه‌های اصلی (PCA)

قطعه‌بندی تصویر با استفاده از ویژگی‌های ۵ـبعدی: مقایسه K-Means و GMM

در این بخش، هدف سگمنتیشن تصاویر با استفاده از اطلاعات همزمان رنگ و مکان است. برای هر پیکسل، یک بردار ویژگی ۵ـبعدی به صورت $x = [R, G, B, r, c]$ تشکیل شد که در آن $[R, G, B]$ اطلاعات رنگی و $[r, c]$ مختصات نرمال‌شده پیکسل هستند. تمامی ویژگی‌ها برای جلوگیری از سوگیری الگوریتم، به بازه $[0, 1]$ مقیاس شدند.

۱.۹ تحلیل عملکرد الگوریتم K-Means

طبق خروجی‌های به‌دست آمده در شکل‌های ۸ و ۹ (ردیف اول)، الگوریتم K-Means تمایل دارد تصویر را به بخش‌های هندسی و بلوکی تقسیم کند.

- **مشاهده:** در تصویر هواپیما و عقاب، با افزایش K، آسمان به جای یکپارچه ماندن، به قطعات عمودی یا افقی تقسیم شده است.
- **علت فنی:** این پدیده به دلیل استفاده از فاصله اقلیدسی و فرض کروی بودن خوشه‌هاست. از آنجا که فاصله مکانی پیکسل‌های دور در آسمان زیاد است، K-Means آن‌ها را در خوشه‌های مجزا قرار می‌دهد، حتی اگر رنگ کاملاً یکسانی داشته باشند. در واقع این الگوریتم اولویت را به نزدیکی مکانی (Spatial Proximity) می‌دهد.

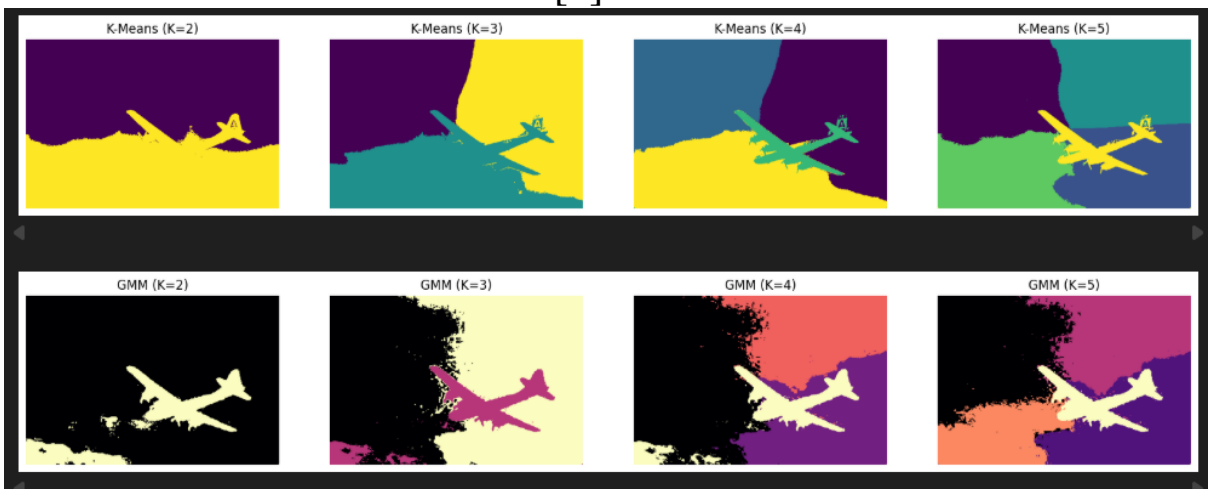
۲.۹ تحلیل عملکرد مدل مخلوط گوسی (GMM)

در ردیف دوم تصاویر، عملکرد GMM که با الگوریتم EM آموزش دیده، به وضوح برتر است.

- **مشاهده:** GMM موفق شده است سوژه‌های اصلی (هواپیما و عقاب) را به طور کامل از پس‌زمینه جدا کند. برخلاف متد قبلی، پس‌زمینه (آسمان) علیرغم وسعت مکانی، به صورت یکپارچه شناسایی شده است.

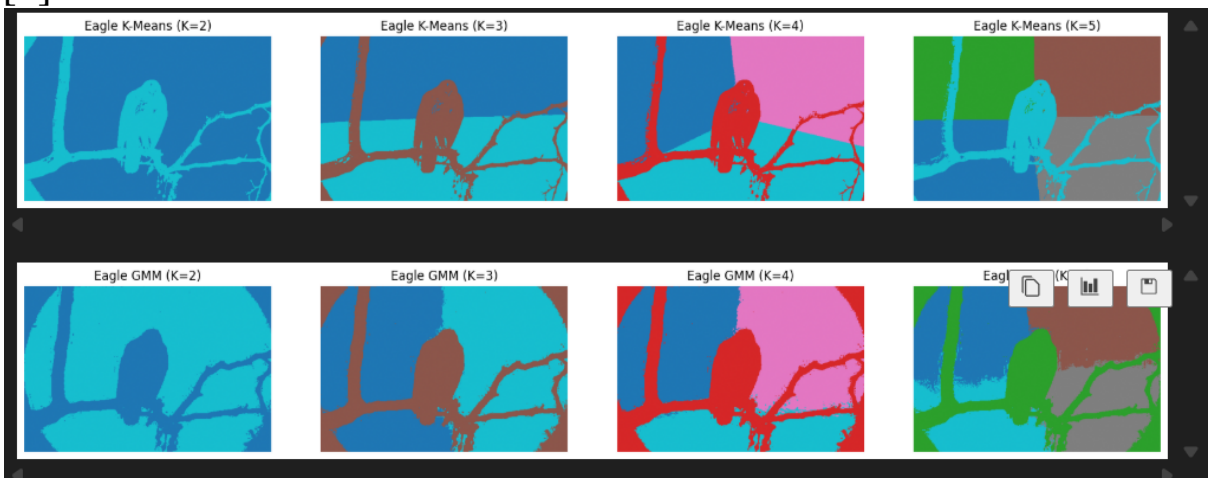
- **علت فنی:** GMM از ماتریس کوواریانس کامل استفاده می‌کند که اجازه می‌دهد خوشه‌ها به صورت بیضوی مدل‌سازی شوند. این مدل یاد می‌گیرد که برخی خوشه‌ها (مانند پس‌زمینه) می‌توانند در ابعاد مکانی واریانس بسیار بالا و در ابعاد رنگی واریانس بسیار پایینی داشته باشند. این انعطاف‌پذیری باعث می‌شود سگمنتیشن با ادراک معنایی (Se-mantic Perception) انسان مطابقت بیشتری داشته باشد.

[b]۰.۹



شکل ۸: نتایج سگمنتیشن تصویر هواپیما (ردیف اول: K-Means، ردیف دوم: GMM)

[b]۰.۹



شکل ۹: نتایج سگمنتیشن تصویر عقاب (ردیف اول: K-Means، ردیف دوم: GMM)

شکل ۱۰: مقایسه الگوریتم‌های خوشه‌بندی برای مقادیر $K \in \{2, 3, 4, 5\}$

منابع و مراجع

۱. Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

۲. Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

۳. Lecture Notes & Homework Statement, Machine Learning Basics Course, University of Tehran, Fall 2025.

۴. Scikit-learn Documentation: *Dimensionality Reduction and Feature Selection modules*.