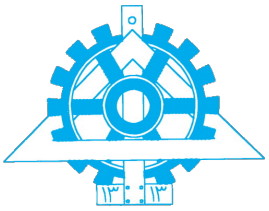


دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۵

نام و نام خانوادگی

محمدمهدی یاری

شماره دانشجویی

۸۱۰۱۰۲۵۳۲

۱۵ بهمن ۱۴۰۴

فهرست مطالب

چکیده ۱

۱ تخمین بیشینه‌احتمال Maximum Likelihood Estimation ۲

۲ رگرسیون لجستیک با یک ویژگی Logistic Regression with One Feature ۳

۳ رگرسیون خطی با منظم‌ساز L2 و روش نیوتن ۵

۴ رگرسیون چندجمله‌ای و منظم‌سازی ریج Ridge Regularization ۶

۵ الگوریتم پرسپترون و تبدیل‌های غیرخطی Perceptron ۹

۶ نمایش توابع توسط گراف‌های محاسباتی Neural Network Representations ۱۱

۷ رابطه بیشینه‌احتمال MLE و انتروپی متقاطع Cross-Entropy ۱۳

۸ پایداری استوک استیک و پدیده Dead ReLU ۱۵

۹ حفظ واریانس و مقداردهی اولیه زویر Xavier Initialization ۱۷

۱۰ یادگیری انتقالی با استفاده از شبکه‌های پیش‌آموزش‌دیده ۱۹

۱.۱۰ روش تحقیق و معماری مدل‌ها ۱۹

۲.۱۰ نتایج عددی و نمودارها ۱۹

۳.۱۰ بحث و تحلیل (Discussion) ۱۹

منابع و مراجع ۲۱

فهرست تصاویر

۱ برازش چندجمله‌ای با درجات ۱، ۳ و ۹ بر روی مجموعه داده A ۸

۲ تغییرات MSE آموزش و اعتبارسنجی بر حسب درجه چندجمله‌ای d ۸

۳ اثر پارامتر منظم‌سازی λ بر خطای مدل با درجه ثابت ۱۲ . . . . . ۹

۴ مقایسه عملکرد سه مدل در ۱۰ اپوک: سمت راست دقت اعتبارسنجی و سمت چپ تابع زیان آموزش. ۲۰

فهرست جداول

چکیده

در این گزارش، مجموعه‌ای از مفاهیم بنیادین و پیشرفته در یادگیری ماشین، شامل روش‌های تخمین پارامتر، رگرسیون، شبکه‌های عصبی و یادگیری انتقالی مورد بررسی قرار گرفته است. ابتدا با تحلیل ریاضی تخمین بیشینه‌احتمال (MLE) و بهینه‌سازی رگرسیون لجستیک و خطی آغاز کرده و نشان دادیم که چگونه روش‌های مرتبه دوم مانند نیوتن می‌توانند همگرایی را تسریع کنند. در بخش عملی، موازنه بایاس–واریانس و پدیده بیش‌برازش در رگرسیون چندجمله‌ای تحلیل شد. سپس با ورود به حوزه شبکه‌های عصبی، پایداری استوکاستیک نورون‌ها، پدیده «ReLU مرده» و اهمیت مقداردهی اولیه وزن‌ها (مانند روش زویر) جهت حفظ واریانس سیگنال در لایه‌های عمیق اثبات گردید. در نهایت، با پیاده‌سازی عملی بر روی مجموعه داده CIFAR-10، برتری شبکه‌های کانولوشنی پیش‌آموزش‌دیده (VGG-11) نسبت به مدل‌های تمام‌متصل (MLP) از منظر قدرت تعمیم‌دهی و سوگیری استقرایی (Inductive Bias) به تصویر کشیده شد.

تخمین بیشینه‌احتمال Maximum Likelihood Estimation

در این مسئله قصد داریم پارامتر θ را برای توزیع داده شده بر اساس n نمونه مستقل و یکسان i.i.d. پیدا کنیم. تابع توزیع احتمال به صورت زیر تعریف شده است:

$$P(x|\theta) = \theta x^{-\theta-1}, \quad \theta > 1, x \geq 1$$

الف) تشکیل تابع درست‌نمایی (Likelihood)

تابع درست‌نمایی $L(\theta)$ برابر است با حاصل‌ضرب احتمال تمامی نمونه‌ها:

$$L(\theta) = \prod_{i=1}^{n} P(x_i|\theta) = \prod_{i=1}^{n} \theta x_i^{-\theta-1}$$

ب) تابع Log-Likelihood

برای سادگی در محاسبات و تبدیل حاصل‌ضرب به مجموع، از لگاریتم طبیعی تابع درست‌نمایی استفاده می‌کنیم:

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^{n} \ln\left(\theta x_i^{-\theta-1}\right)$$

با استفاده از قوانین لگاریتم، عبارت فوق را باز می‌کنیم:

$$\ell(\theta) = \sum_{i=1}^{n} \left[\ln\theta + (-\theta-1)\ln x_i\right]$$

$$\ell(\theta) = n\ln\theta - (\theta+1)\sum_{i=1}^{n} \ln x_i$$

ج) یافتن تخمین‌گر بیشینه‌احتمال (MLE)

برای یافتن مقداری از θ که تابع فوق را بیشینه کند، از آن نسبت به θ مشتق گرفته و برابر صفر قرار می‌دهیم:

$$\frac{\partial \ell(\theta)}{\partial \theta} = \frac{n}{\theta} - \sum_{i=1}^{n} \ln x_i = 0$$

با حل معادله فوق برای θ، تخمین‌گر به صورت زیر به دست می‌آید:

$$\frac{n}{\theta} = \sum_{i=1}^{n} \ln x_i \implies \hat{\theta}_{\text{MLE}} = \frac{n}{\sum_{i=1}^{n} \ln x_i}$$

رگرسیون لجستیک با یک ویژگی Logistic Regression with One Feature

در این مسئله قصد داریم رابطه به‌روزرسانی پارامتر α را با استفاده از الگوریتم بهینه‌سازی Stochastic Gradient Descent (SGD) به دست آوریم. مدل احتمالاتی ما به صورت زیر تعریف شده است:

$$P(y = 1|z) = s(z - \alpha), \quad s(\gamma) = \frac{1}{1 + e^{-\gamma}}$$

تابع زیان برای یک نمونه داده با برچسب $y \in \{0, 1\}$ به صورت زیر است:

$$J(\alpha) = -y \ln s(x - \alpha) - (1 - y) \ln(1 - s(x - \alpha))$$

الف) محاسبه گرادیان نسبت به پارامتر α

برای پیدا کردن رابطه به‌روزرسانی، ابتدا باید مشتق تابع زیان را نسبت به α محاسبه کنیم. با استفاده از قاعده زنجیره‌ای (Chain Rule) داریم:

۱. مشتق تابع زیان نسبت به خروجی مدل (s):

$$\frac{\partial J}{\partial s} = -\frac{y}{s} + \frac{1-y}{1-s} = \frac{s-y}{s(1-s)}$$

۲. مشتق تابع سیگموئید نسبت به آرگومان آن ($u = x - \alpha$):

$$\frac{\partial s(u)}{\partial u} = s(u)(1 - s(u))$$

۳. مشتق آرگومان نسبت به پارامتر α:

$$\frac{\partial (x-\alpha)}{\partial \alpha} = -1$$

با ضرب این سه عبارت در یکدیگر، گرادیان نهایی به دست می‌آید:

$$\frac{\partial J}{\partial \alpha} = \left(\frac{s-y}{s(1-s)}\right) \cdot (s(1-s)) \cdot (-1) = y - s$$

ب) رابطه به‌روزرسانی در SGD

با در نظر گرفتن گام حرکت (Step Size) با مقدار $\epsilon > 0$، قانون به‌روزرسانی پارامتر به صورت زیر خواهد بود:

$$\alpha_{new} = \alpha_{old} - \epsilon \frac{\partial J}{\partial \alpha}$$

$$\alpha_{new} = \alpha_{old} - \epsilon(y - s(x - \alpha_{old}))$$

رگرسیون خطی با منظم‌ساز L2 و روش نیوتن

در این مسئله قصد داریم نشان دهیم که برای تابع زیان رگرسیون خطی منظم‌شده ، روش نیوتن تنها در یک گام به جواب بهینه (w^*) همگرا می‌شود. تابع زیان به صورت زیر تعریف شده است:

$$J(w) = \|Xw - y\|_2^2 + \lambda \|w\|_2^2$$

که می‌توان آن را به فرم ماتریسی زیر نوشت:

$$J(w) = (Xw - y)^\top (Xw - y) + \lambda w^\top w$$

الف) محاسبه گرادیان و ماتریس هسین

ابتدا مشتق اول (گرادیان) را نسبت به w محاسبه می‌کنیم:

$$\nabla J(w) = 2X^\top (Xw - y) + 2\lambda w = 2[(X^\top X + \lambda I)w - X^\top y]$$

سپس با مشتق‌گیری مجدد، ماتریس هسین (H) که شامل مشتقات مرتبه دوم است را به دست می‌آوریم:

$$H = \frac{\partial^2 J(w)}{\partial w \partial w^\top} = 2(X^\top X + \lambda I)$$

مشاهده می‌شود که ماتریس هسین ثابت بوده و به w وابسته نیست.

ب) اعمال گام نیوتن

فرمول به‌روزرسانی نیوتن برای شروع از یک نقطه دلخواه w_0 به صورت زیر است:

$$w_1 = w_0 - H^{-1} \nabla J(w_0)$$

با جایگذاری مقادیر به دست آمده در مرحله قبل داریم:

$$w_1 = w_0 - \left[2(X^\top X + \lambda I)\right]^{-1} \cdot \left[2(X^\top X + \lambda I)w_0 - 2X^\top y\right]$$

$$w_1 = w_0 - (X^\top X + \lambda I)^{-1}(X^\top X + \lambda I)w_0 + (X^\top X + \lambda I)^{-1} X^\top y$$

$$w_1 = w_0 - Iw_0 + (X^\top X + \lambda I)^{-1} X^\top y$$

در نهایت:

$$w_1 = (X^\top X + \lambda I)^{-1} X^\top y = w^*$$

بنابراین ثابت شد که پس از یک گام، w_1 دقیقاً برابر با جواب بهینه w^* است.

رگرسیون چندجمله‌ای و منظم‌سازی ریج Ridge Regularization

در این بخش به بررسی عملی مفاهیم پایه در رگرسیون، از جمله پیچیدگی مدل، پدیده بیش‌برازش (Overfitting) و روش‌های کنترل آن از طریق منظم‌سازی (Regularization) می‌پردازیم. هدف این آزمایش، درک تجربی موازنه میان بایاس و واریانس (Bias-Variance Tradeoff) با استفاده از داده‌های چندجمله‌ای است.

الف) پیاده‌سازی و برازش بر روی data_A

در گام نخست، برای مدل‌سازی روابط غیرخطی، ورودی‌های تک‌بعدی x را با استفاده از ماتریس طراحی (Design Matrix) به فضای ویژگی‌های چندجمله‌ای با درجات $d \in \{1, 3, 9\}$ نگاشت دادیم. بردار ویژگی برای هر نمونه به صورت $\phi(x) = [1, x, x^2, \ldots, x^d]^\top$ تعریف می‌شود. برای یافتن پارامترهای بهینه مدل (θ)، از معادله نرمال استفاده شده است:

$$\theta = (X^\top X)^{-1} X^\top y$$

تحلیل نتایج:

- **درجه ۱ (خط آبی):** مدل به دلیل ظرفیت پایین، قادر به یادگیری انحنای موجود در داده‌ها نیست و دچار کم‌برازش (Underfitting) شده است.
- **درجه ۳ (خط نارنجی):** مدل تا حدودی رفتار داده را توصیف می‌کند اما همچنان بسیاری از جزییات روند را نادیده می‌گیرد.

- **درجه ۹ (خط سبز):** مدل با ظرفیت بالا، به خوبی بر روی داده‌ها منطبق شده است. هرچند در این داده خاص به نظر می‌رسد مدل به خوبی برازش شده، اما افزایش درجه بدون کنترل می‌تواند منجر به حساسیت شدید نسبت به نویز شود.

ب) تحلیل خطا و پیچیدگی مدل بر روی data_B

برای بررسی دقیق‌تر اثر درجه چندجمله‌ای، مدل را با درجات ۱ تا ۱۲ بر روی داده‌های آموزش data_B_train فیت کرده و خطای میانگین مربعات (MSE) را برای هر دو مجموعه آموزش و اعتبارسنجی (Validation) محاسبه کردیم.

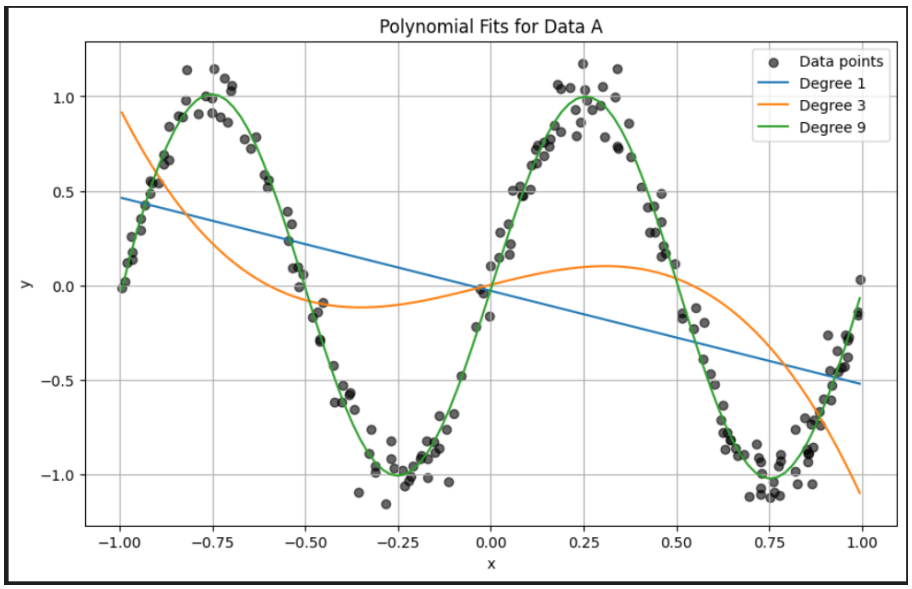
تحلیل موازنه بایاس ـ واریانس: طبق نمودار فوق، با افزایش d، خطای آموزش به طور پیوسته کاهش می‌یابد. اما خطای اعتبارسنجی تا درجه ۹ روند کاهشی داشته و پس از آن به شدت صعودی می‌شود. این نقطه (درجه ۹) نشان‌دهنده بهینه‌ترین پیچیدگی مدل است. افزایش خطا در درجات ۱۰ به بالا، نشان‌دهنده واریانس بالای مدل و پدیده بیش‌برازش است که در آن مدل به جای یادگیری الگوی کلی، نویزهای مجموعه آموزش را حفظ کرده است.

ج) کنترل بیش‌برازش با استفاده از منظم‌سازی ریج

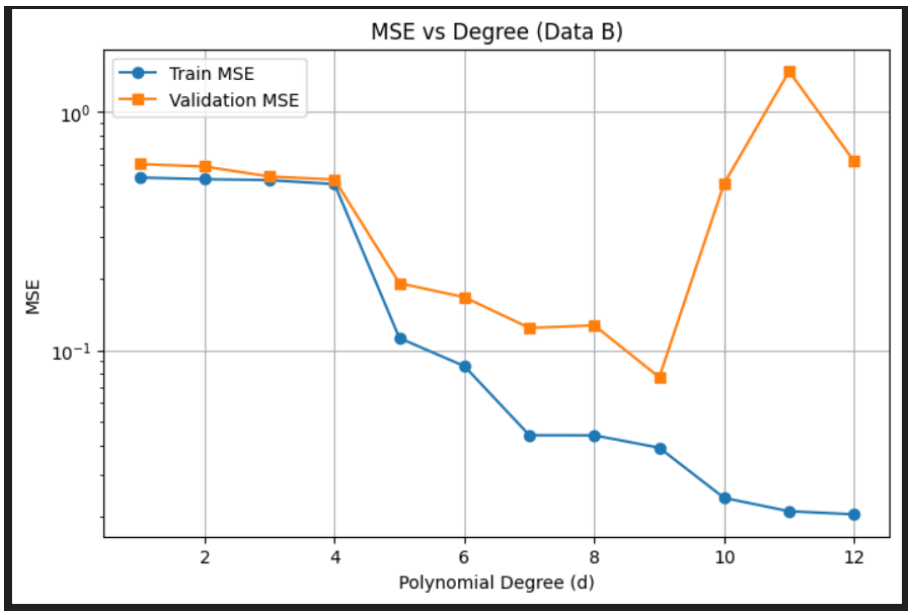
در مرحله نهایی، اثر پارامتر منظم‌سازی λ را بر روی مدلی با درجه ثابت ۱۲ (که پیش‌تر دچار بیش‌برازش شده بود) بررسی کردیم. در این حالت پارامترها با حل معادله زیر به دست می‌آیند:

$$\theta_\lambda = (X^\top X + \lambda I)^{-1} X^\top y$$

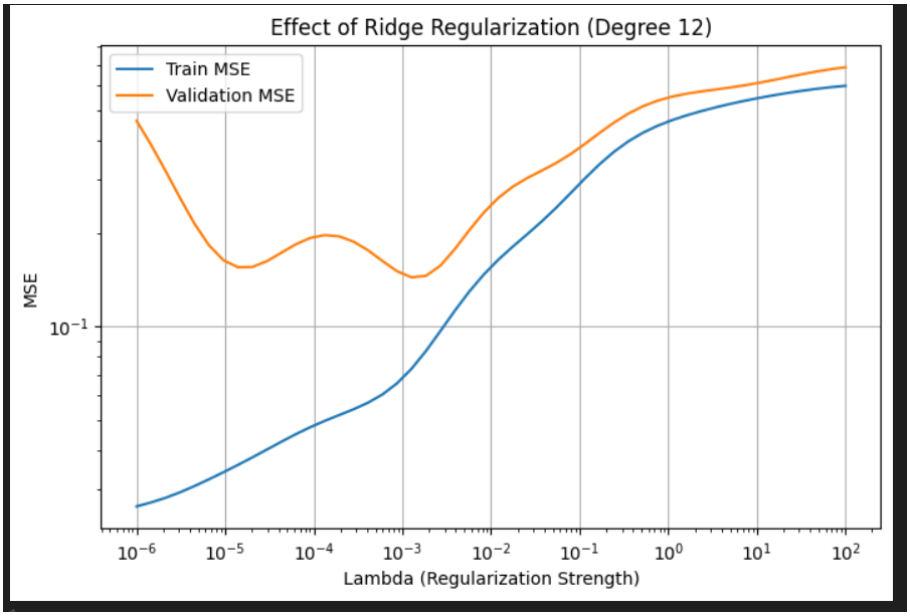
تحلیل نهایی: استفاده از منظم‌سازی (Regularization) به ما اجازه می‌دهد حتی با داشتن مدلی با ظرفیت بالا ($d = 12$)، از بیش‌برازش جلوگیری کنیم. با انتخاب یک λ بهینه (در بازه میانی نمودار)، خطای اعتبارسنجی به حداقل می‌رسد. این پارامتر با جریمه کردن مقادیر بزرگ در بردار وزن θ، از نوسانات شدید تابع برازش شده جلوگیری کرده و قدرت تعمیم‌دهی (Generalization) مدل را افزایش می‌دهد.



شکل ۱: برازش چندجمله‌ای با درجات ۱، ۳ و ۹ بر روی مجموعه داده A



شکل ۲: تغییرات MSE آموزش و اعتبارسنجی بر حسب درجه چندجمله‌ای d



شکل ۳: اثر پارامتر منظم‌سازی λ بر خطای مدل با درجه ثابت ۱۲

الگوریتم پرسپترون و تبدیل‌های غیرخطی Perceptron

در این مسئله شش نقطه در دو کلاس مثبت و منفی داریم. کلاس منفی شامل نقاط $[1,0]$، $[-1,0]$ و $[0,1]$ و کلاس مثبت شامل نقاط $[2,0]$، $[-2,0]$ و $[0,2]$ می‌باشد.

۱) به‌روزرسانی وزن

با فرض وزن اولیه $w=[0,5]$ و پردازش نقطه $x=[0,1]$ از کلاس منفی $(y=-1)$:

$$w \cdot x = (0 \times 0) + (5 \times 1) = 5 > 0$$

از آنجا که خروجی مدل مثبت اما برچسب واقعی منفی است، وزن به صورت زیر آپدیت می‌شود:

$$w_{new} = w_{old} + y \cdot x = [0,5] + (-1)[0,1] = [0,4]$$

۲) تعداد تکرار تا همگرایی

با توجه به توزیع نقاط، کلاس منفی توسط کلاس مثبت محصور شده است. بنابراین این دو مجموعه در فضای دو بعدی به صورت خطی تفکیک‌پذیر (Linearly Separable) نیستند. در نتیجه الگوریتم پرسپترون هرگز همگرا نخواهد شد:

$$\text{Iterations} = \infty$$

۳) تحلیل و انتخاب تبدیل‌های مناسب

برای همگرایی پرسپترون، داده‌ها باید در فضای جدید تفکیک‌پذیر خطی (Linearly Separable) باشند. تحلیل گزینه‌ها به شرح زیر است:

- $[x, y] \rightarrow [y, x]$: صرفاً جابه‌جایی محورهاست و تأثیری در تفکیک‌پذیری غیرخطی ندارد.
- $[x, y] \rightarrow [x, y, 1]$: تنها یک بُعد ثابت (بایاس) اضافه می‌کند که تغییری در آرایش نسبی نقاط ایجاد نمی‌کند.
- $[x, y] \rightarrow [x, y, x^2, 1]$: **صحیح است.** وجود جمله درجه دو (x^2) اجازه می‌دهد تا مرز تصمیم‌گیری منحنی (سهموی) در فضای اصلی داشته باشیم که نقاط داخلی را از خارجی جدا کند.
- $[x, y] \rightarrow [x, y, x^2 + y^2]$: هرچند $x^2 + y^2$ معیار خوبی برای فاصله است، اما چون بایاس (عدد ۱) ندارد، صفحه جداکننده حتماً باید از مبدأ عبور کند. با توجه به اینکه نقاط مثبت در همان راستای نقاط منفی اما با شعاع بیشتر هستند، صفحه‌ای که از مبدأ بگذرد نمی‌تواند آن‌ها را جدا کند.

انتخاب نهایی: $[x, y] \rightarrow [x, y, x^2, 1]$

۴) محاسبه بردار وزن برای تبدیل مرتبه دو

با استفاده از تبدیل $\phi(x, y) = [x, y, x^2 + y^2, 1]$، ویژگی سوم ($z = x^2 + y^2$) فاصله شعاعی را نشان می‌دهد:

- برای نقاط کلاس منفی: $x^2 + y^2 = 1$.
- برای نقاط کلاس مثبت: $x^2 + y^2 = 4$.

برای جداسازی، نیاز به صفحه‌ای داریم که بین $z = 1$ و $z = 4$ قرار گیرد. با صفر قرار دادن ضرایب x و y، و انتخاب وزن ۱ برای z و مقدار -2.5 برای بایاس، خواهیم داشت:

$$w = [0, 0, 1, -2.5]^\top$$

بررسی صحت:

- نقاط منفی: $1(1) - 2.5 = -1.5 < 0$ (Correct)
- نقاط مثبت: $1(4) - 2.5 = 1.5 > 0$ (Correct)

۵) معرفی تبدیل جایگزین

یک تبدیل دیگر که می‌تواند باعث جداسازی شود، استفاده از میانگین قدرمطلق مختصات (L1 Norm) است:

$$[x, y] \to [x, y, |x| + |y|, 1]$$

در این حالت برای نقاط منفی $|x| + |y| = 1$ و برای نقاط مثبت $|x| + |y| = 2$ است. بنابراین با قرار دادن یک آستانه در 1.5، داده‌ها تفکیک‌پذیر می‌شوند.

نمایش توابع توسط گراف‌های محاسباتی Neural Network Representations

در این مسئله توانایی گراف‌های مختلف محاسباتی در بازنمایی توابع خطی تکه‌ای (Piece-wise Linear) مورد بررسی قرار می‌گیرد. لازم به ذکر است که تابع (g) یعنی $\log(x)$ به دلیل غیرخطی بودنِ پیوسته، توسط هیچ‌یک از این شبکه‌های مبتنی بر ReLU قابل بازنمایی دقیق نیست.

۱. **گراف G_1 (تابع a):** این گراف خروجی $o = wx$ را محاسبه می‌کند. برای بازنمایی $2x$ کافی است قرار دهیم: $w = 2$

۲. **گراف G_2 (تابع b):** خروجی به صورت $o = wx + b$ است. برای بازنمایی $4x - 5$ داریم: $w = 4, b = -5$

۳. **گراف G_3 (توابع c و d):** این گراف خروجی $o = \text{ReLU}(wx + b)$ را تولید می‌کند.

- برای تابع (c): $w = 2, b = -5$
- برای تابع (d): $w = -2, b = -5$

۴. **گراف G_4 (تابع b):** این گراف ترکیب دو لایه خطی است که در نهایت به یک فرم خطی ساده $o = (w_1 w_2)x + (w_2 b_1 + b_2)$ تبدیل می‌شود. برای بازنمایی $4x - 5$: $w_1 = 4, b_1 = -5, w_2 = 1, b_2 = 0$

۵. **گراف G_5 (تابع e):** خروجی به صورت $o = w_2\text{ReLU}(w_1 x + b_1) + b_2$ است. تابع (e) را می‌توان به فرم $1 - \text{ReLU}(x - 2)$ نوشت. پارامترها: $w_1 = 1, b_1 = -2, w_2 = -1, b_2 = 1$

۶. **گراف G_6 (تابع f):** این گراف دارای دو لایه ReLU متوالی است. تابع (f) که شکلی شبیه به خیمه دارد را می‌توان با $\text{ReLU}(3 - \text{ReLU}(x))$ نمایش داد: $w_1 = 1, b_1 = 0, w_2 = -1, b_2 = 3, w_3 = 1, b_3 = 0$

۷. **گراف G_7 (تابع h):** این گراف مجموع وزنی دو مسیر ReLU موازی است. تابع (h) را می‌توان به صورت ترکیب $-0.5\text{ReLU}(-x) + 3\text{ReLU}(x - 3)$ بازنویسی کرد:

- مسیر اول: $w_1 = -1, b_1 = 0, w_3 = -0.5$
- مسیر دوم: $w_2 = 1, b_2 = -3, w_4 = 3$
- بایاس نهایی: $b_3 = 0$

رابطه بیشینه‌احتمال MLE و انتروپی متقاطع Cross-Entropy

۱) استخراج انتروپی متقاطع چندکلاسه

برای یک مسئله با K کلاس و برچسب‌های 1-of-K، خروجی شبکه y_k نشان‌دهنده احتمال $p(t_k = 1|x)$ است. طبق توزیع چندجمله‌ای (Multinomial)، احتمال مشاهده بردار هدف t_n برای داده n برابر است با:

$$p(t_n|x_n, w) = \prod_{k=1}^{K} y_{kn}^{t_{kn}}$$

با فرض مستقل و یکسان بودن توزیع داده‌ها (i.i.d.)، تابع درست‌نمایی کل (Likelihood) به صورت زیر است:

$$L(w) = \prod_{n=1}^{N} \prod_{k=1}^{K} y_{kn}^{t_{kn}}$$

تابع خطا (E) با گرفتن لگاریتم منفی از طرفین (Negative Log-Likelihood) به دست می‌آید:

$$E = -\ln L(w) = -\sum_{n=1}^{N} \sum_{k=1}^{K} t_{kn} \ln y_{kn}$$

که این همان فرمول استاندارد Cross-Entropy برای حالت چندکلاسه است.

۲) تحلیل برچسب‌های نویزی (Label Noise)

در این بخش فرض می‌کنیم برچسب‌ها دارای نویز ϵ هستند. برای یک مسئله دسته‌بندی دوتایی، احتمال مشاهده برچسب $t = 1$ را با در نظر گرفتن احتمال خطای ϵ به صورت زیر مدل می‌کنیم:

$$p(t = 1|x) = p(t = 1|c = 1)p(c = 1|x) + p(t = 1|c = 0)p(c = 0|x)$$

با فرض اینکه $p(c=1|x)=y$ (خروجی شبکه) و احتمال خطا در برچسب‌زنی ϵ باشد:

$$p(t=1|x)=(1-\epsilon)y+\epsilon(1-y)$$

به همین ترتیب برای برچسب $t=0$ داریم: $p(t=0|x)=(1-\epsilon)(1-y)+\epsilon y$. بنابراین تابع زیان (Negative Log-Likelihood) به صورت زیر به دست می‌آید:

$$E=-\sum_{n=1}^{N}\{t_n\ln[(1-\epsilon)y_n+\epsilon(1-y_n)]+(1-t_n)\ln[(1-\epsilon)(1-y_n)+\epsilon y_n]\}$$

بررسی صحت: اگر $\epsilon=0$ (حالت بدون نویز) باشد، عبارت داخل لگاریتم اول به y_n و در لگاریتم دوم به $1-y_n$ تبدیل می‌شود که دقیقاً همان انتروپی متقاطع استاندارد است. این فرمول نشان می‌دهد نویز باعث می‌شود مدل مرزهای تصمیم‌گیری سخت‌گیرانه‌ای نداشته باشد.

۳) تابع زیان برای برچسب‌های $t\in\{-1,1\}$

اگر برچسب‌ها در بازه $\{-1,1\}$ تعریف شوند، احتمال کلاس صحیح را می‌توان با استفاده از خروجی لایه قبل از فعال‌ساز (a) به صورت زیر بیان کرد:

$$p(t|a)=\sigma(ta)=\frac{1}{1+e^{-ta}}$$

با استفاده از روش MLE، تابع زیان برابر است با:

$$E=-\sum_{n=1}^{N}\ln\sigma(t_na_n)=\sum_{n=1}^{N}\ln(1+e^{-t_na_n})$$

مشتق این تابع نسبت به a_n جهت به‌روزرسانی وزن‌ها:

$$\frac{\partial E}{\partial a_n}=\frac{-t_ne^{-t_na_n}}{1+e^{-t_na_n}}=-t_n(1-\sigma(t_na_n))$$

انتخاب تابع فعال‌ساز: با توجه به اینکه هدف پیش‌بینی برچسب‌های $\{-1,1\}$ است، استفاده از تابع فعال‌ساز Hyperbolic Tangent (tanh) در لایه خروجی توصیه می‌شود، زیرا خروجی آن در

بازه $(-1, 1)$ قرار دارد و با ساختار برچسب‌ها سازگارتر است.

پایداری استوک استیک و پدیده Dead ReLU

در این مسئله یک نورون واحد با تابع فعال‌ساز ReLU را بررسی می‌کنیم: $a = \max(0, z)$ که در آن $z = w^\top x + b$.

۱) اثبات توزیع پیش‌فعالسازی (Pre-activation)

متغیر z ترکیبی خطی از متغیرهای تصادفی مستقل با توزیع نرمال است. از آنجا که $x_i \sim \mathcal{N}(0, \sigma_x^2)$ و $w_i \sim \mathcal{N}(0, \sigma_w^2)$، میانگین z برابر است با:

$$E[z] = E[\sum_{i=1}^{n} w_i x_i + b] = \sum_{i=1}^{n} E[w_i]E[x_i] + b = 0 + b = b$$

برای محاسبه واریانس σ_z^2، با توجه به استقلال متغیرها داریم:

$$Var(z) = Var(\sum_{i=1}^{n} w_i x_i + b) = \sum_{i=1}^{n} Var(w_i x_i)$$

از آنجا که $Var(wx) = E[w^2]E[x^2] - (E[w]E[x])^2$ و میانگین‌ها صفر است:

$$Var(w_i x_i) = \sigma_w^2 \sigma_x^2 \implies \sigma_z^2 = n\sigma_w^2\sigma_x^2$$

بنابراین $z \sim \mathcal{N}(b, \sigma_z^2)$.

۲) احتمال فعال بودن نورون

نورون زمانی فعال است که $z > 0$ باشد. با استانداردسازی متغیر z داریم:

$$P(a > 0) = P(z > 0) = P\left(\frac{z - b}{\sigma_z} > \frac{-b}{\sigma_z}\right)$$

با استفاده از تابع توزیع انباشته نرمال استاندارد (Φ):

$$P(a > 0) = 1 - \Phi\left(\frac{-b}{\sigma_z}\right) = \Phi\left(\frac{b}{\sigma_z}\right)$$

۳) آستانه 3σ و محاسبات عددی

اگر بایاس اولیه را $b = -3\sigma_z$ قرار دهیم:

$$P(a > 0) = \Phi(-3) \approx 0.00135$$

برای لایه‌ای با $N = 1000$ نورون، تعداد نورون‌های فعال مورد انتظار برابر است با:

$$E[\text{neurons active}] = N \times P(a > 0) = 1000 \times 0.00135 = 1.35 \approx 1$$

این یعنی تقریباً تمام نورون‌ها در ابتدای آموزش خاموش هستند.

۴) اثبات گرادیان صفر و پیامد ریاضی

اگر برای تمام نمونه‌های یک mini-batch داشته باشیم $z \leq 0$، آنگاه خروجی $a = 0$ و طبق فرض مسئله مشتق آن $\frac{\partial a}{\partial z} = 0$ خواهد بود. طبق قاعده زنجیره‌ای برای گرادیان نسبت به وزن‌ها:

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w}$$

چون $\frac{\partial a}{\partial z} = 0$، پس $\frac{\partial L}{\partial w} = 0$ و در نتیجه آپدیت وزن $\Delta w = 0$ خواهد بود. این نتیجه نشان می‌دهد که اگر یک نورون برای تمام داده‌های آموزش در ناحیه غیرفعال ReLU قرار بگیرد، گرادیان آن صفر شده و وزن‌هایش هرگز تغییر نمی‌کنند. به این پدیده مرگ نورون گفته می‌شود زیرا هیچ

سازوکاری برای رستاخیز یا بازگشت این نورون به چرخه یادگیری در طول بهینه‌سازی وجود ندارد.

حفظ واریانس و مقداردهی اولیه زویر Xavier Initialization

۱) اثبات محدودیت‌های متقارن

در یک لایه خطی $y = Wx$، با فرض اینکه وزن‌ها و ورودی‌ها مستقل، دارای میانگین صفر و توزیع یکسان باشند، واریانس خروجی برای هر نورون y_j به صورت زیر است:

$$Var(y) = \sum_{i=1}^{n_{in}} Var(w_{ji}x_i) = n_{in}Var(W)Var(x)$$

برای حفظ پایداری سیگنال در مسیر رفت (Forward Pass)، یعنی $Var(y) = Var(x)$، شرط زیر لازم است:

$$n_{in}Var(W) = 1 \implies Var(W) = \frac{1}{n_{in}}$$

به طور مشابه در مسیر برگشت (Backward Pass)، برای جلوگیری از محو شدن یا انفجار گرادیان‌ها، با توجه به تعداد خروجی‌ها (n_{out}) به شرط زیر می‌رسیم:

$$Var(W) = \frac{1}{n_{out}}$$

۲) سنتز گلوروت (Xavier)

از آنجا که معمولاً $n_{in} \neq n_{out}$ است، امکان ارضای هم‌زمان هر دو شرط وجود ندارد. زویر گلوروت پیشنهاد داد که از میانگین این دو مقدار برای تنظیم واریانس استفاده شود:

$$Var(W) = \frac{2}{n_{in} + n_{out}}$$

این انتخاب به عنوان یک مصالحه، پایداری واریانس سیگنال و گرادیان را در کل شبکه تضمین می‌کند.

۳) واریانس القا شده توسط عمق

با تعریف بهره لایه به صورت $G = n \cdot Var(W)$ و با توجه به رابطه بازگشتی $Var(y^{(l)}) = G \cdot Var(y^{(l-1)})$، واریانس خروجی در لایه Lـام برابر خواهد بود با:

$$Var(y^{(L)}) = G^L \cdot Var(x^{(0)}) = (n \cdot Var(W))^L Var(x^{(0)})$$

۴) کران پایداری و رشد نمایی

اگر مقداردهی اولیه دارای خطای کوچک ϵ باشد به طوری که $n \cdot Var(W) = 1 + \epsilon$:

$$Var(y^{(L)}) = (1+\epsilon)^L Var(x^{(0)})$$

برای مقادیر بزرگ L و ϵ کوچک، می‌توان این رشد را با تابع نمایی تقریب زد: $(1+\epsilon)^L \approx e^{L\epsilon}$. این موضوع نشان می‌دهد که کوچکترین انحراف از مقیاس‌گذاری صحیح، منجر به رشد یا زوال نمایی واریانس در عمق شبکه می‌شود.

۵) تحلیل عددی و مخاطرات FP16

برای شبکه‌ای با عمق $L = 150$ و خطای $\epsilon = 0.02$، فاکتور تقویت برابر است با:

$$(1.02)^{150} \approx 19.49$$

این موضوع در آموزش با دقت ۱۶ بیتی (FP16) بسیار بحرانی است، زیرا:

- **محدوده پویا (Dynamic Range):** در FP16 بزرگترین عدد قابل نمایش حدود $65,504$ است. تقویت ۲۰ برابری واریانس در هر مرحله از آموزش می‌تواند منجر به سرریز عددی (Overflow) و تولید مقادیر NaN شود.
- **ناپایداری در بهینه‌سازی:** این بی‌ثباتی باعث محو شدن (Underflow) یا انفجار گرادیان‌ها شده و همگرایی مدل را دشوار می‌کند، که لزوم استفاده از تکنیک‌هایی مانند Gradient

Clipping را دوچندان می‌سازد.

یادگیری انتقالی با استفاده از شبکه‌های پیش‌آموزش‌دیده

۱.۱۰ روش تحقیق و معماری مدل‌ها

در این بخش، عملکرد سه مدل مختلف بر روی مجموعه داده CIFAR-10 با استفاده از بهینه‌ساز Adam و اندازه دسته (batch size) ۵۱۲ مورد ارزیابی قرار گرفت:

- **مدل ۱ MLP Baseline:** یک شبکه عصبی تمام‌متصل که تصاویر را به صورت بردار تخت (flattened) دریافت کرده و کاملاً از ابتدا آموزش دیده است.
- **مدل ۲ Frozen VGG-11:** معماری VGG-11 که روی ImageNet پیش‌آموزش دیده و لایه‌های استخراج ویژگی آن منجمد (frozen) شده‌اند. تنها بخش طبقه‌بندی‌کننده (classifier) آن برای ۱۰ کلاس جدید آموزش می‌بیند.
- **مدل ۳ Fine-Tuned VGG-11:** همان معماری مدل قبلی، با این تفاوت که تمامی لایه‌ها اجازه آپدیت شدن دارند تا ویژگی‌ها با جزئیات داده‌های جدید سازگار شوند.

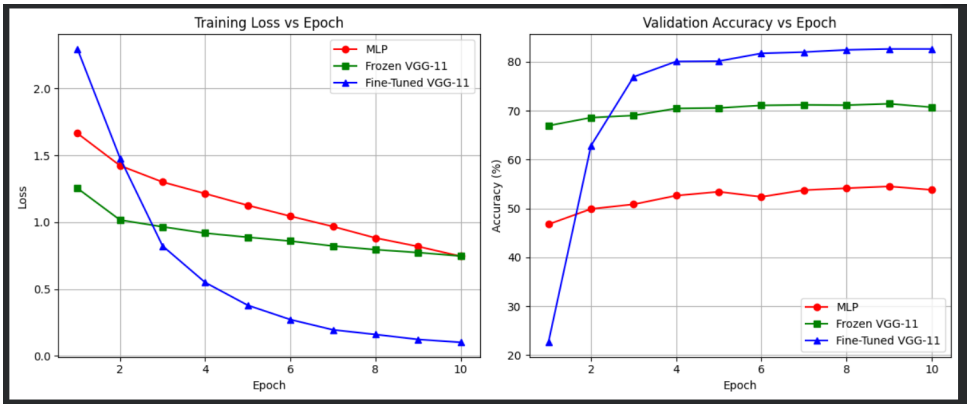
۲.۱۰ نتایج عددی و نمودارها

نمودارهای مربوط به تابع زیان آموزش (Training Loss) و دقت اعتبارسنجی (Validation Accuracy) در شکل زیر نمایش داده شده است:

۳.۱۰ بحث و تحلیل (Discussion)

الف) بررسی همگرایی و پایداری

طبق نمودارها، مدل Frozen VGG-11 به دلیل استفاده از ویژگی‌های استخراج‌شده از قبل، بلافاصله در اپوک اول به دقت بالای ٪۶۰ دست یافت که نشان‌دهنده یک شروع قدرتمند (Head Start)



شکل ۴: مقایسه عملکرد سه مدل در ۱۰ اپوک: سمت راست دقت اعتبارسنجی و سمت چپ تابع زیان آموزش.

است. در مقابل، مدل Fine-Tuned VGG-11 در ابتدا به دلیل تغییر در وزن‌های لایه آخر و انتشار گرادیان‌های نویزی به لایه‌های پایین‌تر، شروع کندتری داشت، اما پس از اپوک سوم با سرعت بسیار زیاد از بقیه مدل‌ها پیشی گرفت و به دقت نهایی حدود ٪۸۲ رسید. مدل MLP کمترین سرعت همگرایی را داشته و در دقت ٪۵۴ متوقف شد. این تفاوت نشان می‌دهد که مقداردهی اولیه با وزن‌های پیش‌آموزش‌دیده، مدل را در "ناحیه جذب" (Basin of Attraction) بهینه‌ای قرار می‌دهد که بهینه‌سازی را بسیار پایدارتر از آموزش از صفر می‌کند.

ب شکاف تعمیم‌پذیری و سوگیری استقرایی Inductive Bias

نکته قابل توجه در نمودارها این است که در اپوک ۱۰، مقدار Loss برای مدل MLP و Frozen VGG تقریباً یکسان (حدود ۰.۷۵) است، اما دقت مدل VGG حدود ٪۱۵ بالاتر است. دلیل این شکاف عملکرد به سوگیری استقرایی (Inductive Bias) شبکه‌های کانولوشنی بازمی‌گردد:

- مدل **MLP** تصویر را به صورت یک بردار یک‌بعدی می‌بیند و روابط فضایی بین پیکسل‌های مجاور را از دست می‌دهد.
- مدل **VGG** به دلیل استفاده از لایه‌های کانولوشن، ویژگی‌هایی مانند ثبات در جابه‌جایی (Translation Invariance) و محلی بودن الگوها را در ساختار خود دارد. این باعث می‌شود حتی زمانی که لایه‌های کانولوشن تغییر نمی‌کنند، مدل قدرت تعمیم‌دهی بسیار بالاتری نسبت به یک شبکه تمام‌متصل داشته باشد.

منابع و مراجع

۱. Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

۲. Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

۳. Lecture Notes & Homework Statement, Machine Learning Basics Course, University of Tehran, Fall 2025.

۴. Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.